

Tilastollisen päättelyn peruskurssi, kevät 2024 — Harjoitus 2

1. Uudenvuodenpäivän keskilämpötilat Turun Artukaisissa vuosina 2011–2024 olivat (lähde Ilmatieteen laitos):

-3.4 -2.1 3.8 4.0 2.8 -4.3 -1.5 0.8 2.5 3.1 1.9 -6.0 -0.6 -16.6

- a.) Määritä havaintojen mediaani ja kvartiilit sekä piirrä niiden jakaumaa kuvaava Tukeyn laatikko-janakuvio. Tee kaikki tämä ”käsini” ilman R:ää. Kirjaa myös tarpeelliset perustelut vastaukseesi mukaan.
- b.) Laske havaintojen otoskeskiarvo ja -keskihajonta. (Tässä saa käyttää halutessaan R:ää.) Huom. Jos haluat tarkistaa kvanttiileja R:llä, kurssilla esitettyä p-kvantiilin määritelmää vastaa komento `quantile(x,p,type=2)`, jossa x on havainnoista koostuva vektori, esim. tässä $x \leftarrow c(-3.4, -2.1, 3.8, 4.0, 2.8, -4.3, -1.5, 0.8, 2.5, 3.1, 1.9, -6.0, -0.6, -16.6)$.

a.)

Koska havaintoja on parillinen lkm., mediaani muodostuu järjestettyjen havaintojen keskimmäisten havaintojen keskiarvosta:

$$1/2 * (-0.6 + 0.8) = 0.1$$

Kvartiileja laskettaessa $n=14$. Kvartiili $q(0.5)$ on sama kuin mediaani:


$$q(0.5) = 0.1$$

Lasketaan ensin $q(0.25)$ ja $q(0.75)$ järjestysluvut ja sitten niitä vastaavat arvot järjestetyistä havainnoista:

$$\lceil 14/4 \rceil = 4 \rightarrow q(0.25) = -3.4$$

$$\lceil 3 * 14/4 \rceil = 11 \rightarrow q(0.75) = 2.8$$

Tukeyn laatikko-janakuvio käsini piirrettynä:



b.)

Lasketaan otoskeskiarvo R:n komennolla 'mean' ja otoskeskihajonta komennolla 'sd':

```
> x <- c(-3.4,-2.1,3.8,4.0,2.8,-4.3,-1.5,0.8,2.5,3.1,1.9,-6.0,-0.6,-16.6)
> mean(x)
[1] -1.114286
> sd(x)
[1] 5.474677
```

2. Liitteessä on kolme Tukeyn laatikko-janakuvioita ja kolme normaalikvantiilikuvioita, jotka esittävät kolmea eri aineistoa, kussakin 75 havaintoa.

a.) Mitkä laatikko-janakuvioita ja normaalikvantiilikuvioita vastaavat toisiaan?

b.) Kuvaile kutakin kolmea aineistoa sopivilla ilmauksilla seuraavista: vasemmalle vino, oikealle vino, (likimain) normaalisti jakautunut, huipukas, litteä.

a.)

Laatikko-janakuvio	Normaalikvantiilikuvio
A	2
B	3
C	1

b.)


Aineisto	Kuvaus
A/2	(likimain) normaalisti jakautunut
B/3	oikealle vino
C/1	litteä

3. (R) Moodlessa olevassa R-skriptissä harjoitus2.r tutkitaan terveys.csv-aineistoa, joka sekin on Moodlessa. Lataa nämä koneellesi, käy koodi läpi ja suorita se sekä varmistu, että ymmärrät, mitä siinä tehdään.


- Lisää terveys-aineistoon uusi painoindeksimuuttuja (body mass index) komennolla `'terveys$bmi <- terveys$paino/(terveys$pituus/100)^2'`. Piirrä tämän muuttujan arvojen histogrammi.
- Piirrä muuttujan 'bmi' arvoista Tukeyn laatikko-janakuviot ('boxplot') erikseen miehille ja naisille. Miten kuvailisit miesten ja naisten painoindeksien eroja?
- Piirrä muuttujan 'bmi' normaalikvantiilikuviot miehille ja naisille erikseen ('qqnorm' ja 'qqline'). Millaisia johtopäätöksiä voit tehdä kuvioiden perusteella muuttujan jakaumasta?

a.)


Luodaan histogrammi komennolla `'hist(terveys$bmi)'`:



b.)




1: Naisten BMI




2: Miesten BMI

Miesten BMI:n mediaani on merkittävästi naisten BMI:n mediaania korkeampi. Miehiä koskevasta aineistosta on myös havaittavissa, että havainnoissa on enemmän hajontaa kuin naisia koskevassa aineistossa.

c.)



3: Naisten BMI



4: Miesten BMI

Kumpikaan aineistoista ei ole kovin lähellä normaalijakautunutta aineistoa, mutta molemmat jakavat piirteitä huipukkaan jakauman kanssa. Tämän lisäksi miehiä koskeva aineisto on piirteiltään hieman oikealle vino (vrt. normaalijakautuneeseen aineistoon).

4. Todista, että havaintojen $x_1, \dots, x_n$ otosvarianssille pätee

$$s^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right] = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right].$$

Tässä on siis tarkistettava kaksi yhtäsuuruutta: ensimmäinen on luentomuistiinpanojen sivun 23 lauseen 1 väite ja toinen (helpompi) on vaihtoehtoinen tapa sen kirjoittamiseen.

Otosvarianssi s^2 on määritelty havaintojen erojen summan ja havaintojen keskiarvon keskiarvona:

$$s^2 = 1/(n-1) \sum_{i=1}^n (x_i - \bar{x})^2$$

Kaavassa x_i kuvaa yksittäistä havaintoa, $\bar{x}$ havaintojen keskiarvoa ja n havaintojen lukumäärää.

Muuttuja s^2 voidaan laventaa seuraavasti:

$$s^2 = 1/(n-1) \sum_{i=1}^n (x_i^2 - 2x_i\bar{x} + \bar{x}^2) = 1/(n-1) \left(\sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2 \right)$$

Koska havaintojen keskiarvo on $\sum_{i=1}^n x_i = n\bar{x}$, voidaan sieventää edelleen:

$$s^2 = 1/(n-1) \left(\sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \right) = 1/(n-1) \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)$$

Koska $\bar{x} = 1/(n-1) \sum_{i=1}^n x_i$, voidaan nyt merkitä $\bar{x}^2 = (1/n \sum_{i=1}^n x_i)^2$:

$$s^2 = 1/(n-1) \left[\sum_{i=1}^n x_i^2 - 1/n \left(\sum_{i=1}^n x_i \right)^2 \right]$$