

Tilastollisen päättelyn peruskurssi, kevät 2024 — Harjoitus 2

Tehtävien 1–4 ratkaisut ladataan palautusalueelle Moodlessa pe 19.1. klo 16 mennessä ja vertaisarvioidaan. Lue palautusohjeet huolella. **Tehtävä 5** on vapaa lisätehtävä, jota ei palauteta.

1. Uudenvuodenpäivän keskilämpötilat Turun Artukaisissa vuosina 2011–2024 olivat (lähde Ilmatieteen laitos):

−3.4 −2.1 3.8 4.0 2.8 −4.3 −1.5 0.8 2.5 3.1 1.9 −6.0 −0.6 −16.6

a) Määritä havaintojen mediaani ja kvartiilit sekä piirrä niiden jakaumaa kuvaava Tukeyn laatikko-janakuvio. Tee kaikki tämä ”käsini” ilman R:ää. Kirjaa myös tarpeelliset perustelut vastaukseesi mukaan.

b) Laske havaintojen otoskeskiarvo ja -keskihajonta. (Tässä saa käyttää halutessaan R:ää.)

Huom. Jos haluat tarkistaa kvantileja R:llä, kurssilla esitettyä p -kvantiilin määritelmää vastaa komento `quantile(x,p,type=2)`, jossa x on havainnoista koostuva vektori, esim. tässä `x <- c(-3.4,-2.1,3.8,4.0,2.8,-4.3,-1.5,0.8,2.5,3.1,1.9,-6.0,-0.6,-16.6)`.

2. Liitteessä on kolme Tukeyn laatikko-janakuvioita ja kolme normaalikvantiilikuvioita, jotka esittävät kolmea eri aineistoa, kussakin 75 havaintoa.

a) Mitkä laatikko-janakuvioita ja normaalikvantiilikuvioita vastaavat toisiaan?

b) Kuvaile kutakin kolmea aineistoa sopivilla ilmauksilla seuraavista: vasemmalle vino, oikealle vino, (likimain) normaalisti jakautunut, huipukas, litteä.

3. (R) Moodlessa olevassa R-skriptissä `harjoitus2.r` tutkitaan `terveys.csv`-aineistoa, joka sekin on Moodlessa. Lataa nämä koneellesi, käy koodi läpi ja suorita se sekä varmistu, että ymmärrät, mitä siinä tehdään. (Tätä osiota ei tarvitse sisällyttää palautukseen.)

a) Lisää `terveys`-aineistoon uusi painoindeksimuuttuja (*body mass index*) komennolla

```
terveys$bmi <- terveys$paino/(terveys$pituuks/100)^2
```

Piirrä tämän muuttujan arvojen histogrammi.

Jaetaan aineisto kahteen osa-aineistoon, miehet ja naiset erikseen:

```
terveys.m <- subset(terveys,sukupuoli=="Mies")
terveys.n <- subset(terveys,sukupuoli=="Nainen")
```

Nyt voit viitata esimerkiksi naisten `bmi`-arvoihin kirjoittamalla `terveys.n$bmi`.

b) Piirrä muuttujan `bmi` arvoista Tukeyn laatikko-janakuvioita (`boxplot`) erikseen miehille ja naisille. Miten kuvailisit miesten ja naisten painoindeksien eroja?

c) Piirrä muuttujan `bmi` normaalikvantiilikuvioita miehille ja naisille erikseen (`qqnorm` ja `qqline`). Millaisia johtopäätöksiä voit tehdä kuvioiden perusteella muuttujan jakaumasta?

4. Todista, että havaintojen $x_1, \dots, x_n$ otosvarianssille pätee

$$s^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right] = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right].$$

Tässä on siis tarkistettava kaksi yhtäsuuruutta: ensimmäinen on luentomuistiinpanojen sivun 23 lauseen 1 väite ja toinen (helpompi) on vaihtoehtoinen tapa sen kirjoittamiseen.

— — —

5. (R) ”Perus-R:ssä” ei ole valmiita funktioita aineiston jakauman vinouden tai huipukkuuden laskemiseen (joskin sellaiset löytyvät monista netistä ladattavista paketeista); ks. muistiinpanojen jaksojen 2.3.3 ja 2.3.4 määritelmät.

Seuraavassa on R-koodi, joka määrittelee `vinous`-funktion, jolla voi laskea argumenttina annettavan `x`-vektorin sisältämän aineiston vinouden:

```
vinous <- function(x) {  
  n <- length(x) # havaintojen lkm  
  ka <- mean(x)   # otoskeskiarvo  
  (1/n)*sum((x-ka)^3) / ((1/n)*sum((x-ka)^2))^(3/2)  
}
```

Suorita tämä määrittely R:ssä ja kokeile funktion toimintaa joihinkin `terveys`-aineiston numeerisiin muuttujiin. Muodosta sitten vastaavalla tavalla R-funktio `huipukkuus`, joka laskee argumenttinaan annettavan aineiston huipukkuuden, ja kokeile senkin toimintaa. Huomaa, että funktion määrittelyssä viimeisellä koodirivillä annetaan palautettava funktion arvo.

Huom. Tilastoseuran *Tilastotieteen sanasto* (<https://sanasto.tilastoseura.fi/>) suosittelee ”huipukkuuden” sijasta käytettävän termiä *kurtoosi* (engl. *kurtosis*), sillä ko. tunnusluku ei loppujen lopuksi kuvaa niinkään jakauman huippua vaan riippuu enemmänkin sen hännistä.

