

TILM3555 — Harjoitus 3


February 27, 2024

Tehtävä 1


Korrelaatiokerroin ja PNS-suora sopivat hyvin lineaaristen riippuvuuksien kuvaamiseen. Niiden avulla ei kuitenkaan voida selvittää epälineaarisia riippuvuussuhteita. Kuvioissa *A* ja *B* on havaittavissa suhteellisen vahvaa positiivista lineaarista riippuvuutta. Kuvioissa *D* ja *E* on puolestaan havaittavissa erittäin vahvaa (*D*:ssä täydellistä) negatiivista lineaarista riippuvuutta. Kuviossa *C* puolestaan ei ole minkäänlaista lineaarista riippuvuutta, mutta kuitenkin voimakasta epälineaarista riippuvuutta (koska havainnot asettuvat tietylle muodolle, tässä tapauksessa paraabelille).

Yhdistetään tehtävänannon PNS-suorien kulmakertoimien arvot sekä harjoituksen liitetiedoston hajontakuviot toisiinsa. Hahmotellaan tämän jälkeen PNS-suoria liitetiedoston kuvioihin:

<i>A</i>	0.7
<i>B</i>	0.4
<i>C</i>	0
<i>D</i>	-1
<i>E</i>	-0.9




E



Tehtävä 2

Laskemalla aineistojen väliset korrelaatiokertoimet huomataan, että Turku-Helsinki välillä on merkittävää korrelaatiota ($r_{xy} \approx 0.90$). Tämän tiedon perusteella sovitetaan siis kyseiseen hajontakuviioon myös PNS-suora:



```

Tku <- c(62.4, 32.5, 72.8, 10, 20.9, 11.3, 40.8, 146.1, 46.5, 100.9, 76.6, 26.1)
Hki <- c(82.5, 39, 65, 10.2, 17.5, 4.5, 94.3, 172.5, 70.7, 130.6, 60.6, 67.4)
Ina <- c(27.3, 15.6, 25.6, 13.5, 55.6, 13.4, 105.9, 82.3, 87, 15.8, 22.2, 20.5)

# Haiontakuvio plot-komennolla, PNS-suora abline-komennolla ja
# korrelaatiokerroin cor-komennolla

# Turku-Helsinki
plot(Tku, Hki, xlab="Turku", ylab="Helsinki", main="Turku-Helsinki")
abline(lm(Tku ~ Hki))
cor(Tku, Hki)

# Turku-Inari
plot(Tku, Ina, xlab="Turku", ylab="Inari", main="Turku-Inari")
cor(Tku, Ina)

# Helsinki-Inari
plot(Hki, Ina, xlab="Helsinki", ylab="Inari", main="Helsinki-Inari")
cor(Hki, Ina)

> cor(Tku, Hki)
[1] 0.9001893
> cor(Tku, Ina)
[1] 0.2438302
> cor(Hki, Ina)
[1] 0.4385289

```

Kuvioiden generoimiseen käytetty R-koodi ja sen tulostamat korrelaatiokertoimet

Tehtävä 3

Näytetään todeksi, että PNS-suoran yhtälö $y = a + bx$ voidaan kirjoittaa muodossa

$$\frac{y - \bar{y}}{s_y} = r_{xy} \frac{x - \bar{x}}{s_x},$$

jossa otoskorrelaatiokerroin r_{xy} on määritelty seuraavasti:

$$r_{xy} = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}.$$

Tiedetään, että pienimmän neliösumman kriteerinä on, että a ja b tulee valita siten, että jäännösumma $\sum_{i=1}^n (y_i - a - bx_i)^2$ minimoituu. Tämä tapahtuu kun seuraavat yhtälöt ovat tosia:

$$b = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$a = \bar{y} - b\bar{x}$$

Yhdistämällä tämän määritelmän kaavat:

$$y = (\bar{y} - b\bar{x}) + bx = \bar{y} - r_{xy} \frac{s_y}{s_x} \bar{x} + r_{xy} \frac{s_y}{s_x} x.$$

Saatu kaava voidaan muokata tehtävänannon esittämän kaavan muotoon uudelleenjärjestämällä termit:

$$y = \bar{y} + r_{xy} \frac{s_y}{s_x} (x - \bar{x})$$

$$\frac{y - \bar{y}}{s_y} = r_{xy} \frac{x - \bar{x}}{s_x},$$

Tehtävä 4

a.)

Populaation noudattaessa normaalijakaumaa $N(\mu, \sigma^2)$, noudattaa otoskeskiarvo $\bar{X}$ jakaumaa $N(\mu, \frac{\sigma^2}{n})$. Tässä tapauksessa populaation noudattaessa jakaumaa $N(1, 2)$ ja otoskoon ollessa n , on kysytty jakauma siis $N(1, \frac{2}{n})$.

b.)

Määritellään todennäköisyys $P(|\bar{X} - 1| > 0.1)$, kun $n = 10$ eli tarkasteltava populaatio noudattaa jakaumaa $N(1, \frac{1}{5})$. Muunnetaan jakauma ensin standardoiduksi normaalijakaumaksi hyödyntämällä tietoa normaalijakauman symmetrisyydestä ja lasketaan sitten todennäköisyys kertymäfunktion Φ avulla:

$$P(|\bar{X} - 1| > 0.1) = 2P(\bar{X} - 1 < -0.1) = 2P\left(\frac{\bar{X} - 1}{\sqrt{0.2}} > \frac{0.1}{\sqrt{1/5}}\right) = 2P(Z < -0.1\sqrt{5}) = 2(\Phi(-0.1\sqrt{5}))$$

joka voidaan ratkaista joko R:llä tai käsin taulukkokirjan avulla:

$$2(\Phi(-0.1\sqrt{5})) = 2(1 - \Phi(0.1\sqrt{5})) = 2(1 - 0.5871) = 2 \cdot 0.4129 = 0.8258 \approx 0.83$$

c.)

Ratkaistaan aiemman tehtävän perusteella seuraava yhtälö (epäyhtälön sijaan, koska tällöin saadaan suurin mahdollinen n). Kun n on tuntematon, pätee otoskeskiarvon otosjakaumalle $\bar{X} \sim N(1, \frac{2}{n})$:

$$\begin{aligned} 2P\left(\frac{\bar{X} - 1}{\sqrt{2/n}} > \frac{0.1}{\sqrt{2/n}}\right) &= 0.01 \\ \Rightarrow 2P\left(Z > \frac{0.1}{\sqrt{2/n}}\right) &= 0.01 \\ \Rightarrow 2\left(1 - P\left(Z < \frac{0.1}{\sqrt{2/n}}\right)\right) &= 0.01 \\ \Rightarrow P\left(Z < \frac{0.1}{\sqrt{2/n}}\right) &= 0.995 \\ \Rightarrow \Phi\left(\frac{0.1}{\sqrt{2/n}}\right) &= 0.995 \\ \Rightarrow \frac{0.1}{\sqrt{2/n}} &= \Phi^{-1}(0.995) \end{aligned}$$

$$\Rightarrow \sqrt{n} = 10\sqrt{2} \cdot \Phi^{-1}(0.995), \text{ josta ratk. } n \approx 1327.$$

Tehtävä 5 (lisätehtävä)

a.)

Odotusarvon lineaarisuuden perusteella

$$E(X + Y) = E(X) + E(Y) = 1 + 2 = 3$$

$$E(2X) = 2 \cdot E(X) = 2 \cdot 1 = 2$$

b.)

Mikäli satunnaismuuttujat X ja Y eivät olisi riippumattomia (ts. niiden kovarianssi ei olisi nolla), olisi $Var(X + Y) = Var(X) + Var(Y) + 2cov(X, Y)$. Koska kuitenkin $X \perp\!\!\!\perp Y$, ei satunnaismuuttujien välimerkki vaikuta varianssin arvoon ja kovarianssi on nolla, jolloin

$$Var(X \pm Y) = Var(X) + Var(Y) = 1 + 2 = 3$$

$$Var(2X) = 2^2 Var(X) = 4 \cdot 1 = 4.$$

c.)

Yleisesti jos $X \sim N(\mu_X, \sigma_X^2)$, $Y \sim N(\mu_Y, \sigma_Y^2)$ ja $X \perp\!\!\!\perp Y$, niin

$$Z = X + Y \sim N(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2) = N(1 + 2, 1 + 2) = N(3, 3).$$

d.)

Kun n on suuri, $X_1, \dots, X_n$ ovat riippumattomia ja samoin jakautuneita satunnaismuuttujia, joille $X \sim N(1, 2)$, niin likimain

$$\bar{X} \sim N(1, \frac{2}{n}) \text{ ja } Z \sim N(0, 1).$$