

Tehtävien 1–4 ratkaisut ladataan palautusalueelle Moodlessa pe 2.2. klo 16 mennessä ja vertaisarvioidaan. **Tehtävät 5 ja 6** ovat vapaita lisätehtäviä, joita ei palauteta.

1. Suuren hake-erän kosteusprosentin $[(\text{märkápaino} - \text{kuivapaino}) / \text{märkápaino} \times 100]$ määrittämiseksi erästä tehtiin seitsemän paikallista kosteusmittausta, joiden arvot olivat 36, 43, 38, 39, 37, 38 ja 44. Laske mittausten otoskeskiarvo ja otoskeskihajonta sekä muodosta 90 %:n luottamusväli hake-erän keskimääräiselle kosteusprosentille, kun oletetaan, että kosteuspitoisuuden vaihtelu hakkeessa on (likimain) normaalisti jakautunutta.

Ohje. Voit tehdä tehtävän ”käsini” ja peruslaskimella tai vaihtoehtoisesti R:llä. Kaikkien välivaiheiden tulee kuitenkin näkyä ratkaisusta. Studentin t -jakauman kvantiilien etsimiseen voi käyttää R:n funktiota `qt` tai jotakin netistä löytyvää laskinta, esim. <https://stattrek.com/online-calculator/t-distribution>. Muistiinpanojen s. 83 taulukon avulla tulee myös toimeen, ja sekin on syytä opetella esim. tenttiä varten.

2. Merkitään I :llä edellisessä tehtävässä muodostettua luottamusväliä ja μ :llä hake-erän keskimääräistä kosteusprosenttia. Mitkä seuraavista tulkinnoista ovat oikein ja mitkä väärin? Perustele erityisesti väärin tulkintojen kohdalla, miksi ne ovat väärin.

- a) μ :n todennäköisyysjakaumasta 90 % sijaitsee välillä I .
- b) Jos samanlaisia seitsemän mittauksen ”otoksia” tehtäisiin useita ja jokaisesta muodostettaisiin vastaava luottamusväli I , kuuluisi μ :n arvo noin 90 %:iin näistä väleistä.
- c) Jos paikallisia kosteusmittauksia tehtäisiin suuri määrä, niiden tuloksista noin 90 % sijoittuisi välille I .

3. On poimittu satunnaisotos kokoa n normaalijakaumasta $N(\mu, \sigma^2)$, jossa μ on estimoinnin kohteena oleva parametri. Oletetaan helppouden vuoksi $\sigma^2 > 0$ tunnetuksi luvuksi (halutessasi voit valita $\sigma^2 = 1$) ja tarkastellaan luentomuistiinpanojen sivulla 39 esitettyä μ :n kaksipuolisen luottamusvälin kaavaa.

- a) Miten otoskoon n kasvu vaikuttaa luottamusvälin pituuteen? Jos luottamusvälin pituus halutaan puoleen aikaisemmasta eli halutaan ”kaksinkertainen tarkkuus”, mitä n :lle on tehtävä?
- b) Viimeiset prosentit luottamustason $1 - \alpha$ kasvattamisessa kohti sataa prosenttia ovat kalliita. Jos luottamustaso nostetaan 90 %:sta 95 %:iin, kuinka moninkertaiseksi luottamusväli tulee pituudeltaan? Entä jos nostetaan luottamustaso 95 %:sta 99 %:iin?
- c) Oletetaan, että $\sigma^2 = 1$. Kuinka suuri on otoskoon n likimain oltava, jotta 95 %:n luottamusväli μ :lle olisi pituudeltaan noin 0.1 eli muotoa $(\bar{x} - 0.05, \bar{x} + 0.05)$?

Huom. Muistiinpanoissa normaalijakaumaa on merkitty $\text{Normal}(\mu, \sigma^2)$.

4. Tutkimusryhmät A ja B ovat toisistaan riippumattomasti tutkineet populaatiota, jota voidaan kuvata normaalijakaumalla $N(\mu, \sigma^2)$, jossa molemmat parametrit ovat tuntemattomia ja kiinnostuksen kohteena. Tutkimusryhmien tulokset (otoskoko, otoskeskiarvo ja otosvarianssi) ovat vastaavasti

$$\begin{aligned} n_A &= 10, & \bar{x}_A &= 3.90, & s_A^2 &= 1.90 \\ n_B &= 20, & \bar{x}_B &= 3.50, & s_B^2 &= 1.30 \end{aligned}$$

Tehtäväsi on harjoittaa meta-analyysiä eli yhdistää näiden kahden tutkimuksen tulokset. Laske parametrien μ ja σ^2 tavanomaiset piste-estimaatit eli otoskeskiarvo ja otosvarianssi käyttämällä hyväksi sekä ryhmän A että ryhmän B havainnot yhdessä.

Apu. Otosvarianssi saattaa olla hieman haastava. Harjoituksen 2 tehtävän 4 kaava voi olla avuksi.

— — —

5. Tarkastellaan normaalijakauman $N(\mu, \sigma^2)$ odotusarvon luottamusväliä, kun sekä μ että σ^2 ovat tuntemattomia. Joissakin lähteissä kerrotaan, että suuren otoskoon tapauksessa (esim. $n \geq 25$) luottamusväli voidaan laskea t -luottamusvälin kaavan (muistiinpanojen s. 40–41) sijasta z -luottamusvälin kaavalla (s. 39), johon sijoitetaan $\sigma = s$. Tällä tavalla saatava väli on aina lyhyempi kuin ”oikea” t -luottamusväli, mutta riittävän suurella otoskoolla tällä erolla ei ole käytännön merkitystä. (Puhumme tässä kaksipuolisesta $\bar{x}$:n suhteen symmetrisestä luottamusvälistä.)

a) Kuinka monta prosenttia leveämpi 95 %:n t -luottamusväli on kuin 95 %:n z -luottamusväli, jos $n = 25$?

b) Kuinka suuri otoskoon n pitää olla, jotta 95 %:n t -luottamusväli olisi enintään yhden prosentin leveämpi kuin 95 %:n z -luottamusväli?

6. Oletetaan, että $X_1, \dots, X_n$ on (riippumaton) satunnaisotos jakaumasta $N(\mu, \sigma^2)$.

a) Joskus parametrin σ^2 estimaattorina käytetään muuttujaa

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

(esimerkiksi ns. suurimman uskottavuuden menetelmä antaa tämän estimaattorin). Laske sen odotusarvo ja totea, että se on *alaspäin harhainen* eli $E(\hat{\sigma}^2) < \sigma^2$.

b) Siinä harvinaisessa tapauksessa, että odotusarvo μ tunnetaan, voidaan estimaattorina käyttää myös muuttujaa

$$\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2.$$

Laske sen odotusarvo ja totea, että se on harhaton.

Lisätieto. Kysymys siitä, mikä estimaattori on *paras* missäkin estimointitehtävässä ei ole useinkaan yksiselitteinen – ei edes niin perustavassa tehtävässä kuin normaalijakauman varianssin estimointi. Voidaan esimerkiksi osoittaa, että $\hat{\sigma}^2$ on (vaikkakin harhainen) parempi kuin S^2 siinä mielessä, että sillä on pienempi *keskineliövirhe*: $E[(\hat{\sigma}^2 - \sigma^2)^2] < E[(S^2 - \sigma^2)^2]$. Tällaisia aiheita pohditaan aine- ja syventävien opintojen päättelyn kursseilla.