

TILM3555 — Harjoitus 5

February 10, 2024

Tehtävä 1

Käsitellään tehtävänannon aineistoa parittaisina havaintoina ja oletetaan, että normaalisuusoletus täyttyy. Merkitään Turussa mitattuja lämpötiloja x_i ja Vaasassa mitattuja lämpötiloja y_i . Aloitetaan laskemalla lämpötilojen erotukset kaavalla $d_i = x_i - y_i$. Tämän perusteella voidaan johtaa 95 %:n luottamusväli

$$(\bar{d} - t_{1-\alpha/2}^{(n-1)}SE(\bar{D}), \bar{d} + t_{1-\alpha/2}^{(n-1)}SE(\bar{D}))$$

keskimääräiselle (odotusarvoiselle) lämpötilaerolle t-jakaumaa käyttäen (pienen aineistokoon johdosta):


```
# t. 1.)
x <- c(3.8, 4.0, 2.8, -4.3, -1.5, 0.8, 2.5, 3.1, 1.9, -6.0, -0.6, -16.6)
y <- c(1.9, 2.2, 4.2, -4.6, -1.7, -1.1, 0.3, 3.9, 0.3, -8.5, 0.3, -20.6)

# Erotukset:
d <- x - y
hist(d, breaks=20, main="Histogrammi lämpötilojen erotuksista")


# Erotusten otoskeskiarvo:
d_mean <- mean(d)
print(paste("erotusten keskiarvo: ", d_mean))

# 95 %:n luottamusvälin muodostus:
qqnorm(d, main="Normaalikvantiilikuvio") # tutkitaan normaalisuutta normaalikvantiilikuvion avulla
s_d <- sd(d) # otoskeskihajonta
n <- length(d)
alpha <- 0.05
t <- qt(1-(alpha/2), n-1) # t-jakauman kvantiili vapausasteella n-1
theta_l <- d_mean - t*s_d/sqrt(n) # luottamusvälin alaraja
theta_u <- d_mean + t*s_d/sqrt(n) # luottamusvälin yläraja
c(theta_l, theta_u)
[1] "erotusten keskiarvo: 1.10833333333333"
[1] 0.07830793 2.13835874
```

R-koodi ja sen tulosteet



Histogrammi lämpötilojen erotuksista



Erotusten normaalikvantiilikuvio

R-koodin tulosteista nähdään, että luottamusväliksi saadaan

$$(0.07830..., 2.13835...) \approx (0.078, 2.14).$$

Tehtävä 2

Ladataan terveysterveys-aineisto R:ään ja määritellään painoindeksimuuttuja *bmi* taulukkoon.

```
terveys <- read.csv("~/Projects/uni-assignments/R/TILM3555/materials/terveys.csv", sep=";")

terveys$bmi <- terveys$paino/(terveys$pituu/100)^2
x <- subset(terveys, sukupuoli=="Mies")$bmi
y <- subset(terveys, sukupuoli=="Nainen")$bmi

# a.)

# Miesten havaintojen lkm., otoskeskiarvo ja -hajonta
n_x <- length(x)
x_mean <- mean(x)
s_x <- sd(x)
print(paste("x (miehet):", n_x, x_mean, s_x))

# Naisten havaintojen lkm., otoskeskiarvo ja -hajonta
n_y <- length(y)
y_mean <- mean(y)
s_y <- sd(y)
print(paste("y (naiset):", n_y, y_mean, s_y))

# b.)

# Vapausasteet Welch-Satterthwaite-approksimaatiolla:
v <- (s_x^2/n_x+s_y^2/n_y)^2 / (s_x^4/(n_x^2*(n_x-1))+s_y^4/(n_y^2*(n_y-1)))

# T-jakauman kvantiili 95 % luottamustasolla
alpha <- 0.05
t <- qt(1-(alpha/2), v) # t-kvantiili aiemmin approksimoidulla vapausasteella
se=sqrt(s_x^2/n_x+s_y^2/n_y)
theta_l <- (x_mean-y_mean)-t*se # luottamusvälin alaraja
theta_u <- (x_mean-y_mean)+t*se # luottamusvälin yläraja
c(theta_l, theta_u)

[1] "x (miehet): 36 26.689042461827 4.13381384615852"
[1] "x (miehet): 36 26.689042461827 4.13381384615852"
[1] 0.9700005 4.7416723
```

A- ja b-kohtien R-koodi ja tulosteet

a.)

- Miehillä $n_x = 36$, $\bar{x} = 26.68904... \approx 26.69$ ja $s_x = 4.13381... \approx 4.13$
- Naisilla $n_y = 34$, $\bar{y} = 23.83320... \approx 23.83$ ja $s_y = 3.77178... \approx 3.77$

b.)

Koska ei voida olettaa jakaumien $N(\mu_1, \sigma_1^2)$ ja $N(\mu_2, \sigma_2^2)$ varianssien olevan samoja, tulee käyttää Welch-Satterthwaite-approksimaatiota. Approksimaation kaava luottamusvälille on

$$\bar{x} - \bar{y} \pm t_{\alpha/2}^{(v)} \cdot \sqrt{\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}},$$

jossa t-jakauman kvantiilin vapausluku v määritellään

$$v = \frac{(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2})^2}{\frac{s_1^4}{n_1^2(n_1-1)} + \frac{s_2^4}{n_2^2(n_2-1)}}$$

R:llä saadaan t-jakauman kvantiilin vapausluvuksi $v = 67.92335... \approx 67.92$ ja tulosteesta nähdään, että approksimoitu 95 %:n luottamusväli on

$$(0.97000..., 4.74167...) \approx (0.97, 4.74).$$

Vaihtoehtoisesti R:llä kyseinen luottamusväli saataisiin laskettua myös komennolla `t.test()`, jossa oletuksena on Welch-Satterthwaite-approksimaatio.

Tehtävä 3

Merkitään muuttujalla p henkilöautoa ensisijaisena kulkumuotona käyttävien suhteellista osuutta kyselyyn vastanneista. Suhteellisen osuuden piste-estimaatti on suhteellinen frekvenssi

$$\hat{p} = \frac{147}{444} = 0.33108... \approx 0.33$$

sekä likimääräinen suhteellisen frekvenssin keskivirhe

$$SE(\hat{P}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0.22146...}{444}} = 0.022333... \approx 0.022.$$

Nyt suotuisten tapausten suhteelliselle osuudelle saadaan 95 %:n luottamusvälin rajat (z -arvo 1.96 saadaan taulukosta)

$$\theta_L = \hat{p} - z_{0.025}SE(\hat{P}) = 0.33108... - 1.96 * 0.022333... = 0.28730... \approx 0.29$$

$$\theta_U = \hat{p} + z_{0.025}SE(\hat{P}) = 0.33108... + 1.96 * 0.022333... = 0.37485... \approx 0.37$$

$$(\theta_L, \theta_U) \approx (0.29, 0.37)$$

Tehtävä 4

Aineistona toimivat kuusi hake-erästä tehtyä kosteusmittausta (merk. $x_1, \dots, x_6$), jolle $\bar{x} = 43.9$ ja $s_X = 3.8$. Laatuvaatimus koskee keskimääräistä kosteusprosenttia, joten asetetaan se tutkimuksen kohteeksi hypoteeseja valittaessa:

$$\begin{cases} H_0 : \mu \leq 40 \\ H_v : \mu > 40 \end{cases}.$$

Testisuure t saadaan kaavalla

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}},$$

jossa μ_0 on kosteusprosentin raja. Mitä suurempi testisuure t on, sitä voimakkaammin aineisto on ristiriidassa nollahypoteesin H_0 kanssa (eli ts. tukee vastahypoteesia H_v). Käytetään R-kieltä testisuureen t ja p -arvon ratkaisemiseen.

```
# Tehtävänannon arvot:
x_mean <- 43.9
s <- 3.8
n <- 6

# Laatuvaatimus
mu_0 <- 40

# t-testisuure:
t <- (x_mean - mu_0) / (s / sqrt(n))

# p-arvo (havaittu merkitsevyystaso):
p <- 1 - pt(t, n-1) # pt-funktio antaa kertymäfunktion arvon t-jakaumalle

print(paste("t-testisuure:", t))
print(paste("p-arvo:", p))

[1] "t-testisuure: 2.51394999917221"
[1] "p-arvo: 0.0267844446727077"
```

T-testisuure ja p-arvo

R-tulosteen perusteella saadaan siis

$$t = 2.51394\dots \approx 2.51$$

$$p = 0.026784\dots \approx 0.0268.$$