

## Tilastollisen päättelyn peruskurssi, kevät 2024 — Harjoitus 5

**Tehtävien 1–4** ratkaisut ladataan palautusalueelle Moodlessa pe 9.2. klo 16 mennessä ja vertaisarvioidaan. **Tehtävät 5 ja 6** ovat vapaita lisätehtäviä, joita ei palauteta.

**1.** Uudenvuodenpäivän keskilämpötilat vuosina 2013–2024 olivat Turun Artukaisissa ja Vaasan Klemetilässä seuraavat (lähde Ilmatieteen laitos):

| Vuosi | 2013 | 2014 | 2015 | 2016 | 2017 | 2018 | 2019 | 2020 | 2021 | 2022 | 2023 | 2024  |
|-------|------|------|------|------|------|------|------|------|------|------|------|-------|
| Turku | 3.8  | 4.0  | 2.8  | −4.3 | −1.5 | 0.8  | 2.5  | 3.1  | 1.9  | −6.0 | −0.6 | −16.6 |
| Vaasa | 1.9  | 2.2  | 4.2  | −4.6 | −1.7 | −1.1 | 0.3  | 3.9  | 0.3  | −8.5 | 0.3  | −20.6 |

Laske lämpötilojen erotukset (lämpötila Turussa – lämpötila Vaasassa) ja johda aineiston avulla 95 %:n luottamusväli keskimääräiselle (odotusarvoiselle) uudenvuodenpäivän lämpötilaerolle. Ajattele aineisto parittaisista havainnoista koostuvana (ks. jakso 3.2.2) ja oletta, että normaalisuusoletus täyttyy. (Voit tehdä tehtävän joko R:llä tai käsin laskemalla.)

Oletus lämpötilaerojen normaalisuudesta ei ole tässäkään itsestäänselvyys, mutta tutkittavien suureiden luonteesta johtuen voidaan otaksua, että kovin merkittävää poikkeamaa normaalisuudesta ei ole. Asiaa voi tutkia piirtämällä esim. normaalikvantiilikuvion (R:ssä `qqnorm`) lasketuista erotuksista (tee se halutessasi lisätehtävänä). Näin pienestä aineistosta ( $n = 12$ ) luotettavien johtopäätösten tekeminen on kuitenkin mahdotonta.

**2.** (R) Tarkastellaan aikaisemmissa harjoituksissa käsiteltyä **terveys**-aineistoa, johon lisättiin painoindeksimuuttuja `bmi` harjoituksen 2 tehtävässä 3. Sijoitetaan `x`-vektoriin miesten painoindeksit ja `y`-vektoriin naisten painoindeksit esim. seuraavilla komennoilla:

```
x <- subset(terveys, sukupuoli=="Mies")$bmi
y <- subset(terveys, sukupuoli=="Nainen")$bmi
```

a) Laske sekä `x`-havaintojen että `y`-havaintojen lukumäärät, otoskeskiarvot ja otoskeskihajonnat (funktiot `length`, `mean`, `sd`).

b) Oletetaan, että miesten painoindeksit muodostavat otoksen jakaumasta  $N(\mu_1, \sigma_1^2)$  ja naisten indeksit otoksen jakaumasta  $N(\mu_2, \sigma_2^2)$ , jossa  $\mu_1$  ja  $\mu_2$  ovat populaatiotason keskimääräiset painoindeksit. Johda 95 %:n luottamusväli erotukselle  $\mu_1 - \mu_2$  eli miesten ja naisten keskimääräisten painoindeksien erotukselle populaatiotasolla.

*Huom.* Emme voi olettaa, että populaatioiden varianssit olisivat samoja, joten joudut käyttämään ns. Welch–Satterthwaite-approksimaatiota (ks. muistiinpanojen s. 44). Tarvittavaa normaalisuusoletusta oli kommentoitu harjoituksen 2 tehtävässä 3.

**3.** Turun kaupungin vuonna 2017 tekemässä kyselyssä 444:stä vastaajasta 147 ilmoitti pitävänsä henkilöautoa ensisijaisena liikkumismuotonaan talvella. Jos oletetaan, että vastaajat muodostavat satunnaisotoksen kaikista turkulaisista, muodosta piste-estimaatti ja likimääräinen 95 %:n luottamusväli niiden turkulaisten suhteelliselle osuudelle, jotka pitävät henkilöautoa ensisijaisena liikkumismuotonaan talvella.

**4.** Haketta polttava lämpölaitos vaatii, että sisäänostettavan hakkeen keskimääräinen kosteusprosentti on korkeintaan 40. Laadunvalvonnassa tehdään eräästä suuresta hake-erästä kuusi paikallista kosteusmittausta, joiden keskiarvoksi saadaan 43.9 ja keskihajonnaksi 3.8. Testaa  $t$ -testillä, voidaanko katsoa, että laatuvaatimus ei hake-erässä täyty: muotoile hypoteesit ja laske testisuureen arvo sekä  $p$ -arvo. Oletetaan, että kosteusprosentin vaihtelut hakkeessa ovat normaalisti jakautuneita.  $P$ -arvon voit laskea tarkasti esim. R:llä tai sitten käyttää muistiinpanojen s. 83 taulukkoa sen haarukointiin.

5. (R) Tarkastellaan aikaisemmissa harjoituksissa esiintynyttä `terveys`-aineistoa ja siihen lisättyä painoindeksimuuttujaa `bmi`. Laske, kuinka monta merkittävästi ylipainoista henkilöä aineistossa on, kun merkittävän ylipainoisuuden rajana pidetään painoindeksin arvoa 30. R:llä tämän voi tehdä esim. komennolla `sum(terveys$bmi > 30)`. Tehtäväsi on tämän avulla estimoida taustalla olevassa populaatiossa merkittävästi ylipainoisten suhteellista osuutta.

a) Mikä on ko. suhteellisen osuuden tavanomainen piste-estimaatti?

b) Mikä on sen keskivirhe (oikeastaan keskivirheen arvio)?

c) Mikä on ko. suhteellisen osuuden likimääräinen 95 %:n luottamusväli laskettuna klassisella (mm. muistiinpanojen s. 46 mainitulla kaavalla)?

d) Klassinen luottamusväli saattaa tässä esimerkissä olla epätarkka, koska estimoitava suhteellinen osuus lieenee melko pieni eikä otoskokokaan ole järkevästi suuri. Millaisen 95 %:n luottamusvälin saat, jos käytät sen laskemiseen luentovideolla ja -kalvolla 76 viitattua ”plus neljä” -menetelmää?

6. Oletetaan, että havainnot  $x_1, \dots, x_n$  ovat satunnaisotos normaalisti jakautuneesta populaatiosta, jonka keskiarvo (odotusarvo) on  $\mu$  ja varianssi  $\sigma^2$ . Mallinnetaan niitä siis riippumattomilla satunnaismuuttujilla  $X_1, \dots, X_n$ , jotka noudattavat jakaumaa  $N(\mu, \sigma^2)$ . Muistiinpanojen kohdassa 3.1.2 todetaan, että

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1) \quad (\text{khiin neliön jakauma, } n-1 \text{ vap.ast.}),$$

kun

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

on otosvarienssi. Lähtien liikkeelle sopivasta ”hätätodennäköisyystarkastelusta” näytä, miten tämän jakaumatuloksen avulla johdetaan kaava  $\sigma$ :n  $100(1-\alpha)$  %:n luottamusvälille. Oletetaan, että käytössä on tietokoneohjelma tai taulukko, jonka avulla voi määrittää jakauman  $\chi^2(n-1)$  kvanttileja (esim. R:ssä funktio `qchisq` tai muistiinpanojen s. 84).

*Apu.* Mahdollisuuksia on useita, mutta yksi lähtökohta voisi olla muotoa  $q < (n-1)S^2/\sigma^2$  oleva tapahtuma, joka johtaa yksipuoliseen luottamusväliin.