

5. Harjoitusten ratkaisut

2024-02-09

Tehtävä 1

i	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023	2024
x_i	3.8	4.0	2.8	-4.3	-1.5	0.8	2.5	3.1	1.9	-6.0	-0.6	-16.6
y_i	1.9	2.2	4.2	-4.6	-1.7	-1.1	0.3	3.9	0.3	-8.5	0.3	-20.6
d_i	1.9	1.8	-1.4	0.3	0.2	1.9	2.2	-0.8	1.6	2.5	-0.9	4.0

Taulukossa on esitetty lämpötila Turussa muuttujana x_i , lämpötila Vaasassa muuttujana y_i sekä näiden erotus $d_i = x_i - y_i$. Erotuksen otoskeskiarvo ja otoskeskihajonta ovat

$$\bar{d} = \frac{1}{n} \sum_{i=1}^n d_i = \frac{1}{12} (1.9 + 1.8 - 1.4 + 0.3 + 0.2 + 1.9 + 2.2 - 0.8 + 1.6 + 2.5 - 0.9 + 4.0) = 1.108333 \approx 1.1$$

sekä

$$s_d = \sqrt{\frac{1}{n-1} \left(\sum_{i=1}^n d_i^2 - n\bar{d}^2 \right)} = 1.621143 \approx 1.6.$$

Lasketaan 95 prosentin luottamusväli ($t_{0.025}^{11} \approx 2.201$, kts. luentomoniste s. 83):

$$\theta_L = \bar{d} - t_{0.025}^1 \frac{s_d}{\sqrt{n}} = 1.108 - 2.201 \cdot \frac{1.621}{\sqrt{12}} \approx 2.1.$$
$$\theta_U = \bar{d} + t_{0.025}^1 \frac{s_d}{\sqrt{n}} = 1.108 + 2.201 \cdot \frac{1.621}{\sqrt{12}} \approx 0.1.$$

95%:n luottamusväli keskimääräiselle lämpötilojen erotukselle on (0.1, 2.1).

Ylläolevat laskut R:llä:

```
x <- c(3.8, 4.0, 2.8, -4.3, -1.5, 0.8, 2.5, 3.1, 1.9, -6.0, -0.6, -16.6)
y <- c(1.9, 2.2, 4.2, -4.6, -1.7, -1.1, 0.3, 3.9, 0.3, -8.5, 0.3, -20.6)
d <- x - y
```

```
n <- length(d)
d.mean <- mean(d) # otoskeskiarvo
d.sd <- sd(d) # otoskeskihajonta
# 95% luottamusväli
d.mean - qt(0.975, n - 1) * d.sd / sqrt(n)
d.mean + qt(0.975, n - 1) * d.sd / sqrt(n)
```

```
## [1] 0.07830793
## [1] 2.138359
```

Tehtävä 2

Luetaan terveys-aineisto R:ään ja sijoitetaan miesten ja naisten painoindeksit vektoreihin x ja y:

```
terveys<-read.csv("terveys.csv",sep=";")
#lisätään muuttuja bmi
terveys$bmi <- terveys$paino /( terveys$pituus /100)^2
x <- subset (terveys , sukupuoli == "Mies")$bmi
y <- subset (terveys , sukupuoli == "Nainen")$bmi
```

(a) Lasketaan nämä käyttäen R:n komentoja `length`, `mean` ja `sd`.

```
#x-havaintojen lukumäärä, otoskeskiarvo ja otoskeskihajonta
length(x)
```

```
## [1] 36
```

```
mean(x)
```

```
## [1] 26.68904
```

```
sd(x)
```

```
## [1] 4.133814
```

```
#y-havaintojen lukumäärä, otoskeskiarvo ja otoskeskihajonta
length(y)
```

```
## [1] 34
```

```
mean(y)
```

```
## [1] 23.83321
```

```
sd(y)
```

```
## [1] 3.771782
```

(b) Erotuksen $\mu_1 - \mu_2$ piste-estimaatti on

$$\bar{x} - \bar{y} = 26.69 - 23.83 = 2.86$$

Koska emme voi olettaa, että jakaumien varianssit ovat samat, erotuksen keskivirhe on likimääräisesti

$$se(\bar{X} - \bar{Y}) = \sqrt{\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}} = \sqrt{\frac{4.134^2}{36} + \frac{3.772^2}{34}} \approx 0.945.$$

Lasketaan 95% luottamusväli käyttäen Welch-Satterthweite-approksimaatiota, jolloin luottamusväli on

$$\bar{x} - \bar{y} \pm t_{0.025}^v \sqrt{\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}}.$$

Lasketaan vapausaste v :

$$v = \frac{\left(\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}\right)^2}{\frac{s_x^4}{n_x^2(n_x-1)} + \frac{s_y^4}{n_y^2(n_y-1)}}.$$

Sijoittamalla $n_x = 36$, $n_y = 34$, $s_x = 4.1$ ja $s_y = 3.77$ saadaan vapausasteen arvoksi $v \approx 68$.

```
## [1] 67.92335
```

Nyt 95 prosentin luottamusväli on

$$\bar{x} - \bar{y} \pm t_{0.025}^{68} \sqrt{\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}} = 26.69 - 23.83 \pm 2 * \sqrt{\frac{4.13^2}{36} + \frac{3.77^2}{34}} = (0.97, 4.74) \approx (1.0, 4.7).$$

Sama laskutoimitus on alla toteutettu R:llä.

```
x.mean=mean(x)
sx=sd(x)
nx=length(x)
y.mean=mean(y)
sy=sd(y)
ny=length(y)
se=sqrt(sx^2/nx+sy^2/ny)
v=(sx^2/nx+sy^2/ny)^2/(sx^4/(nx^2*(nx-1))+sy^4/(ny^2*(ny-1)))
(x.mean - y.mean) + c(-1, 1) * qt(0.975, v) * se # welch-satterthwaite
```

```
## [1] 0.9700005 4.7416723
```

R:ssä saa myös laskettua luottamusvälin suoraan komennolla `t.test()`, jossa oletuksena on Welch-Satterthwaite-approksimaatio.

```
t.test(x,y)

##
##  Welch Two Sample t-test
##
## data:  x and y
## t = 3.0219, df = 67.923, p-value = 0.00354
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  0.9700005 4.7416723
## sample estimates:
## mean of x mean of y
## 26.68904 23.83321
```

Tehtävä 3

Nyt otoskoko n on 444, ensisijaisesti henkilöautolla talvisin ajavien määrä y on 147 ja piste-estimaatti $\hat{p}$ suhteelliselle osuudelle on $147/444 \approx 0.33$.

Piste-estimaatin keskivirhe on $se(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0.33(1-0.33)}{444}} \approx 0.02$.

Tällöin likimääräinen 95 prosentin luottamusväli suhteelliselle osuudelle saadaan kaavalla

$$\hat{p} \pm z_{0.025} se(\hat{p}) = 0.33 \pm 1.96 * 0.02 = (0.29, 0.37).$$

Tehtävä 4

Aineistosta tiedetään, että $\bar{x} = 43.9$, $s = 3.8$ ja $n = 6$. Lisäksi oletetaan, että kosteusprosentin vaihtelut hakkeessa ovat normaalisti jakautuneita.

Asetetaan hypoteesit

$H_0 : \mu = 40$ (tai $H_0 : \mu \leq 40$) ja $H_v : \mu > 40$

Tehtävän tilanteessa ollaan erityisesti kiinnostuneita siitä, onko keskimääräinen kosteusprosentti suurempi kuin 40. Näin ollen valitaan yksisuuntainen vastahypoteesi.

Lasketaan testisuureen arvo

$$t_{hav} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{43.9 - 40}{3.8/\sqrt{6}} \approx 2.51.$$

Lasketaan p-arvo

H_0 :n ollessa voimassa $T \sim t(5)$, joten

$$p = P_{H_0}(T \geq t_{hav}) = 1 - F_T(t_{hav}) = 1 - F_T(2.51) \approx 1 - 0.973 = 0.027.$$

$F_T(2.51)$ voidaan laskea R:llä seuraavasti:

```
pt(2.51, 5)
```

```
## [1] 0.973086
```

Taulukkoa käytettäessä (luentomoniste s. 83) joudutaan p-arvoa arvioimaan. Koska vastahypoteesi on yksisuuntainen ja muotoa $\mu > 40$, etsitään taulukosta vapausastetta 5 vastaavalta riviltä vierekkäiset sarakkeet, joiden arvojen väliin t_{hav} sijoittuu. Nähdään, että $2.015 < t_{hav} < 2.571$. Koska $P(T \geq 2.015) = 0.05$ ja $P(T \geq 1.2.571) = 0.025$, on p-arvo näiden todennäköisyyksien välissä eli $0.025 < p < 0.05$.

Tehdään päätelmät

Pienet p-arvot (eli suuret testisuureen arvot) todistavat nollahypoteesia vastaan. Tässä tapauksessa p-arvo ($p = 0.027$ tai $0.025 < p < 0.05$) on varsin pieni eli aineisto todistaa nollahypoteesia vastaan.

Tehtävä 5

Ladataan aluksi aineisto ja lisätään bmi-muuttuja.

```
terveys <- read.csv("terveys.csv", sep = ";")
terveys$bmi <- terveys$paino / (terveys$pituus / 100)^2
```

(a) Lasketaan merkittävästi ylipainoisten lukumäärä y .

```
y=sum(terveys$bmi>30)
y
```

```
## [1] 6
```

Suhteellisen osuuden piste-estimaatti on $\hat{p} = \frac{y}{n}$.

```
n=length(terveys$bmi)
p.hat=y/n
p.hat
```

```
## [1] 0.08571429
```

Suhteellisen osuuden estimaatiksi saadaan noin 0.086 (eli noin 8.6 prosenttia).

(b) Keskivirheen arvio saadaan laskettua kaavalla $se(\hat{P}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$.

```
p.hat.se <- sqrt(p.hat * (1 - p.hat) / n)
p.hat.se
```

```
## [1] 0.03345943
```

Suhteellisen osuuden keskivirheen arvio on noin 0.033.

(c) Likimääräinen 95% luottamusväli p :lle on $\hat{p} \pm z_{0.025}se(\hat{P})$.

```
p.hat - qnorm(0.975) * p.hat.se
p.hat + qnorm(0.975) * p.hat.se
```

```
## [1] 0.02013501
```

```
## [1] 0.1512936
```

Likimääräiseksi 95% luottamusväliksi saadaan (0.02, 0.15).

(d) Korvataan nyt $y \rightarrow y + 2$ ja $n \rightarrow n + 4$ ja lasketaan uudestaan 95 prosentin likimääräinen luottamusväli.

```
y = y+2
n=n+4
p.hat=y/n
p.hat.se <- sqrt(p.hat * (1 - p.hat) / n)
p.hat - qnorm(0.975) * p.hat.se
p.hat + qnorm(0.975) * p.hat.se
```


```
## [1] 0.03735957
```

```
## [1] 0.1788566
```

Nyt havaitaan, että “plus neljä” -menetelmän käyttö kasvattaa hieman luottamusvälin ylä- ja alarajoja. Myös suhteellisen osuuden piste-estimaatti kasvaa 0.11:een.

Tehtävä 6

Olko $q = \chi^2_{1-\alpha}$ eli kvantiiliin q vasemmalla puolella on α :n verran $\chi^2(n-1)$ -jakauman todennäköisyysmassaa ja oikealla puolella $1 - \alpha$:n verran todennäköisyysmassaa. Tilannetta on havainnollistettu oheisessa kuviossa, jossa jakauma on $\chi^2(8)$ ja $\alpha = 0.05$.




Koska $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$, voidaan kirjoittaa

$$\begin{aligned}
P\left(q < \frac{(n-1)S^2}{\sigma^2}\right) &= 1 - \alpha \\
P\left(\frac{1}{q} > \frac{\sigma^2}{(n-1)S^2}\right) &= 1 - \alpha \\
P\left(\frac{(n-1)S^2}{q} > \sigma^2\right) &= 1 - \alpha \\
P\left(\sigma < \sqrt{\frac{(n-1)}{q}}S\right) &= 1 - \alpha
\end{aligned}$$

Kun sijoitetaan q :n paikalle kvantiili $\chi^2_{1-\alpha}$ saadaan yksipuoliseksi luottamusväliksi $\left(0, \sqrt{\frac{(n-1)}{\chi^2_{1-\alpha}}}s\right)$. Vasen päätepiste on 0, koska $\sigma > 0$.

Kaksipuolinen luottamusväli saadaan vastaavasti. Olkoot $q_1 = \chi^2_{1-\alpha/2}$ ja $q_2 = \chi^2_{\alpha/2}$, eli kvantiilin q_1 vasemmalla puolella on $\alpha/2$:n verran $\chi^2(n-1)$ -jakauman todennäköisyysmassaa, ja kvantiilin q_2 oikealla puolella $\alpha/2$:n verran todennäköisyysmassaa. Oheisessa kuviossa on esimerkkinä esitetty χ^2 -jakauman tiheysfunktio vapausastein 8, sekä mainitut kvantiilit, kun $\alpha = 0.1$. Kvantiilien väliin jää tässä tapauksessa siis 90 % todennäköisyysmassasta. Tärkeää on havaita, ettei jakauma ole symmetrinen, kuten esimerkiksi standardinormaalijakauman tapauksessa.

Chi-Square Distribution (df = 8)



$100(1 - \alpha)$ %:n peittotodennäköisyys σ :lle voidaan kirjoittaa muodossa:

$$\begin{aligned}
P\left(q_1 \leq \frac{(n-1)S^2}{\sigma^2} \leq q_2\right) &= 1 - \alpha \\
P\left(\frac{q_1}{(n-1)S^2} \leq \frac{1}{\sigma^2} \leq \frac{q_2}{(n-1)S^2}\right) &= 1 - \alpha \\
P\left(\frac{(n-1)S^2}{q_1} \geq \sigma^2 \geq \frac{(n-1)S^2}{q_2}\right) &= 1 - \alpha \\
P\left(\sqrt{\frac{(n-1)}{q_1}}S \geq \sigma \geq \sqrt{\frac{(n-1)}{q_2}}S\right) &= 1 - \alpha
\end{aligned}$$

Kun sijoitetaan q_1 :n ja q_2 :n paikalle ylempänä mainitut kvantiilit ja järjestetään edeltävä yhtälö uudelleen, saadaan peittotodennäköisyys muotoon

$$P\left(\sqrt{\frac{(n-1)}{\chi_{\alpha/2}^2}}S \leq \sigma \leq \sqrt{\frac{(n-1)}{\chi_{1-(\alpha/2)}^2}}S\right) = 1 - \alpha$$

$100(1 - \alpha)$ %:n kaksipuolinen luottamusväli on siis muotoa

$$\left(\sqrt{\frac{(n-1)}{\chi_{\alpha/2}^2}}s, \sqrt{\frac{(n-1)}{\chi_{1-(\alpha/2)}^2}}s\right)$$