

TILM3555 — Harjoitus 6

February 16, 2024

Tehtävä 1

Tehdyllä tilastollisella tutkimuksella pyritään selvittämään eri hoitomuotojen vaikuttavuutta akuuttiin niskakipuun. Tutkimuksen hoitomuotoina olivat akupunktuuri, hieronta sekä lumelaserakupunktuuri ja yksittäisen hoidon tehokkuutta pyrittiin mittaamaan VAS-mittarilla, jolla pyritään sijoittamaan potilaan tuntema kipu tietylle mitta-asteikolle.

Viikko hoitojen päättymisen jälkeen mitattujen tulosten perusteella akupunktuurihoidon läpikäynyt ryhmä koki kipujensa vähentyneen keskimäärin 16.32 VAS-pistettä enemmän kuin hierontahoidon läpikäynyt ryhmä. Mittaustulosten analysoinnin yhteydessä tälle piste-erolle määriteltiin myös 95 %:n luottamusväli 4.4...28.3, joka käytännössä tarkoittaa että todellinen piste-ero sijoittuu 95 %:n todennäköisyydellä kyseiselle välille. Ts. piste-ero on 95 %:n todennäköisyydellä vähintään 4.4 ja enintään 28.3. Saaduista tuloksista laskettu p -arvo $p = 0.005$ puolestaan tarkoittaa havaittua merkitsevyystasoa eli todennäköisyyttä sille, että saadaan kuvattu aineisto, kun alustavasti oletetaan piste-eron olevan mahdollisimman pieni (nollahypoteesi). Ts. saatu pieni (oletetaan riskitasoksi α esim. 0.05) p -arvo kertoo, että tulokset mitä todennäköisimmin osoittavat akupunktuurin tuottavan hierontaa tehokkaampia tuloksia tutkimuksen kaltaisia vaivoja hoidettaessa.

Toisaalta saaduissa tutkimustuloksissa on myös mainittu, että piste-ero akupunktuurihoidon sekä lumelaserakupunktuurihoidon välillä on keskimäärin 6.93. 95 %:n todennäköisyydellä tämä piste-ero sijoittuu välille $-5.0...18.9$ eli ts. hoitomuotojen tuottamien tulosten välillä ei ole merkittävää eroa. Myös saatu p -arvo $p = 0.33$ kertoo, että saadut tulokset tukevat alkuperäistä oletamaa siitä, että hoitomuotojen välillä ei ole merkittäviä eroja. Kaiken kaikkiaan tutkimus siis osoittaa, että akupunktuuri voi olla tehokkaampi keino kivun lievittämisessä verrattuna hierontaan, mutta sen tehokkuus verrattuna lumelaserakupunktuioon ei ole tilastollisesti merkittävä.

Kun lähdetään oletuksesta, että VAS-mittarin antamat tulokset ovat likimain normaalisti jakautuneita, voidaan olettaa eri ryhmien odotusarvojen μ_1 ja μ_2 laskemiseen käytettäneen t -testiä (olettaen nollahypoteesi todeksi). Tällöin siis molempien populaatioiden keskimääräisten arvojen erotus voitaisiin määrittellä $\mu_1 - \mu = \delta$. Koska erotus pohjautuu tällöin populaatioiden odotusarvoihin, voidaan luottamusväli laskea Studentin t -jakauman avulla (koska populaatioiden varianssit ovat tuntemattomia). P -arvojen laskemiseen voidaan olettaa käytettäneen normaaliapproksimaatiota (koska n arvot ovat suuria), jolloin siis $p = P_{H_0}(Z \geq z_{hav}) \approx 1 - \Phi(z_{hav})$.

Tehtävä 2

```
terveys <- read.csv("materials/terveys.csv", sep=";")
```

Aineiston lataaminen R:ään

a.)

```
x <- subset(terveys, sukupuoli=="Mies")$kolesteroli
y <- subset(terveys, sukupuoli=="Nainen")$kolesteroli

n_x <- length(x)
n_y <- length(y)

x.ka <- mean(x)
y.ka <- mean(y)

s_x <- sd(x)
s_y <- sd(y)

# Keskiarvojen erotuksen piste-estimaatti
pe <- x.ka-y.ka
print(paste("erotuksen piste-estimaatti:", pe))

# Keskiarvo ilman oletusta varianssien yhtäsuuruudesta
se <- sqrt(s_x^2/n_x+s_y^2/n_y)
print(paste("keskiarvo:", se))

# Testisuureen arvo, kun oletetaan nollahypoteesi todeksi
# (H_0: miesten ja naisten keskim. kolesteroliarvot samat)
t_hav <- (x.ka-y.ka)/se
print(paste("t-testisuureen havaittu arvo:", t_hav))

# Kaksipuolinen p-arvo
# (liikarvo standardinormaalijakaumasta, koska otoskoko suht. on suuri)
p <- 2*(1-pnorm(t_hav))
print(paste("kaksipuolinen p-arvo:", p))

[1] "erotuksen piste-estimaatti: 0.507026143790849"
[1] "keskiarvo: 0.26908639077766"
[1] "t-testisuureen havaittu arvo: 1.88425041610445"
[1] "kaksipuolinen p-arvo: 0.0595311109204912"
```

A-kohdan R-koodi ja sen tulosteet

R-koodin tulosteesta nähdään seuraavat arvot:

- Keskiarvojen erotuksen piste-estimaatti: $\bar{x} - \bar{y} = 0.50702... \approx 0.51$
- Testisuureen havaittu arvo: $t_{hav} = 1.88425 \approx 1.88$
- Havaittu merkitsevyystaso (liikarvo): $p \approx 0.059531... \approx 0.06$

Piste-estimaatin perusteella miesten keskimääräinen kolesterolitaso olisi korkeampi kuin naisilla. Testisuureen arvon $t_{hav} \approx 1.88$ sekä havaitun merkitsevyystason $p \approx 0.06$ perusteella nollahypoteesia H_0 eli olettamusta keskimääräisten kolesterolitason yhtäsuuruudesta ei kuitenkaan voida täysin hylätä. Koska havaittu merkitsevyystaso p on kuitenkin suhteellisen lähellä arvoa 0.05, voidaan olettaa aineiston todistavan lievästi nollahypoteesia H_0 vastaan.

b.)

```
x <- subset(terveys, liikunta=="ei lainkaan")$kolesteroli
y <- subset(terveys, liikunta!="ei lainkaan")$kolesteroli

n_x <- length(x)
n_y <- length(y)

x.ka <- mean(x)
y.ka <- mean(y)

s_x <- sd(x)
s_y <- sd(y)

# Keskiarvojen erotuksen piste-estimaatti
pe <- x.ka-y.ka
print(paste("erotuksen piste-estimaatti:", pe))

# Keskivirhe ilman oletusta varianssien yhtäsuuruudesta
se <- sqrt(s_x^2/n_x+s_y^2/n_y)
print(paste("keskivirhe:", se))

# Testisuureen arvo, kun oletetaan nollahypoteesi todeksi
# (H_0: miesten ja naisten keskim. kolesteroliarvot samat)
t_hav <- (x.ka-y.ka)/se
print(paste("t-testisuureen havaittu arvo:", t_hav))

# Kaksipuolinen p-arvo
# (liikarvo standardinormaalijakaumasta, koska otoskoko suht. on suuri)
p <- 2*(1-pnorm(t_hav))
print(paste("kaksipuolinen p-arvo:", p))
[1] "erotuksen piste-estimaatti: 1.1125"
[1] "keskivirhe: 0.263271129571365"
[1] "t-testisuureen havaittu arvo: 4.22568172139222"
[1] "kaksipuolinen p-arvo: 2.38218494530429e-05"
```

B-kohdan R-koodi ja sen tulosteet

R-koodin tulosteesta nähdään seuraavat arvot:

- Keskiarvojen erotuksen piste-estimaatti: $\bar{x} - \bar{y} = 1.1125... \approx 1.11$
- Testisuureen havaittu arvo: $t_{hav} = 4.22568... \approx 4.23$
- Havaittu merkitsevyystaso (liikarvo): $p \approx 2.38218... \cdot 10^{-5} \approx 0.000024$

Piste-estimaatin perusteella liikuntaa harrastavien kolesterolitaseksi olisi huomattavasti matalampi kuin niillä, jotka eivät harasta liikuntaa. Testisuureen $t_{hav} \approx 4.23$ sekä havaitun merkitsevyystason $p \approx 0.000024$ perusteella nollahypoteesia H_0 eli olettamusta keskimääräisten kolesterolitaseiden yhtäsuuruudesta ei voida pitää totena, vaan päätelmässä kallistutaan vastahypoteesin H_v puoleen. Pienen p -arvon ($p \leq 0.01$) johdosta on siis hyvin todennäköistä, että keskimääräisissä kolesterolitaseissa on kohdan populaatioiden välillä merkittävä ero.

Tehtävä 3

Tutkimuksen kohteena ovat suhteelliset osuudet, joten lähdetään tutkimaan tilannetta toistokokeen kautta. Nollahypoteesin H_0 perusteella käräjäoikeudet määräävät lapset yhtä todennäköisesti asumaan äidin ja isän luona. Olkoon siis p todennäköisyys, että lapsi määrätään asumaan isänsä luo, jolloin $\hat{p} = 0.29661\dots$ ja nollahypoteesin pätiessä $p_0 = 0.5$. Kaksipuolisen tarkastelun asetelma on siis

$$\begin{cases} H_0 : p = 0.5 \\ H_v : p \neq 0.5. \end{cases}$$

Kaksipuolisessa tarkastelussa asemalle kriittistä ovat suuret $|\hat{p} - p_0|$ arvot. P -arvon laskemiseen voidaan lähtökohtaisesti suurilla n arvoilla ($n \geq 30$) käyttää normaaliapproksimaatiota (KRL):

$$p\text{-arvo} = P_{H_0}(|Z| \geq |z_{hav}|) \approx 2(1 - \Phi(|z_{hav}|)),$$

jossa Φ on $N(0, 1)$ -jakauman kertymäfunktio ja

$$z_{hav} = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}} = -4.41876\dots$$

P -arvon likiarvoksi saadaan siis (R:ssä `2*(1-pnorm(abs(z_hav)))`)-komennolla)

$$2(1 - \Phi(|z_{hav}|)) = 9.92688\dots \cdot 10^{-6} \approx 9.93 \cdot 10^{-6}.$$

Erittäin pieni p -arvo viittaa melko vahvasti nollahypoteesia vastaan eli vastahypoteesin puolesta.

Tehtävä 4

Tehtävänannon määrittelemä hypoteesipari $H_0 : p = 0.5$ ja $H_v : p \neq 0.5$.

a.)

Otoskoon n ollessa suuri, pätee likimääräisesti

$$\hat{P} \sim \text{Normal}\left(p, \frac{p(1-p)}{n}\right).$$

Nollahypoteesin N_0 perusteella $p_0 = 0.5$ ja aineiston tulosten perusteella estimaattori $\hat{p} = 0.7$. Lasketaan havaittu testisuureen arvo

$$z_{hav} = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} = \frac{0.7 - 0.5}{\sqrt{0.5 * 0.5/100}} = 0.28426... \approx 0.28,$$

jonka avulla voidaan laskea testin p -arvon likiarvo

$$p\text{-arvo} = \Phi(z_{hav}) = \Phi(0.28426...) = 0.61189... \approx 0.61.$$

Havaitun testisuureen arvo z_{hav} ei kuulu tasolla $\alpha = 0.05$ määritellylle kriittiselle alueelle ($z \leq -1.64$). Saatu p -arvo on suurempi kuin α , joten nollahypoteesin voidaan olettaa pitävän suhteellisen hyvin paikkansa.

b.)

Nyt otoskoko $n = 10$ ja kruunuja saadaan 7, jolloin siis yhä $\hat{p} = 0.7$, mutta pienen otoskoon johdosta ei binomijakaumaa voida approksimoida normaali jakauman avulla. Tehtävänannon määrittelemän hypoteesiasetelman perusteella p -arvo voidaan laskea kaavalla

$$p\text{-arvo} = P_{H_0}(|\hat{P} - p_0| \geq |\hat{p} - p_0|) = P_{H_0}(|Y - np_0| \geq |y - np_0|).$$

Lasketaan binomitodennäköisyydet R:llä:

```
p <- pbinom(3, size=10, prob=0.5, lower.tail=TRUE) + pbinom(6, size=10, prob=0.5, lower.tail=FALSE)
print(paste("kaksipuolinen p-arvo:", p))
[1] "kaksipuolinen p-arvo: 0.34375"
```

Kaksipuoliseksi p -arvoksi saadaan siis $0.34375... \approx 0.34$, joka tukee suhteellisen hyvin nollahypoteesia $H_0 : p = 0.5$.