

TILM3555 — Harjoitus 7

February 23, 2024

Tehtävä 1

Nollahypoteesiksi H_0 asetetaan, että luokan A_j (yksittäisen viikonpäivän) todennäköisyys $p_j = \frac{1}{7}$. Tällöin siis $e_j = n \cdot p_j = 12.85714...$ (sama kaikille luokille A_j). Lähdetään toteuttamaan χ^2 -yhteensopivuustestiä laskemalla testisuure h_{hav} ja likimääräinen p -arvo:

$$h_{hav} = \sum_{j=1}^k \frac{(f_j - e_j)^2}{e_j} = \frac{(10 - e_j)^2}{e_j} + \dots + \frac{(19 - e_j)^2}{e_j} = 8.93333... \approx 8.93$$

$$p \approx 1 - F_{k-1}(h_{hav}) = 1 - F_{7-1}(8.93333...) = 0.17736... \approx 0.18$$

R-kielen komennolla $pchisq(x, v)$ avulla lasketun p -arvon perusteella voidaan päätellä havaintojen sopivan kohtuullisen hyvin yhteen nollahypoteesin kanssa. Tulos voidaan myös tarkastaa komennolla $chisq.test(f, p = p)$, jossa f on vektori havaituista frekvensseistä ja p vektori nollahypoteesin mukaisista todennäköisyyksistä.

Tehtävä 2

Tehtävä eroaa 1. tehtävästä siten, että nyt tapausluokkia on vain kaksi kappaletta. Nollahypoteesiksi asetetaan, että luokan A_1 (arkipäivän) todennäköisyys $p_1 = \frac{5}{7}$ ja luokan A_2 (viikonlopun) todennäköisyys $p_2 = \frac{2}{7}$. Tällöin siis $e_1 = n \cdot p_1 = 64.28571\dots$ ja $e_2 = n \cdot p_2 = 25.71428\dots$. Käytetään tehtävän ratkaisuun χ^2 -yhteensopivuustestiä ja lasketaan testisuure h_{hav} ja likimääräinen p -arvo:

$$h_{hav} = \sum_{j=1}^k \frac{(f_j - e_j)^2}{e_j} = \frac{((10 + 11 + 11 + 8 + 12) - e_1)^2}{e_1} + \frac{((19 + 19) - e_2)^2}{e_2} = 8.21778\dots \approx 8.22$$

$$p \approx 1 - F_{k-1}(h_{hav}) = 1 - F_{2-1}(8.21778\dots) = 0.00414\dots \approx 0.0041$$

R-kielen komennolla $pchisq(x, v)$ avulla laskettu p -arvo todistaa suhteellisen vahvasti nollahypoteesia vastaan. Saadut arvot voidaan jälleen tarkastaa 1. tehtävän tavoin $chisq.test(f, p = p)$ R-komennolla.

Tehtävä 3

Tutkitaa nollahypoteesia H_0 , jonka mukaan puolisoien pituudet ovat toisistaan riippumattomia. Käytännössä tulee siis tutkia (x_i, y_j) parien suhteellista osuutta $p_{i,j}$ populaatiossa. Muodostetaan aineistosta $r \times s$ -frekvenssitaulukko, jonka perusteella voidaan laskea estimaatit $e_{i,j} = n \cdot \hat{p}_i \hat{q}_j = \frac{f_{i..}}{f_{..j}}$:

	pitkä vaimo	keskipitkä vaimo	lyhyt vaimo	yht.
pitkä mies	18	28	14	60
keskipitkä mies	20	51	28	99
lyhyt mies	12	25	9	46
yht.	50	104	51	205

	pitkä vaimo	keskipitkä vaimo	lyhyt vaimo
pitkä mies	14.6341...	30.4390...	14.9268...
keskipitkä mies	24.1463...	50.2243...	24.6292...
lyhyt mies	11.2195...	23.3365...	11.4439...

Käytetään ratkaisuun jälleen χ^2 -yhteensopivuustestiä ja lasketaan testisuure h_{hav} ja likimääräinen p -arvo:

$$h_{hav} = \sum_{i=1}^r \sum_{j=1}^s \frac{(f_{i,j} - e_{i,j})^2}{e_{i,j}} = \frac{(18 - e_{1,1})^2}{e_{1,1}} + \dots + \frac{(9 - e_{3,3})^2}{e_{3,3}} = 2.9072... \approx 2.91$$

$$p \approx 1 - F_{(r-1)(s-1)}(h_{hav}) = 1 - F_{(3-1)(3-1)}(2.9072...) = 0.5734... \approx 0.57$$

R-kielen komennolla `pchisq(x, v)` avulla laskettu p -arvo osoittaa suhteellisen vahvasti, että nollahypoteesi H_0 pitää paikkansa, eli puolisoien pituudet ovat toisistaan riippumattomia. Tarkistetaan saatujen tulosten paikkansapitävyys vielä R-kielellä:

```
tab <- matrix(c(18, 28, 14, 20, 51, 28, 12, 25, 9), ncol=3, byrow=TRUE)
chisq.test(tab)

Pearson's Chi-squared test

data:  tab
X-squared = 2.9072, df = 4, p-value = 0.5735
```

Tehtävä 4

a.)

Tilastollisessa päättelyssä on kyse erilaisten aineistojen analysoinnista tilastollisten menetelmien avulla. Olennaista tässä prosessissa on etenkin aineiston satunnaisuuden ja epävarmuuden hallinta, jolloin saadut tulokset ja niistä tehdyt johtopäätökset ovat loogisesti perusteltavissa.

b.)

-