

TILM3702 — Harjoitustyö

Arttu Einistö

May 7, 2024

Sisällysluettelo

1	Numeeristen vastemuuttujien mallitus	3
1.1	Regressiomalli	3
2	Toistomittausmalli	5
3	Kategoristen vastemuuttujien mallinnus	9
3.1	Kaksiluokkainen selitettävä muuttuja	9
4	Monimuuttujamenetelmät	11
4.1	Muuttujien ryhmittely	11
4.2	Havaintojen ryhmittely	17

1 Numeeristen vastemuuttujien mallitus

1.1 Regressiomalli

Tutkitaan sovittamalla regressiomalli, onko kotitalouden kuluttajayksiköiden lukumäärällä, asumismenoilla yhteensä ja alueella asumisajalla yhteyttä asunnon pinta-alaan.

Aloitetaan määrittelemällä asunnon pinta-ala (*pala*) vastemuuttujaksi ja muut yllä mainitut muuttujat mallin selittäjiksi (*rkyks*, *asmenot* ja *alaika*). Sovitetaan tämä malli R:llä:

```
> lm1 = lm(pala~rkyks+asmenot+alaika)
> summary(lm1)

Call:
lm(formula = pala ~ rkyks + asmenot + alaika)

Residuals:
    Min       1Q   Median       3Q      Max
-66.957 -20.588  -4.635   15.140  169.028

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.848e+01  3.837e+00   4.816 1.75e-06 ***
rkyks        2.630e+01  1.444e+00  18.211 < 2e-16 ***
asmenot      2.438e-04  2.312e-04   1.054   0.292
alaika       2.980e-01  6.987e-02   4.266 2.23e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 31.85 on 796 degrees of freedom
Multiple R-squared:  0.3105,    Adjusted R-squared:  0.3079
F-statistic: 119.5 on 3 and 796 DF,  p-value: < 2.2e-16
```


Muodostetusta mallin yhteenvedosta voidaan lähteä analysoimaan sen sopivuutta eli toisin sanoen miten hyvin selittäjät selittävät vastemuuttujan arvoa. Muiden selittäjien ollessa 0, saa pinta-ala arvoksi 18.48 mallin kertoimen β_0 perusteella. Analysoidaan yksittäisten kertoimien tilastollista merkittävyyttä sekä niiden merkitystä pinta-alan saamalle arvolle:

- *rkyks*: Saa estimoidun kertoimen 26.30 ja p-arvon $< 2 \cdot 10^{-16}$. Muuttuja on siis tilastollisesti merkitsevä ja sillä on suhteellisen suuren kertoimen perusteella merkittävä vaikutus vastemuuttujaan.
- *asmenot*: Saa estimoidun kertoimen $2.438 \cdot 10^{-4}$ ja p-arvon 0.292. Muuttuja ei siis ole tilastollisesti merkitsevä, joten se ei vaikuta merkittävästi vastemuuttujan arvoon.
- *alaika*: Saa estimoidun kertoimen 0.298 ja p-arvon $2.23 \cdot 10^{-5}$. Muuttuja on siis *rkyks* tavoin tilastollisesti merkitsevä, mutta sen vaikutus vastemuuttujan arvoon on huomattavasti pienempi suhteellisen pienen kertoimen perusteella.

Tutkitaan sitten itse mallin sopivuutta: yhteenvedosta voidaan nähdä R^2 - sekä korjatun R^2 -kertoimen

arvot $R^2 = 0.3105$ ja $R^2\text{-adjusted} = 0.3079$. Kyseiset arvot kertovat siis sen, että noin 31 % vastemuuttujan *pala* vaihtelusta on selitettävissä muodostetun mallin avulla. Toisin sanoen siis käytettyjen selittäjien avulla muodostetun mallin näkökulmasta suurin osa vastemuuttujan vaihtelusta on tuntematonta. Mallin F-testi saa arvokseen 119.5 p-arvolla $< 2.2 \cdot 10^{-16}$, mikä viittaa vahvasti siihen, että muodostettu malli on tilastollisesti merkitsevä.

Mallin sovittamisen lisäksi sen residuaaleja voidaan analysoida sekä vertaamalla niitä sovitteisiin sekä sijoittamalla ne histogrammiin:



Kuvaajasta (residuaalit vasten sovitteita) voidaan nähdä, että residuaalit asettuvat suhteellisen hyvin ja satunnaisesti nollan ympärille eri sovitteille, mikä viittaa homoskedastisuuteen. Histogrammista puolestaan voidaan nähdä, että residuaalit sijoittuvat suhteellisen hyvin myös normaalijakauman muotoon, vaikkakin jakauma on kevyesti oikealle vino poikkeavien residuaalien myötä. Voidaan siis todeta, ettei mallissa synny merkittävää systemaattista virhettä, vaan sen residuaalit ovat lähtökohtaisesti satunnaisia.


Sovitetun regressiomallin perusteella yhteenvetona voidaankin sanoa, että pinta-alan ja sekä kotitalouden kuluttajayksiköiden lukumäärän että alueella asumisajan välillä on tilastollisesti merkitsevä positiivinen yhteys. Asumismenoilla sen ei sijaan ole tilastollisesti merkitsevää vaikutusta asunnon pinta-alaan, mikä loogisesti ajateltuna kuulostaa erittäin epätodennäköiseltä. On siis hyvä huomioida myös se, että sovitettu regressiomalli selittää vain noin 30 % pinta-alan vaihtelusta eli se on suhteellisen epätarkka. Todellisen tutkimuksen kontekstissa olisikin siis syytä sovittaa uusia regressiomalleja, joiden kautta muiden aineiston potentiaalisten selittäjien mahdolliset yhteydet pinta-alaan tulisivat esiin, jolloin malli selittäisi suurempaa osaa pinta-alan vaihtelusta.

2 Toistomittausmalli

Käsitellään nyt toistettujen mittausten varianssianalyysin kautta tutkijan hypoteesia siitä, että käsitellyssä aineistossa potilaan mielestä saatu ohjaus leikkauksen jälkeisistä toiminnallisista seikoista (*Functional_M1*) on ollut vähäisempää kuin ennen leikkausta on odotettu (*Functional_M2*). Toisin sanoen tutkitaan siis onko toisen mittauksen keskiarvo matalampi kuin toisen. Lisäksi ollaan kiinnostuneita siitä, onko kyseinen mittausten välinen ero erilainen sukupuolittain.

Aloitetaan tarkastelemalla muuttujia laatikko-janakuvioiden ja tunnuslukujen avulla varianssianalyysin oletusten kannalta:

```
> summary(Functional_M1)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
  1.000  3.500   4.000   3.671  4.000   4.000     3
> summary(Functional_M2)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
  1.000  2.875   3.500   3.292  4.000   4.000     5
```



Kuten jo havaintojen tunnusluvuista sekä laatikko-janakuvaajasta nähdään, ei kumpikaan jakaumista vaikuta läheskään normaalisti jakautuneelta. Myös poikkeavia havaintoja on huomattavan suuri lukumäärä. Tehdään lisäksi vielä havaintojen normaalijakautuneisuutta testaavat Shapiro-Wilk-testit:

```

> # Normaalisuustestit eri sukupuolille
> with(oma.otos2, tapply(Functional_M1, D2, shapiro.test))
$female

      Shapiro-Wilk normality test

data:  X[[i]]
W = 0.63919, p-value < 2.2e-16

$male

      Shapiro-Wilk normality test

data:  X[[i]]
W = 0.65827, p-value < 2.2e-16

> with(oma.otos2, tapply(Functional_M2, D2, shapiro.test))
$female

      Shapiro-Wilk normality test

data:  X[[i]]
W = 0.8692, p-value = 2.845e-15

$male

      Shapiro-Wilk normality test

data:  X[[i]]
W = 0.87722, p-value = 2.502e-11

```

Shapiro-Wilk-testeistä nähdään, että kummankin vastauksen ja sukupuolen yhdistelmät saavat p-arvot, jotka ovat selvästi alle merkitsevyystason 0.001:

- *Functional_M1-female*: $p < 2.2 \cdot 10^{-16}$
- *Functional_M1-male*: $p < 2.2 \cdot 10^{-16}$
- *Functional_M2-female*: $p = 2.845 \cdot 10^{-15}$
- *Functional_M2-male*: $p = 2.502 \cdot 10^{-11}$

Saadut p-arvot todistavat siis nollahypoteesia eli normaali-jakautuneisuuden oletusta vastaan.

Tämä ei kuitenkaan estä meitä käyttämästä toistomittausten varianssianalyysiä, joka edellyttää otoskeskiarvojen olevan peräisin likimain normaalisti jakautuneesta aineistosta. Keskeisen raja-arvolauseen avulla voidaan todeta, että keskiarvo riittävän suuresta lukumäärästä toisistaan riippumattomia satunnaismuuttujia (joille määritelty odotusarvo ja varianssi) on likipitään normaalisti jakautunut riippumatta kyseisten satunnaismuuttujien omista jakaumista. Tutkitussa tilanteessa $n = 500$, joten voidaan siis edetä keskeisen raja-arvolauseen perusteella toteuttamaan toistettujen mittausten varianssianalyysiä.

Jotta havainnot voitaisiin syöttää R:n `av`-komentoon, muokataan aineistoa niin, että havainnot *Func-*

tional_M1 ja *Functional_M2* ovat allekkain. Testatessa falsifioutavana nollahypoteesinamme H_0 on $\mu_1 = \mu_1$ eli että sekä ennen että jälkeen leikkauksen tehtyjen mittausten keskiarvot olisivat yhtäsuuret ja näin ollen eroa ei olisi:

```
> fit1 <- aov(Score~Measurement*D2+Error(patient/Measurement*D2), data=oma.otos2_long)
> summary(fit1)

Error: patient
      Df Sum Sq Mean Sq
Measurement 1 0.708 0.708

Error: D2
      Df Sum Sq Mean Sq
Measurement 1 0.8717 0.8717

Error: patient:Measurement
      Df Sum Sq Mean Sq
Measurement 1 23.25 23.25

Error: patient:D2
      Df Sum Sq Mean Sq
Measurement 1 2.16 2.16

Error: patient:Measurement:D2
      Df Sum Sq Mean Sq
Measurement 1 1.242 1.242

Error: Within
      Df Sum Sq Mean Sq F value Pr(>F)
Measurement 1 11.4 11.426 26.850 2.67e-07 ***
Measurement:D2 1 0.3 0.347 0.816 0.366
Residuals 974 414.5 0.426
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Testin tulosteesta voidaan nähdä, että vastaukset ennen ja jälkeen toimenpiteen eroavat tilastollisesti merkitsevästi p-arvon $2.67 \cdot 10^{-7} < 0.001$ perusteella. Matala p-arvo siis todistaa vahvasti nollahypoteesia $H_0 : \mu_1 = \mu_1$ vastaan eli vahvasti alkuperäisen tutkijan esittämän hypoteesin puolesta.

Toisaalta sukupuolten väliset erot eivät mittauksen perusteella näytä olevan tilastollisesti merkitseviä. F-testin p-arvo 0.366 on yli merkitsevyystasojen ja puoltaa näin ollen nollahypoteesia keskiarvojen yhtäsuuruudesta. On siis pääteltävissä, että vastausten eron suuruus ei riipu tilastollisesti merkitsevästi siitä, onko potilas (vastaaja) mies vai nainen.

Mikäli sukupuolten välistä eroa halutaan tutkia tarkemmin, voidaan tehdä parittaisia vertailuja eri ryhmien välillä (ennen ja jälkeen leikkauksen kerättyjen tulosten kesken). Koska tehtävästä tutkimuksesta ei anneta tehtävänannossa enempää taustatietoa, voidaan p-arvojen korjausmenetelmän valinnassa olla suhteellisen luovia. Yksinkertaisuutensa sekä konservatiivisuutensa vuoksi tehtävään voidaan valita esimerkiksi Bonferroni-korjaus, jonka avulla tyyppin I virheen todennäköisyyttä voidaan pienentää huomattavasti:

```

$male

      Pairwise comparisons using t tests with pooled SD

data:  subset_data$Score and subset_data$Measurement

      Functional_M1
Functional_M2 2.4e-06

P value adjustment method: bonferroni

$female

      Pairwise comparisons using t tests with pooled SD

data:  subset_data$Score and subset_data$Measurement

      Functional_M1
Functional_M2 4.6e-14

P value adjustment method: bonferroni

```

Toisin kuin ensiksi tehty toistettujen mittausten varianssianalyysi, Bonferroni-korjattujen parittaisten t-testien tuloksista voidaan nähdä, että sekä miesten että naisten leikkausta edeltävien ja sen jälkeen annettujen vastausten välillä on tilastollisesti merkitsevää eroa. Tätä tukevat naisten kohdalla p-arvo $4.6 \cdot 10^{-14}$, joka on selvästi alle merkitsevyystason 0.001 ja miesten kohdalla p-arvo $2.4 \cdot 10^{-6}$, joka sekin on selvästi alle merkitsevyystason 0.001, mutta kuitenkin huomattavasti suurempi kuin naisten kohdalla. Tästä voitaisiin alustavasti päätellä naisten vastausten välisen erotuksen olevan hieman suurempi kuin miesten vastaavan.

Tärkeimpänä seikkana parittaisten t-testien kautta voidaan kuitenkin todeta tutkijan tehtävänannon mukainen hypoteesi todeksi, sillä testeissä on vahvaa tilastollista merkitsevyyttä jopa konservatiivisella Bonferroni-korjauksella.

Mikäli vastausten yhteyttä potilaiden piirteisiin haluttaisiin tutkia tehtävänannon hypoteesia pidemmälle, voitaisiin esimerkiksi pyrkiä sovittamaan useammista aineiston muuttujista koostuva regressiomalli, mutta tässä tapauksessa tarkoitus oli tutkia hypoteesia nimenomaan toistettujen mittausten varianssianalyysiä hyödyntämällä, minkä johdosta yllä tehdyt päätelmät jäävät voimaan.

3 Kategoristen vastemuuttujien mallinnus

3.1 Kaksiluokkainen selitettävä muuttuja

Lähdetään tutkimaan sukupuolen (*d2*) ja iän (*ika*) yhteyttä työttömyyteen viimeisen 12 kuukauden aikana (*d32*) sovittamalla logistinen binäärinen regressiomalli:

```
> logr_d32 <- glm(d32~d2+ika, data=oma.otos3, family=binomial)
> summary(logr_d32)

Call:
glm(formula = d32 ~ d2 + ika, family = binomial, data = oma.otos3)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -0.195538   0.319978  -0.611   0.541
d2Nainen    -0.282075   0.223802  -1.260   0.208
ika         -0.035546   0.006529  -5.445 5.19e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 583.47  on 785  degrees of freedom
Residual deviance: 549.75  on 783  degrees of freedom
(14 observations deleted due to missingness)
AIC: 555.75

Number of Fisher Scoring iterations: 5
```

R:llä sovitetun mallin yhteenvedosta voidaan nähdä selittäjien estimoidut kertoimet sekä näiden p-arvot. Selittäjän *d2* eli sukupuolen kohdalla voidaan nähdä, että estimoitu kerroin on negatiivinen luokalle *Nainen*, joka viittaisi naisten hieman matalampaan todennäköisyyteen olla työttömänä verrattuna vertailuluokkaan (miehet). Kuitenkin korkea p-arvo 0.208 on yli yleisesti hyvänä pidetyn 5 % merkitsevyystason eli edellä mainittu päätelmä ei ole tilastollisesti merkitsevä. Sen sijaan selittäjän *ika* p-arvo $5.19 \cdot 10^{-8}$ on selvästi alle merkitsevyystason 0.001 eli se on tilastollisesti merkitsevä. Voidaankin havaita, että iän negatiivinen kerroin viittaa siihen, että iän kasvaessa työttömänä olemisen todennäköisyys pienenee (vaikkakin kertoimen pienuudesta johtuen estimoitu vaikutus on pientä).

Mallin tarkempi tulkinta tehdään riskisuhteiden eli niin sanottujen odds ratioiden sekä näille lasketujen 95 % luottamusvälien avulla:

```
> exp(cbind(OR=coef(logr_d32), confint(logr_d32)))
Waiting for profiling to be done...
              OR      2.5 %    97.5 %
(Intercept) 0.8223921 0.4371830 1.5360908
d2Nainen    0.7542175 0.4847419 1.1680555
ika         0.9650784 0.9525006 0.9772467
```

Odds ratiot auttavat tulkitsemaan suhdetta selittäjien ja eri tulosten todennäköisyyksien välillä. Nyt R:llä muodostetusta tulosteesta voidaankin havaita jo aiemmin tehtyjä huomioita tukevia seikkoja.

Naisten odds ratioksi saadaan 0.754, mutta sille laskettu 95 % luottamusväli sisältää myös arvon 1 eli mahdollisuuden sille ettei kyseisellä selittäjällä ole vaikutusta vastemuuttujan $d32$ arvoon. Sen sijaan aiemmin havaitun mukaisesti ikä vaikuttaa olevan tilastollisesti merkitsevä selittäjä, sillä sen odds ratiolle 0.965 laskettu 95 % luottamusväli arvosta 0.953 arvoon 0.977 ei sisällä arvoa 1. Ikä siis näin ollen vaikuttaa 95 % luottamustasolla negatiivisesti työttömyyden todennäköisyyteen (toisin sanoen vanhemmat vastaajat ovat epätodennäköisemmin olleet työttömänä viimeisten 12 kuukauden aikana verrattuna nuorempiin vastaajiin). Alla vielä tarkat 95 % luottamusvälit tulosteesta:

- Sukupuoli ($d2$): [0.4847419, 1.1680555]
- Ikä (ika): [0.9525006, 0.9772467]

Lopuksi mallille voidaan laskea Nagelkerke-selitysaste: $R^2 = 0.08012942 \approx 0.0801$. Selitysastetta voidaan tulkita siten, että muodostettu malli selittää noin 8.01 % työttömyyttä koskevissa vastauksissa esiintyvistä vaihtelusta.

Yhteenvetona sovitetusta logistisesta regressiomallista voidaan siis sanoa, että mallin perusteella sukupuoli ei ole tilastollisesti merkitsevää yhteyttä siihen, onko vastaaja ollut työttömänä viimeisen 12 kuukauden aikana, mutta iällä sen sijaan on tilastollisesti merkitsevä negatiivinen vaikutus työttömyyden olemiseen. Toisin sanoen siis mitä vanhempi vastaaja on, sitä epätodennäköisemmin tämä on ollut työttömänä kuluneena ajanjaksona. Valituista selittäjistä työttömyyttä selittää siis ikä, muttei sukupuoli. Mallin suhteellisen heikko selitysaste myös viittaa siihen, että valitut selittäjät ovat loppupeleissä kuitenkin huonoja selittämään kuvaillun kaltaista työttömyyttä ja tosiasiallisessa tutkimuksessa olisi tässä tapauksessa syytä sovittaa mallia, jossa selittäjiä valittaisiin enemmän.

4 Monimuuttujamenetelmät

4.1 Muuttujien ryhmittely

Muodostetaan pääkomponenttianalyysillä aineiston luokitelluista muuttujista (yht. 41 kappaletta) pääkomponentteja ominaisarvokriteerin mukaan hyödyntäen Promax-rotatiota. Pääkomponenttianalyysiin ei liity jakauma- tai korrelaatio-oletuksia, mutta kuitenkin oletetaan, että muuttujien välillä on tilastollisesti merkitseviä korrelaatioita. Tässä tapauksessa otoskoko $n = 1600$ on myös enemmän kuin riittävä pääkomponenttianalyysin suorittamiseen. Myös aineiston kategoriset muuttujat on jo valmiiksi ilmoitettu numeerisessa muodossa, joten aineistoa ei tarvitse käsitellä ennen analyysiä.

Ennen varsinaista pääkomponenttianalyysiä voidaan aineistosta muodostetun korrelaatiomatriisin sopivuutta tutkia esimerkiksi Kaiser-Meyer-Olkin-testin (KMO) avulla:

```
> KMO(data.kor1)
Kaiser-Meyer-Olkin factor adequacy
Call: KMO(r = data.kor1)
Overall MSA = 0.71
MSA for each item =
```

autom_lainan_perinta_luok	lainojen_lukumaara_luok	asuntoluotot1_luok
0.89	0.86	0.65
automaattinostoja_luok	vakuutus_a_luok	asuntolaina_a_kpl_luok
0.98	0.78	0.49
asuntolaina_b_kpl_luok	vakuutus_b_luok	vakuutus_c_luok
0.56	0.71	0.74
korkeakork_kpl_luok	rahasto_a1_luok	pankkikorttilkm_luok
0.57	0.24	0.64
luottokortteja_yhteensa_luok	maaraaikaistileja_luok	maksuautomaattitapahtumia_luok
0.65	0.71	0.75
kayttotili_tal_luok	kayttotili_vel_luok	asuntolaina_c_kpl_luok
0.67	0.81	0.55
osakkeet_euroa_1_luok	eri_osakesarjoja_luok	rahasto_b1_luok
0.58	0.62	0.37
ottoja_luok	pkorttimaksuja_luok	panoja_luok
0.89	0.80	0.98
asuntolaina_d_kpl_luok	palveluja_kpl_luok	rahastolajeja_luok
0.53	0.89	0.46
lainarastit_luok	saastotililla_luok	asuntolaina_e_kpl_luok
0.69	0.63	0.53
suoraveloituksia_luok	netissa_maksut_luok	maksupalvelussa_maksut_luok
0.86	0.79	0.72
tiskilla_maksut_luok	tilinylityspaivat_luok	toimeksianto_a_kpl_luok
0.71	0.85	0.64
toimeksianto_b_kpl_luok	kv_maksukortit_luok	rahasto_c1_luok
0.60	0.66	0.37
korttiluotot1_luok	kulutustuotot1_luok	
0.85	0.82	

KMO-testin MSA-suureet (measure of sampling adequacy) kertovat, kuinka hyvin kyseinen indikaattori soveltuu analyysiin. R:llä tuotetusta tulosteesta voidaan poimia seuraavat tiedot:

Kriteerilaji	Otoksesta laskettu	Toteutuuko edellytys?
KMO-suureen arvo	0.71	Kyllä, koska $MSA > 0.6$

Saatua MSA-kokonaisarvoa voidaan pitää riittävän hyvänä pääkomponenttianalyysin toteuttamiseen (lähtökohtaisena välttävänä rajana yleisesti pidetty esimerkiksi 0.6, mutta mitä korkeampi suureen arvo on, sitä paremmin muuttujat soveltuvat). Nyt voidaan siis siirtyä itse pääkomponenttianalyysiin:


```

> summary(pca)
Importance of components:
      PC1      PC2      PC3      PC4      PC5      PC6      PC7      PC8      PC9      PC10     PC11     PC12
Standard deviation  3.4498 2.00233 1.84979 1.55917 1.30413 1.26005 1.20892 1.15330 1.08888 1.05528 1.0001 0.97214
Proportion of Variance 0.2903 0.09779 0.08346 0.05929 0.04148 0.03873 0.03565 0.03244 0.02892 0.02716 0.0244 0.02305
Cumulative Proportion 0.2903 0.38806 0.47152 0.53081 0.57229 0.61102 0.64667 0.67911 0.70803 0.73519 0.7596 0.78263
      PC13      PC14      PC15      PC16      PC17      PC18      PC19      PC20      PC21      PC22      PC23      PC24
Standard deviation  0.9256 0.88081 0.86304 0.84507 0.82555 0.77807 0.73645 0.72864 0.71130 0.64958 0.64897 0.58261
Proportion of Variance 0.0209 0.01892 0.01817 0.01742 0.01662 0.01477 0.01323 0.01295 0.01234 0.01029 0.01027 0.00828
Cumulative Proportion 0.8035 0.82245 0.84062 0.85804 0.87466 0.88942 0.90265 0.91560 0.92794 0.93823 0.94851 0.95679
      PC25      PC26      PC27      PC28      PC29      PC30      PC31      PC32      PC33      PC34      PC35
Standard deviation  0.56206 0.54977 0.50330 0.48404 0.41057 0.35841 0.31047 0.27388 0.23433 0.21014 0.20138
Proportion of Variance 0.00771 0.00737 0.00618 0.00571 0.00411 0.00313 0.00235 0.00183 0.00134 0.00108 0.00099
Cumulative Proportion 0.96449 0.97186 0.97804 0.98376 0.98787 0.99100 0.99335 0.99518 0.99652 0.99760 0.99859
      PC36      PC37      PC38      PC39      PC40      PC41
Standard deviation  0.15957 0.11838 0.09207 0.07635 0.06488 1.162e-15
Proportion of Variance 0.00062 0.00034 0.00021 0.00014 0.00010 0.000e+00
Cumulative Proportion 0.99921 0.99955 0.99976 0.99990 1.00000 1.000e+00
> # Ominaisarvot
> (pca$sdev)^2
 [1] 1.190128e+01 4.009329e+00 3.421721e+00 2.431012e+00 1.700751e+00 1.587734e+00 1.461487e+00 1.330096e+00
 [9] 1.185656e+00 1.113615e+00 1.000202e+00 9.450471e-01 8.567398e-01 7.758218e-01 7.448432e-01 7.141462e-01
[17] 6.815313e-01 6.053948e-01 5.423626e-01 5.309221e-01 5.059448e-01 4.219579e-01 4.211674e-01 3.394364e-01
[25] 3.159145e-01 3.022500e-01 2.533117e-01 2.342943e-01 1.685656e-01 1.284571e-01 9.639334e-02 7.500834e-02
[33] 5.490956e-02 4.415705e-02 4.055251e-02 2.546149e-02 1.401490e-02 8.477346e-03 5.829707e-03 4.209036e-03
[41] 1.351083e-30

```

Nyt muodostettuja pääkomponentteja (yht. 41 kappaletta) lähdetään analysoimaan ominaisarvokriteerien perusteella. Lähtökohtana voidaan pitää sitä, että keskihajontaa kuvaava ominaisarvo (*Standard deviation*) olisi yli raja-arvon 1. Tämä perustuu Kaiserin kriteeriin, jota monet tilastolliset ohjelmistot, kuten SPSS, käyttävät vakioasetuksena. Tällä perusteella jäljelle jäävät pääkomponentit *PC1-PC11*, jotka saavat seuraavat ominaisarvot (likiarvot):

PC	Ominaisarvo	PC	Ominaisarvo
1	11.90	6	1.59
2	4.01	7	1.46
3	3.42	8	1.33
4	2.43	9	1.19
5	1.70	10	1.11
		11	1.00



Nyt valittujen pääkomponenttien kumulatiivinen selitysprosentti on noin 75.96 %. Tätä voidaan pitää riittävänä selitysasteena, sillä yleisesti tavoiteltava taso tälle on noin 70-90 %. Tehtävänannon kontekstissa tarkan rajan määrittäminen on haastavaa, sillä se vaihtelee perustuen siihen, halutaanko selittää vaihtelua mahdollisimman pienellä pääkomponenttien lukumäärällä vai tähdätäkö vain korkeaan selitysasteeseen.

Valitaan siis yllä mainitut pääkomponentit *PC1-PC11* Promax-rotatioon pyrkimyksenä erotella ne selvästi toisistaan, jotta niiden myöhempi latauksiin perustuva tulkinta helpottuisi. Vinorotaatiomenetelmät, kuten nyt käytetty Promax-rotatio, sallivat komponenttien korreloimisen keskenään määritellyn δ -arvon mukaisesti. Tutkitaan näin muodostettuja latauksia:

Loadings:	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8	PC9	PC10	PC11
autom_lainan_perinta_luok				0.365							
lainojen_lukumaara_luok				0.339					-0.165		
asuntoluotot1_luok				0.436							
automaattinostaja_luok	-0.394										
vakuutus_a_luok					0.102		-0.160		0.107	-0.598	0.110
asuntolaina_a_kpl_luok		-0.101		0.439			-0.189				-0.246
asuntolaina_b_kpl_luok			0.137			0.757					
vakuutus_b_luok			-0.154				-0.246			0.582	
vakuutus_c_luok		-0.195			-0.187	-0.113		-0.361			
korkeakork_kpl_luok		-0.168					-0.101	-0.422	0.105		
rahasto_a1_luok						0.525	-0.102			0.250	
pankkikorttikm_luok	-0.393						-0.192			-0.115	
luottokortteja_yhteensa_luok				-0.114	-0.173	-0.102		0.290	0.552		
maaraaikaistileja_luok								-0.421			-0.162
maksuautomaattitapahtumia_luok	-0.376			-0.130			-0.108		-0.161		
kayttotili_tal_luok		0.255						-0.286			-0.171
kayttotili_vel_luok				-0.130	-0.133		0.634	0.199			
asuntolaina_c_kpl_luok				0.202			0.108			0.104	0.287
osakkeet_euroa_1_luok					0.668						
eri_osakesarjoja_luok					0.614						
rahasto_b1_luok			-0.532							0.118	
ottoja_luok	-0.353										
pkorttimaksuja_luok	-0.346										
panoja_luok	-0.349	0.163									
asuntolaina_d_kpl_luok	0.172			0.420			-0.161	0.120		-0.102	
palveluja_kpl_luok	-0.249			0.171							
rahastolajeja_luok			-0.572								
lainarastit_luok						-0.161	0.113		-0.507		
saastotililla_luok								-0.488			-0.128
asuntolaina_e_kpl_luok		0.137					-0.135	0.162		-0.127	0.860
suoraveloituksia_luok	-0.107	0.341					0.102		0.268		
netissa_maksut_luok	-0.192	-0.158		0.135					0.137		-0.108
maksupalvelussa_maksut_luok		0.551									
tiskilla_maksut_luok		0.580									0.128
tilinylityspaivat_luok	-0.223					-0.104		0.163	-0.265		
toimeksianto_a_kpl_luok	-0.103	0.207			0.205	-0.233	-0.145	0.158	0.198	0.409	
toimeksianto_b_kpl_luok				-0.153	0.161		0.644		-0.120		-0.189
kv_maksukortit_luok			-0.135	0.184			0.252		0.166		
rahasto_c1_luok			-0.512			-0.131				-0.145	
korttiluotot1_luok								0.243	0.285		-0.214
kulutusluotot1_luok		0.101		0.312		-0.112		0.121	-0.235		-0.137
SS loadings	1.048	1.055	1.049	1.160	1.028	1.046	1.216	1.166	1.071	1.077	1.154
Proportion Var	0.026	0.026	0.026	0.028	0.025	0.026	0.030	0.028	0.026	0.026	0.028
Cumulative Var	0.026	0.051	0.077	0.105	0.130	0.156	0.185	0.214	0.240	0.266	0.294

Latauksista voidaan tehdä muutamia havaintoja: esimerkiksi muuttujan *asuntolaina_e_kpl_luok* (pos.) lataus pääkomponentille 3 (*PC3*) on 0.860 ja vastaavasti muuttujan *vakuutus_a_luok* (neg.) lataus pääkomponentille 10 (*PC10*) on -0.598. Molemmat ovat itseisarvoltaan hyvin suuria sekä näin ollen merkittäviä latauksia. Lataukset voidaankin tavallaan ajatella muuttujien ja pääkomponenttien välisiksi korrelaatiokertoimiksi eli toisin sanoen mitä itseisarvoltaan suurempi lataus on, sitä vahvemmin kyseinen muuttuja kytkeytyy tiettyyn ulottuvuuteen (positiivisesti tai negatiivisesti).

Pääkomponenttianalyysin tuloksena saadut pääkomponenttipistemäärät voidaan nyt tallettaa havainnotmatriisiin uusiksi arvoiksi R:n komentoa `pca$x` hyödyntäen, jonka jälkeen pääkomponentit *PC1-PC11* voidaan pyrkiä nimeämään pistemäärien perusteella mahdollisimman kuvailevasti:

- *PC1*: Taloudellinen vakaus
 - Positiiviset: *kayttotili_tal_luok*, *korkeakork_kpl_luok*, *saastotililla_luok*
 - Negatiiviset: *autom_lainan_perinta_luok*, *lainojen_lukumaara_luok*, *asuntoluotot1_luok*, *automaattinostoja_luok*
 - Eri tilityyppien hyödyntäminen ja korkeakorkoisten tilien avulla säästäminen viittaa talouden hallintaan, jota tukee myös lainojen ja erilaisten luottojen matala määrä
- *PC2*: Transaktioaktiivisuus
 - Positiiviset: *maksupalvelussa_maksut_luok*, *suoraveloituksia_luok*, *panoja_luok*, *pkorttimaksuja_luok*
 - Negatiiviset: *linarastit_luok*, *kulutushuotot1_luok*, *tilinylityspaivat_luok*
 - Korttimaksujen, talletusten, ymv. transaktioiden suuri lukumäärä viittaa maksujärjestelmien aktiiviseen käyttöön, lisäksi luottojen ja lainojen matala määrä viittaa siihen, että kyse on nimenomaisesti maksujärjestelmien eikä luottojärjestelmien aktiivisesta käytöstä
- *PC3*: Perinteisten palvelujen käyttö
 - Positiiviset: *tiskilla_maksut_luok*, *kayttotili_tal_luok*, *maaraaikaistileja_luok*, *maksupalvelussa_maksut_luok*
 - Negatiiviset: *rahasto_c1_luok*, *rahastolajeja_luok*, *eri_osakesarjoja_luok*
 - Perinteisten pankkipalveluiden sekä tiskillä maksamisen suosiminen viittaavat perinteiseen lähestymistapaan maksamista kohtaan, jota myös tukee monimutkaisempien instrumenttien, kuten rahastojen ja osakkeiden, vähäisyys
- *PC4*: Asuntolainakeskeisyys
 - Positiiviset: *autom_lainan_perinta_luok*, *asuntoluotot1_luok*, *asuntolaina_c_kpl_luok*, *asuntolaina_e_kpl_luok*
 - Negatiiviset: *luottokortteja_yhteensa_luok*, *maksuautomaattitapahtumia_luok*, *korttiluotot1_luok*
 - Vahva suhde erilaisiin asunto- ja kiinteistölainoihin yhdistettynä muiden luottopalveluiden matalaan käyttöasteeseen viittaavat tyypilliseen tilanteeseen, jossa asuntolainalla (ja siihen liittyvillä elementeillä, kuten esim. koroilla) on suuri merkitys henkilökohtaiselle taloudelle

- *PC5*: Korkeariskinen sijoitustoiminta
 - Positiiviset: *osakkeet_euroa_1_luok*, *toimeksianto_a_kpl_luok*, *toimeksianto_b_kpl_luok*, *eri-osakesarjoja_luok*
 - Negatiiviset: *rahastolajeja_luok*, *asuntolaina_d_kpl_luok*, *asuntolaina_a_kpl_luok*
 - Euromääräisesti paljon osakkeita sekä toimeksiantojen suuri lukumäärä viittaavat korkeaan sijoitusaktiivisuuteen tai jopa treidaukseen tmv. korkeamman riskin sijoitustoimintaan, sillä vakaampien ja pieniriskisempien sijoitusinstrumenttien, kuten rahastojen tai kiinteistöjen, määrä on pieni
- *PC6*: Matalariskinen sijoitustoiminta
 - Positiiviset: *rahasto_a1_luok*, *vakuutus_b_luok*, *asuntolaina_b_kpl_luok*
 - Negatiiviset: *vakuutus_a_luok*, *vakuutus_c_luok*, *luottokortteja_yhteensa_luok*
 - Monipuolisesti erilaisia vakaampia sijoitusinstrumentteja (vrt. esim. osakkeisiin), kuten rahastoja, vakuutuksia sekä asuntoja/kiinteistöjä
- *PC7*: Velkojen ja lainojen hallinta
 - Positiiviset: *kayttotili_vel_luok*, *toimeksianto_b_kpl_luok*, *lainarastit_luok*
 - Negatiiviset: *asuntolaina_a_kpl_luok*, *toimeksianto_a_kpl_luok*
 - Velkaa sekä lainarästejä löytyy, mutta toisaalta myös B-tyypin toimeksiantoja (ei kuitenkaan esim. tyypillistä asuntolainaa, joka keskiwerrolla kuluttajalla aiheuttaa suurimman osan velasta), mikä viittaa tietyn tyyppiseen erityiseen lainanhallintastrategiaan
- *PC8*: Kuluttajapalveluiden käyttö
 - Positiiviset: *vakuutus_a_luok*, *luottokortteja_yhteensa_luok*, *asuntolaina_e_kpl_luok*, *tiskilla_maksut_luok*
 - Negatiiviset: *maaraaikaistileja_luok*, *vakuutus_c_luok*
 - Hyvin keskivertokuluttajan mukaisesti muun muassa vakuutuksia, asuntolainaa sekä luottokorttien hyödyntämistä, lisäksi määräaikaistilien sekä C-tyypin vakuutuksiin säästämisen/sijoittamisen pieni määrä viittaa nimenomaisesti tyypillisen kuluttajan maksukäyttäytymiseen
- *PC9*: Kulutusluottojen hallinta
 - Positiiviset: *asuntolaina_b_kpl_luok*, *luottokortteja_yhteensa_luok*

- Negatiiviset: *lainarastit_luok*
- Asuntolaina sekä kokonaisluoton määrä korostuvat, mutta lainarästejä ei ole, mikä viittaa tarkkaan ja harkitsevaan kulutusluottojen hallintaan
- *PC10*: Riskinotto kyky
 - Positiiviset: *vakuutus_b_luok*, *toimeksianto_a_kpl_luok*
 - Negatiiviset: *vakuutus_a_luok*, *asuntolaina_b_kpl_luok*, *osakkeet_euroa_1_luok*, *eri_osakesarjoja_luok*
 - Sitoutumista tiettyihin vakuutus- ja toimeksiantotyyppisiin, kuitenkin vältellen muita sijoitusinstrumentteja, kuten asuntoja, osakkeita tai muun tyyppisiä vakuutuksia, mikä viittaa tarkasti mietityn riskitason toimintaan
- *PC11*: Asuntomarkkinoiden sitoutuminen
 - Positiiviset: *asuntolaina_b_kpl_luok*, *asuntolaina_e_kpl_luok*
 - Negatiiviset: *kulutustuotot1_luok*
 - Suuri määrä erityyppisiä asuntolainoja, mutta kuitenkin pieni määrä päivittäiskulutukseen suunnattuja luottoja viittaavat lainapainotteiseen sitoutumiseen asunto- ja kiinteistömarkkinoihin (esim. sijoitusmielessä)

Pääkomponenttien nimet voidaan nyt tallettaa havaintomatriisiin, josta niitä voidaan hyödyntää seuraavan vaiheen klusterianalyysin avulla muodostettujen ryhmien kuvailussa.

4.2 Havaintojen ryhmittely

Käytetään nyt pääkomponenttianalyysin avulla muodostettua matriisia, jossa pääkomponentit on nimetty mahdollisimman kuvailevasti laskettujen latausten perusteella. Uusien muuttujien avulla voidaan muodostaa asiakasryhmiä k-means klusteroinnin (k-keskiarvoklusteroinnin) avulla, kun klusterien lukumäärä $k \in \{2, 3, 4, 5\}$. Valitaan R:n `kmeans` -komennon `nstart` -parametrin arvoksi 100 eli ajetaan sama algoritmi siis sadan satunnaisen lähtöpisteen kautta, jotta tuloksista saadaan mahdollisimman kattavat:

$k = 2$:

```
K-means clustering with 2 clusters of sizes 21, 20

Cluster means:
Taloudellinen vakaus Transaktioaktiivisuus Perinteisten palvelujen käyttö Asuntolainakeskeisyys
1      2.953555      0.2360106      -0.1135447      -0.03665129
2     -3.101233     -0.2478111      0.1192220      0.03848385
Korkeariskinen sijoitustoiminta Matalariskinen sijoitustoiminta Velkojen ja lainojen hallinta
1      0.1025943      0.06021152      -0.009472842
2     -0.1077241     -0.06322210      0.009946485
Kuluttajapalveluiden käyttö Kulutusluottojen hallinta Riskinottokyky Asuntomarkkinoihin sitoutuminen
1      0.1618623      0.06309190      -0.01151797      0.1357735
2     -0.1699554     -0.06624649      0.01209387     -0.1425622
```

Kahden klusterin analyysistä nähdään, että havainnot jakautuvat tasaisesti: 21 ensimmäiseen ja 20 havaintoa toiseen klusteriin. Klusterit eroavat merkittävästi etenkin taloudellisen vakauden osalta, jolle ensimmäinen klusteri saa keskiarvoksi likimain 2.95 ja toinen klusteri likimain -3.10 . Muita huomionarvoisia klustereita kuvailevia piirteitä ovat transaktioaktiivisuus, perinteisten palveluiden suosiminen sekä sitoutuminen asuntomarkkinoihin.

Ensimmäiseen klusteriin ryhmitellyt asiakkaat ovat siis taloudellisesti vakaammassa tilanteessa, ovat transaktioiden osalta aktiivisempia, suosivat vähemmän perinteisiä palveluja sekä ovat sitoutuneempia asuntomarkkinoihin asuntolainojen osalta. Kyseinen ryhmä voisikin siis kuvailla nykypäivän pankkien keskiluokkaista asiakasennemmistöä, joka on saavuttanut taloudellisesti stabiilin elämänvaiheen eikä omaa muita huomattavia velkoja tai luottoja kuin asuntolainan.

Toisessa klusterissa puolestaan korostuvat ensimmäisen vastakohdat. Kyseinen asiakasryhmä on taloudellisesti epästabiilimmassa tilanteessa, suosii perinteisempiä palveluja eikä ole yhtä sitoutunut asuntomarkkinoihin lainojen kautta. Verrattuna ensimmäiseen klusteriin, toisen klusterin asemointi reaaliaikailman tilanteeseen on huomattavasti hankalampaa. Toisaalta kyseinen ryhmä voisi esimerkiksi koostua eläkeläisistä, jotka elävät pienten eläkkeiden varassa, suosivat perinteisempiä palveluja, mutta eivät toisaalta käytä runsaasti rahaa tai omaa asuntolainaa. Toisaalta se voisi myös kuvailla nuorempia asiakkaita, joiden tulot eivät ole vielä vakiintuneet, eivätkä he ole vielä ehtineet elämässään vaiheeseen, jossa esimerkiksi asuntolaina tai säästämiseen keskittyminen olisivat ajankohtaisia asioita.

$k = 3$:

K-means clustering with 3 clusters of sizes 16, 17, 8

Cluster means:

	Taloudellinen vakaus	Transaktioaktiivisuus	Perinteisten palvelujen käyttö	Asuntolainakeskeisyys
1	1.936602	-1.1066006	-1.04244576	-0.1083796
2	-3.566786	0.2075592	0.01586511	-0.1577140
3	3.706216	1.7721378	2.05117817	0.5519016

	Korkeariskinen sijoitustoiminta	Matalariskinen sijoitustoiminta	Velkojen ja lainojen hallinta
1	0.2443947	0.19995967	0.2516001
2	-0.1398316	-0.01784345	-0.1872132
3	-0.1916472	-0.36200201	-0.1053722

	Kuluttajapalveluiden käyttö	Kulutusluottojen hallinta	Riskinotto kyky	Asuntomarkkinoihin sitoutuminen
1	0.4152016	0.1617092	0.052363555	0.11440572
2	-0.2369017	-0.1013006	0.004673791	-0.08654231
3	-0.3269871	-0.1081545	-0.114658915	-0.04490903

Kolmen klusterin analyysistä nähdään, että yksiköt eivät enää jakaudu kahden klusterin tavoin tasaisesti, vaan ensimmäinen klusteri sisältää 16 yksikköä, toinen 17 yksikköä ja kolmas vain 8. Klusterit eroavat jälleen erityisesti taloudellisen stabiiliteetin, transaktioaktiivisuuden, perinteisten palveluiden käytön sekä asuntolainakeskeisyyden osalta.

Ensimmäiseen klusteriin ryhmiteltyt asiakkaat ovat suhteellisen stabiilissa taloudellisessa tilanteessa, mutta kuitenkin epävakammassa kuin klusteriin kolme ryhmiteltyä asiakkaat. Sekä transaktioaktiivisuus että perinteisten palveluiden käyttö ovat huomattavan negatiivisia, joka viittaa hyvin mataliin pankkipalveluiden käyttöasteisiin. Vähemmän merkittävistä tuloksista korostuvat sekä matala- että korkeariskisen sijoitustoiminnan ja erilaisten pankin tarjoamien kuluttajapalveluiden käyttö. Kyseessä voisi olla siis esimerkiksi asiakasryhmä, joka hoitaa talousasiansa pääasiallisesti verkon ja muiden perinteisiä palveluita nykyaikaisempien menetelmien kautta hyödyntäen joustoa tarjoavia pankkipalveluita, kuten kulutusluottoja sekä pienimuotoisia sijoituksia.

Toinen klusteri puolestaan keskittyy epästabiiliin talouden sekä vähäisen sijoitustoiminnan ja kuluttajapalveluiden käyttöasteen ympärille. Klusteriin kuuluvat asiakkaat ovat selkeästi kahta muuta klusteria huonommassa taloudellisessa tilanteessa, joka loogisesti myös vähentää esimerkiksi sijoitustoiminnan määrää. Kyseessä voisi olla esimerkiksi varsin tyypillinen pankin asiakasryhmä, joka hyödyntää arkisissa yhteyksissä erilaisia transaktioita, muttei kuitenkaan perehdy tarkemmin monimutkaisempiin palveluihin, kuten kulutusluottoihin tai sijoitusinstrumentteihin.

Kolmas, merkittävästi kahta muuta pienempi, klusteri eroaa kahdesta muusta selvällä marginaalilla taloudellisen stabiiliteetin osalta. Myös transaktioaktiivisuus sekä perinteisten palveluiden käyttöaste ovat korkeita. Asuntolainakeskeisyys on myös muita klustereita korkeampi, mutta toisaalta samalla muiden sijoitusten kohdalla arvot ovat negatiivisia. Klusterin mukainen asiakasryhmä voisi näin ollen koostua esimerkiksi asiakkaista, jotka keskittyvät taloudellisten riskien minimoimiseen pitämällä varojaan pääosin likvidinä käteisenä. Toisaalta korkea taloudellinen stabiiliteetti saattaa myös aiheuttaa sen, ettei erilaisten sijoitusinstrumenttien kylkiäisenä tulevia riskejä ole enää tarpeen ottaa omaisuuden kasvattamiseksi.

$k = 4$:

K-means clustering with 4 clusters of sizes 11, 5, 9, 16				
Cluster means:				
	Taloudellinen vakaus	Transaktioaktiivisuus	Perinteisten palvelujen käyttö	Asuntolainakeskeisyys
1	0.8393674	-2.0068171	0.30180946	-0.278000126
2	3.3103073	0.7022198	-3.93683758	-0.097715589
3	3.6948918	1.5223566	1.84398340	0.388769208
4	-3.6899127	0.3039175	-0.01447292	0.002978529
	Korkeariskinen sijoitustoiminta	Matalariskinen sijoitustoiminta	Velkojen ja lainojen hallinta	
1	0.5080609	-0.089507716	0.1382397	
2	-0.1542837	0.115447538	0.5544259	
3	-0.2155135	0.003871472	-0.1871391	
4	-0.1798519	0.023281496	-0.1630322	
	Kuluttajapalveluiden käyttö	Kulutusluottojen hallinta	Riskinotto-kyky	Asuntomarkkinoihin sitoutuminen
1	0.6371767	0.6438559	0.01226821	0.31482539
2	0.2593745	-0.3527035	-0.27392691	-0.44899833
3	-0.3479795	-0.2338521	0.18960421	-0.08489925
4	-0.3233751	-0.2008893	-0.02948460	-0.02837465

Neljän klusterin analyysistä voidaan havaita samankaltaista epätasapainoa klusterien kokojen kesken: ensimmäinen klusteri sisältää 11 yksikkö, toinen 5, kolmas 9 ja neljäs suurimpana klusterina 16 yksikköä. Klusterit eroavat pääasiallisesti taloudellisen stabiliteetin, transaktioaktiivisuuden, perinteisten palveluiden käyttöasteen, asuntolainakeskeisyyden sekä erilaisten sijoitus- ja luottopalveluiden käytön osalta.

Ensimmäisessä klusterissa korostuvat suhteellisen korkea taloudellinen stabiliteetti sekä merkittävän negatiivinen transaktioaktiivisuus. Lisäksi huomioitava yhteys löytyy korkeariskisten sijoitusten, kuluttajapalveluiden käytön sekä kulutusluottojen hallinnan väliltä, joka korostaa halukkuutta korkeariskisiin, jopa taloudellista stabiliteettia huomattavasti heikentäviin, sijoituksiin. Kyseinen asiakasryhmä profiloituu siis etenkin sijoitus- ja luottotoiminnan kautta, kun taas päivittäinen transaktioaktiiviteetti jää vähemmälle. Tämä saattaa viitata esimerkiksi siihen, että kyseisellä asiakasryhmällä on pääasiallinen asiakkuus jossakin muussa pankissa.

Toisessa, neljän klusterin ryhmän pienimmässä, klusterissa korostuvat erittäin korkea taloudellinen stabiliteetti sekä erittäin alhainen perinteisten palveluiden käyttöaste. Lisäksi huomionarvoista on suhteellisen korkea velkojen ja lainojen hallinnan painotus, joka ei kuitenkaan asuntomarkkinoiden matalan sitoutumisen perusteella liity kiinteistö- tai asuntomarkkinoihin esimerkiksi asuntolainan kautta. Klusterin asiakasryhmä voisikin esimerkiksi koostua asiakkaista, jotka hyötyvät erilaisista pankkien luotto-ohjelmista kuitenkin pitäen taloutensa aina stabiilina esimerkiksi käteisvarojen avulla.

Kolmannessa klusterissa korostuu neljän klusterin ryhmän suurin taloudellinen stabiliteetti yhdistettynä suhteellisen korkeaan transaktioaktiivisuuteen ja perinteisten palveluiden käyttöasteeseen. Lainoista, luotoista ja sijoitusinstrumenteista vain asuntolaina on keskeisessä asemassa kyseisen asiakasryhmän kohdalla. Kyseessä saattaa siis esimerkiksi olla hyvin perinteisten kuluttajien ryhmä, jossa arjen pankkipalvelut ovat aktiivisessa käytössä ja pankista haetaan esimerkiksi asuntolainaa, muttei kuitenkaan tehdä muita merkittäviä sijoituksia.

Neljäs klusteri edustaa taloudellisesti epästabiilimmassa asemassa olevaa asiakasryhmää, jossa transaktioaktiivisuus on suhteellisen matala, eikä oikeastaan mitään pankin palveluita käytetä merkittävässä määrin. Kyseinen asiakasryhmä koostuukin esimerkiksi asiakkaista, jotka ovat pidempiaikaisessa heikossa taloudellisessa asemassa, eivätkä näin ollen pysty hyödyntämään pankin tarjoamia palveluita.

$k = 5$:

K-means clustering with 5 clusters of sizes 7, 8, 8, 8, 10

Cluster means:

	Taloudellinen vakaus	Transaktioaktiivisuus	Perinteisten palvelujen käyttö	Asuntolainakeskeisyys
1	3.3759724	0.1751199	-2.85311564	-0.3088616
2	3.7062159	1.7721378	2.05117817	0.5519016
3	-2.8632266	-1.0424692	-0.14107758	1.7598966
4	-4.2056613	1.7243852	0.02374757	-1.3085634
5	0.3269569	-2.0858270	0.45010243	-0.5863847

Korkeariskinen sijoitustoiminta Matalariskinen sijoitustoiminta Velkojen ja lainojen hallinta

1	-0.24952834	1.0736110	0.2417563
2	-0.19164723	-0.3620020	-0.1053722
3	-0.66188495	-0.1091908	-0.8612749
4	0.06713221	0.1327496	0.1419485
5	0.80378981	-0.4807731	0.4905294

Kuluttajapalveluiden käyttö Kulutusluottojen hallinta Riskinottoa Kyky Asuntomarkkinoihin sitoutuminen

1	0.03988609	-0.20817733	0.12923730	-0.28250462
2	-0.32698706	-0.10815447	-0.11465891	-0.04490903
3	0.07753496	0.04464511	0.23019153	-0.48900895
4	-0.50578137	-0.15266377	-0.25766671	0.39750345
5	0.57626651	0.31866264	0.02324116	0.30688486

Viimeisessä, viiden klusterin analyysissä voidaan huomata selkeästi tasainen klusterien yksikköjen jakauma: ensimmäinen klusteri sisältää 7 yksikköä, toinen, kolmas ja neljäs 8 yksikköä ja viides klusteri 10 yksikköä. Klustereissa korostuvat jälleen aiempien klusterointien mukaisesti taloudellinen stabiilitetti, transaktioaktiivisuus, perinteisten palveluiden käyttöaste sekä erilaisten lainojen ja eri riskiluokkiin kuuluvien sijoitusinstrumenttien hyödyntäminen.

Sekä ensimmäinen että toinen klusteri kuvaavat erittäin hyvän taloudellisen stabiilitetin omaavia asiakasryhmiä. Merkittävänä erona klusterien välillä ovat kuitenkin sekä transaktioaktiivisuus että perinteisten palveluiden käyttöaste. Toisessa klusterissa korostuvat enemmän perinteisemmät ja arkisemmat pankkitoiminnot transaktioista asuntolainaan, kun taas ensimmäisessä klusterissa etenkin matalariskinen sijoitustoiminta on merkittävässä roolissa. Ensimmäinen klusteri voidaankin nähdä pikemminkin pitkäaikaiseen säästö- ja sijoitustoimintaan tähtäävinä asiakkaina, kun taas toisen klusterin asiakkaat taloudellisesti hyvin pärjäävinä, mutta perinteisempiä ja arkisempia palveluita kaipaavana ryhmänä.

Kolmas ja neljäs klusteri puolestaan edustavat erittäin epästabiilissa taloudellisessa tilanteessa olevia asiakkaita. Keskeisenä erona kyseisten klustereiden välillä on kuitenkin se, miten erilaisia sijoitusinstrumentteja hyödynnetään. Erityisesti kolmannen klusterin asiakasryhmän kohdalla voidaan huomata, että asuntolainakeskeisyydellä on suhteellisen suuri rooli, mutta asuntomarkkinoihin sijoitusmielessä sitoutuminen tai muut sijoitusinstrumentit eivät varsinaisesti kuulu ryhmän intresseihin. Myös ryhmän transaktioaktiivisuus on suhteellisen matala, kun taas neljännen klusterin kohdalla tilanne on päinvastainen. Kolmannen klusterin asiakasryhmää voitaisinkin kuvailla esimerkiksi yli omien varojensa asuntolainoja ottaneina keskivertokuluttajina, kun taas neljännen klusterin asiakasryhmää yksinkertaisesti epästabiilissa tilanteessa olevina kuluttajina, jotka kenties transaktioaktiivisuuden kautta pyrkivät vaikuttamaan omaan taloudelliseen tilanteeseensa.

Viides, aineiston suurin, klusteri eroaa muista huomattavan negatiivisella transaktioaktiivisuudella sekä suhteellisen suuren roolin saaneilla korkeariskisillä sijoituksilla. Kyseessä voisikin olla esimerkiksi asiakasryhmä, joka hyödyntää pankkia ainoastaan osakkeiden tai muiden vastaavien korkeampiriskisten sijoitusinstrumenttien kaupankäyntiin arkisten pankkitoimintojen sijaan.

Kokonaisuudessaan eri klusterimäärien testaamisen kautta voidaan huomata, että mitä suurempi määrä klustereita analyysiin otetaan käyttöön, sitä paremmin spesifit asiakasryhmät alkavat erottua massasta. Hyvänä esimerkkinä tästä voidaan pitää viimeistä, viiden klusterin analyysiä, jossa pystytään selkeästi erottelamaan asiakkaista joukko, joka hyödyntää pankkia ainoastaan sijoitustoimintaan. Samalla on kuitenkin tärkeää pitää mielessä, että aineistokoot rajoittavat merkittävästi klusterien maksimimäärää.