

Harjoitustyö TILM3702

Työn voi tehdä haluamallaan tilastollisella ohjelmistolla.

Kirjoita harjoitustyön raportti erilliseen dokumenttiinsa, jonka voit tallentaa esim. word- tai pdf-muodossa. Tulosten tulkintaan kannattaa kiinnittää huomiota, esim. pelkkä huomio siitä, että jokin yhteys on merkitsevä, ei riitä. Tulosteet liitetään erikseen joko yhtenä tai useampana liitteenä. **Työn palautus Moodlen palautuslaatikkoon.**

Numeeristen vastemuuttujien mallitus:

Elinolo2020 (Tilastokeskuksen elinolotutkimuksen aineisto, N=2199)

Kukin opiskelija puolestaan poimii 800 kokoisen satunnaisotoksen kyseisestä datasta seuraavalla tavalla:

```
library(foreign)
ht1.dat<-read.spss("elinolo2020.sav", to.data.frame=TRUE)
attach(ht1.dat)

# Suluissa olevan 1:n tilalle oma opiskelijanumero
set.seed(1)

# 800 kokoinen otos
oma.otos1<-ht1.dat[sample(nrow(ht1.dat), 800), ]
attach(oma.otos1)
```

1. Regressiomalli

Tutki, onko kotitalouden kuluttajayksiköiden lukumäärällä, asumismenoilla yhteensä ja alueella asumisajalla yhteyttä asunnon pinta-alaan.

2. Toistomittausmalli

Toistomittausaineisto2020 (7 maasta kerätty aineisto potilaan ohjauksesta, N=1299)

Kukin opiskelija puolestaan poimii 500 kokoisen satunnaisotoksen kyseisestä datasta seuraavalla tavalla:

```
library(foreign)
ht2.dat<-read.spss("Toistomittausaineisto2020.sav", to.data.frame=TRUE)
attach(ht2.dat)

# Suluissa olevan 1:n tilalle oma opiskelijanumero
set.seed(1)

# 500 kokoinen otos
oma.otos2<-ht2.dat[sample(nrow(ht2.dat), 500), ]
attach(oma.otos2)
```

Tutkijalla on hypoteesi, että potilaan mielestä saatu ohjaus leikkauksen jälkeen toiminnallista seikoista (Functional_M2) on ollut vähäisempää kuin odotettu ennen leikkausta (Functional_M1). Eli keskiarvo toisessa mittauksessa on matalampi. Lisäksi kiinnostaa se, onko tuo ero mittausten välillä erilainen sukupuolittain.

Tutki saavatko nämä tutkimushypoteesit tukea mallittamalla aineisto toistettujen mittausten varianssianalyysillä.

Huom. Numeeristen vastemuuttujien mallituksessa on varianssianalyysien osalta tehtävä tarvittava kuvaileva tarkastelu ja regressiomallissa yhteyksien suoraviivaisuuksien tarkastelu ja jäännöstarkastelu.

Kategoristen vastemuuttujien mallitus:

EK2011 (eduskuntavaaliaineisto vuodelta 2011, N=1318)

Kukin opiskelija puolestaan poimii 800 kokoisen satunnaisotoksen kyseisestä datasta seuraavalla tavalla:

```
library(foreign)
ht3.dat<-read.spss("EK2011.sav", to.data.frame=TRUE)
attach(ht3.dat)
# Suluissa olevan 1:n tilalle oma opiskelijanumero
set.seed(1)
# 800 kokoinen otos
oma.otos3<-ht3.dat[sample(nrow(ht3.dat), 800), ]
attach(oma.otos3)
```

Kaksiluokkainen selitettävä muuttuja

1. Tutki muuttujien sukupuoli (d2) ja ikä yhteyttä työttömyyteen viimeisen 12 kuukauden aikana (d32) käyttämällä logistista regressiomallia.
2. Mitkä muuttujat selittävät työttömyyttä ?

Tulkitse yhteydet OR:ien avulla. Raportoi myös luottamusvälit OR:ille.

Mikä on mallin Nagelkerke selitysaste ?

Monimuuttujamenetelmät:

pankkiotos2020 (todellinen asiakasaineisto, N=2453)

Kukin opiskelija puolestaan poimii 1600 kokoisen satunnaisotoksen kyseisestä datasta seuraavalla tavalla:

```
library(foreign)
ht4.dat<-read.spss("pankkiotos2020.sav", to.data.frame=TRUE)
attach(ht4.dat)

# Suluissa olevan 1:n tilalle oma opiskelijanumero
set.seed(1)

# 1600 kokoinen otos
oma.otos4<-ht4.dat[sample(nrow(ht4.dat), 1600), ]
attach(oma.otos4)
```

Muuttujien ryhmittely

1. Muodosta pääkomponenttianalyysillä luokitelluista muuttujista (41 kpl : autom_lainan_perinta_luok - kulutusluotot1_luok) pääkomponentteja ominaisarvokriteerin mukaan. (Promax-rotaatio)
2. Talleta havaintomatriisiin uusiksi muuttujiksi pääkomponenttipistemäärät.
3. Nimeä uudet muuttujat (pääkomponentteihin latautuneiden muuttujien mukaisesti).

Havaintojen ryhmittely

4. Käytä näitä uusia muuttujia klusterianalyysissä, jossa muodostat asiakasryhmiä K-means menetelmällä lähtien kahdesta klusterista viiteen tai kuuteen klusteriin saakka. Kuvaile muodostamiasi ryhmiä.