


TILM3702 — Tutoriaali 1

March 15, 2024

Tehtävä 3

Tarkastellaan aineistoa tulkitsemalla R:llä muodostettuja keskeisiä tunnuslukuja (keskiarvo, mediaani, keskihajonta) sekä laatikko-janakuvaajia:


```
> # keskiarvot
> mean(tvsaasto)
[1] 6146.387
> mean(oma_tulo)
[1] 1173.42
>
> # mediaanit
> median(tvsaasto)
[1] 5631
> median(oma_tulo)
[1] 1102
>
> # keskihajonnat
> sd(tvsaasto)
[1] 3718.194
> sd(oma_tulo)
[1] 435.2534
```



Tuloksista on välittömästi huomattavissa muuttujien skaalaero. Säästöjä kuvaavan muuttujan *tvsaasto* keskihajonta on merkittävästi suurempi kuin nettotuloja kuvaavan muuttujan *oma_tulo*. Skaala-eroista huolimatta laatikko-janakuvaajia tutkimalla voidaan kuitenkin huomata yhtäläisyyksiä muuttujien jakaumien välillä. Voidaan siis jossain määrin huomata, että nettotulojen ja säästöjen välillä on vähintäänkin korrelaatiota.

Tehtävä 4

Piirretään nettotulojen (*oma_tulo*) ja tutkimusvuoden säästöjen (*tvsaasto*) hajontakuvio ja lasketaan Pearsonin sekä Spearmanin otoskorrelaatiokertoimien arvot:



```
> # Pearson
> cor(oma_tulo, tvsaasto)
[1] 0.146168
> # Spearman
> cor(oma_tulo, tvsaasto, method="spearman")
[1] 0.2165046
```

Koska sekä Pearsonin että Spearmanin otoskorrelaatiokertoimet ovat suhteellisen matalia, ei muuttujien välillä ole vahvaa lineaarista tai monotonista riippuvuutta. Spearmanin korrelaatiokertoimen ollessa noin 0.217 on muuttujien välillä jonkinlaista monotonista riippuvuutta, mutta kuitenkin suhteellisen kevyttä. Muuttujien välinen riippuvuus onkin siis enemmän monotonista kuin lineaarista, koska $0.217 > 0.146$.

Tehtävä 5

Sovitetaan R:llä lineaarinen regressiomalli, jossa nettotulot (*oma_tulo*) ovat selittäjänä ja säästöt (*tvsaasto*) vasteena:

```
Call:
lm(formula = tvsaasto ~ oma_tulo)

Residuals:
    Min       1Q   Median       3Q      Max
-5314.1 -2832.3  -861.4  1867.5 12161.6

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4681.191    869.0404   5.387 2.76e-07 ***
oma_tulo      1.2487     0.6947   1.798  0.0743 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3691 on 148 degrees of freedom
Multiple R-squared:  0.02137,    Adjusted R-squared:  0.01475
F-statistic: 3.231 on 1 and 148 DF,  p-value: 0.07429
```

Sovitteen kuvauksesta nähdään mallin muuttujien kertoimet $\beta_0 = 4681.1911$ ja $\beta_1 = 1.2487$, joiden perusteella voidaan muodostaa mallille yhtälö

$$y = \beta_0 + \beta_1 x = 4681.1911 + 1.2487x.$$

Saadun yhtälön perusteella voidaan laskea kuinka paljon säästöt keskimäärin kasvavat, kun nettotulot kasvavat 350 euroa:


$$1.2487x = 1.2487 \cdot 350 = 437.045$$

ja paljonko henkilöllä, jonka nettotulot ovat 1500 euroa, on keskimäärin säästöjä:

$$4681.1911 + 1.2487x = 4681.1911 + 1.2487 \cdot 1500 = 6554.2411 \approx 6554.24.$$

Mallin selitysaste $R^2 = 1 - \frac{SSE}{SST} = 0.02137$ viittaa siihen, että malli selittää vain noin 2.14 % vaste-muuttujan *tvsaasto* vaihtelusta eli malli on ts. suhteellisen huono.

F-yleisesti $F \sim F_{p,n-p-1}$ kuvaa mallin tilastollista merkitsevyyttä nollahypoteesilla $H_0 : \beta_1 = \dots = \beta_p = 0$. Sovitteen kuvauksen perusteella $F_{1,148} = 3.231$ ja sille $p = 0.07429$ eli mikäli merkitsevyyssoksi valittaisiin tyypillinen 5 % eli 0.05, olisi p -arvo hieman sen yli ja näin ollen mallin tilastollinen merkitsevyys olisi heikko. Koska kyse on yhden selittäjän mallista, pätee sama p -arvo (sekä sen merkitsevyydestä tehdyt tulkinnot) myös ainoan selittäjän tilastollista merkittävyyttä analysoitaessa.



Jo R:n tuottamasta mallin yhteenvedosta nähdään viitteitä residuaalien epäsymmetriaan, sillä kvartiilit eivät ole itseisarvoiltaan yhtäsuuria. Tutkimalla residuaalien hajontakuviota voidaan lisäksi nähdä viitteitä siihen, että pienillä soviteen arvoilla residuaalien hajonta on suurempaa. Residuaalien jakaumaa esittävästä histogrammista puolestaan voidaan nähdä jakauman epäsymmetrisyys nollan ympärillä (jakauma ei siis muistuta normaalijakauman kellokäyrää, joka viittaisi korkeaan symmetriaan). Symmetrian sijaan residuaalit näyttäisivät olevan hieman vinoja oikealle eli on olemassa muutamia suuria positiivisia residuaaleja.

Tehtävä 6

Sovitetaan jälleen R:llä lineaarinen regressiomalli, jossa selittäjinä ovat *oma_tulo*, *ika*, *evsaasto* ja *tyotilan*. Vasteena on jälleen *tvsaasto*:

```
Call:
lm(formula = tvsaasto ~ oma_tulo + ika + evsaasto + tyotilan)

Residuals:
    Min       1Q   Median       3Q      Max
-5398.1  -761.1   316.3  1220.3  4675.8

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -5.289e+03  7.694e+02  -6.874 1.71e-10 ***
oma_tulo       8.924e-01  4.587e-01   1.945  0.0536 .
ika           2.087e+02  1.954e+01  10.679 < 2e-16 ***
evsaasto       3.063e-01  4.066e-02   7.534 4.87e-12 ***
tyotilantyyossa 2.916e+02  4.125e+02   0.707  0.4807
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1941 on 145 degrees of freedom
Multiple R-squared:  0.7349,    Adjusted R-squared:  0.7275
F-statistic: 100.5 on 4 and 145 DF,  p-value: < 2.2e-16
```


Mikäli vertailtaisiin kahta eri henkilöä, joiden ikäero olisi 10 vuotta, olisi säästöjen ero mallin perusteella keskimäärin

$$\Delta y = 208.7 \cdot 10 = 2087.$$

Muuttujan *oma_tulo* kerroin 0.8924 osoittaa että kyseisen selittäjän ja vastemuuttujan välillä on positiivista riippuvuutta. Kun henkilön tulot kasvavat yhdellä, kasvaa vastemuuttuja *tvsaasto* 0.8924 yksikköä. Merkitys vastemuuttujan suuruuteen on siis suhteellisen pientä (vrt. esim. *ika*-selitemuuttujan vaikutukseen).

Malli on tilastollisesti merkitsevä, sillä F -testiarvo on suuri ja mallin p -arvo huomattavasti alle yleisesti käytetyn merkitsevyystason 0.05. Pieni p -arvo osoittaa F -testisuureen nollahypoteesia $H_0 : \beta_1 = \dots = \beta_p = 0$ vastaan eli sen perusteella mallin selittäjillä on tilastollista vaikutusta vastemuuttujan arvoon.

Mallin yksittäisten selittäjien tilastollinen merkitsevyys nähdään selittäjien p -arvoista, jotka ovat kautta linjan hyvin pieniä (alle merkitsevyystason 0.05) lukuun ottamatta *tyotilan*-selittäjän saamaa arvoa 0.4807. Lähes 0.5 p -arvo viittaa siihen, että muuttujan tilastollinen merkitsevyys on erittäin pieni ja se on mallin kannalta turha (koska sillä ei ole merkittävää vaikutusta vastemuuttujan arvoon).



Residuaalien maksimi- ja minimiarvojen perusteella arvot ovat jakautuneet suhteellisen tasaisesti nollan ympärille. Sama nähdään myös residuaalien jakaumaa kuvaavasta histogrammista, jossa toisaalta on myös hienoista kallistumaa vasemmalle (ei kuitenkaan tulkinnan kannalta merkittävässä määrin). Residuaalit jakautuvat siis suhteellisen normaalisti nollan ympärille.

Residuaalien hajontakuviosta on nähtävissä, että residuaalien hajonta on suhteellisen vakio eri sovitetten arvoilla, vaikkakin hieman kasvava suurempia sovitetten arvoja kohti.

Tehtävä 7

Asetetaan tehtävänannon perusteella merkitsevyyden rajoiksi $t \geq 2$ tai $p \leq 0.05$. Tarkastellaan tämän perusteella tehtävässä 6 sovitetun regressiomallin yhteenvedoa tältä pohjalta.

```
Call:
lm(formula = tvsaasto ~ oma_tulo + ika + evsaasto + tyotilan)

Residuals:
    Min       1Q   Median       3Q      Max
-5398.1  -761.1   316.3  1220.3  4675.8

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -5.289e+03  7.694e+02  -6.874 1.71e-10 ***
oma_tulo      8.924e-01  4.587e-01   1.945  0.0536 .
ika           2.087e+02  1.954e+01  10.679 < 2e-16 ***
evsaasto      3.063e-01  4.066e-02   7.534 4.87e-12 ***
tyotilantyossa 2.916e+02  4.125e+02   0.707  0.4807
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1941 on 145 degrees of freedom
Multiple R-squared:  0.7349,    Adjusted R-squared:  0.7275
F-statistic: 100.5 on 4 and 145 DF,  p-value: < 2.2e-16
```

Yhteenvedosta nähdään, että selittäjien *oma_tulo* ja *tyotilan* p -arvot ovat yli määritellyn merkitsevyystason ja vastaavasti niiden t -arvot ovat alle määritellyn tason. Kun nämä selittäjät ovat sisällytettynä malliin, on mallin selitysaste $R^2 = 0.7349$ ja muokattu selitysaste $\text{adj-}R^2 = 0.7275$. Selittäjät poistamalla muuttuu malli seuraavasti:

```
Call:
lm(formula = tvsaasto ~ ika + evsaasto)

Residuals:
    Min       1Q   Median       3Q      Max
-5537.0  -884.8   383.3  1252.2  4736.9

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -4.270e+03  6.170e+02  -6.921 1.29e-10 ***
ika          2.158e+02  1.916e+01  11.262 < 2e-16 ***
evsaasto     2.955e-01  4.073e-02   7.254 2.14e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1989 on 147 degrees of freedom
Multiple R-squared:  0.7178,    Adjusted R-squared:  0.7139
F-statistic: 186.9 on 2 and 147 DF,  p-value: < 2.2e-16
```

Mallin uusi selitysaste on siis $R^2 = 0.7178$ ja uusi muokattu selitysaste $\text{adj-}R^2 = 0.7139$. Voidaan siis huomata, että vaikka kokonaisuudessaan selitysaste on laskenut hieman aiemmasta sovituksesta, on tällä sovituksella ero $|R^2 - \text{adj-}R^2|$ pienempi.

Uuden sovituksen myötä jäljelle jäävistä selittäjistä *ika*:n kerroin kasvaa hieman, kun taas *evsaasto*:n kerroin laskee hieman.