

Tilastollisten mallien peruskurssi 2024

Tutoriaali 1

14.3.2024

Nämä harjoitukset pohjautuvat Jouko Katajiston harjoituksiin vuodelta 2023. Olen kuitenkin tehnyt jotakin pieniä muutoksia.

Jokaisessa kohdassa tuloksia pyydetään tulkitsemaan. Tarkoitus ei kuitenkaan ole tehdä kovin syvällisiä tulkintoja, vaan lähinnä sanoa suomeksi (ei siis pelkällä matematiikan kielellä), mitä näkee. Tulkinta pitää kuitenkin perustella tarvittavilla luvuilla tai kuvilla.

Palauta Moodlessa olevaan palautuslaatikkoon *lyhyt* vastauksesi tehtäviin yhdessä pdf (tai esim. word) -dokumentissa huomiseen perjantaihin 15.3. klo 23.59 mennessä.

Alkutoimet

1. Kopioi moodlesta `demoaineisto2015r.sav` ja R-koodipohja johonkin kansioon omalla koneellasi. Käynnistä RStudio ja vaihda työkansio siksi, mihin kopioit moodlesta tiedostot. (Session - Set Working Directory - Choose Directory). Avaa R-koodipohja ja aloita työskentely.
2. Laita koodipohjan kohtaan `opiskelijanumero` opiskelijanumerosi tai muu kiva numerosarja. Aja koodirivit, joilla luet aineiston.

Aineiston kuvailu

3. Tarkastele muuttujien `tvsaasto` ja `oma_tulo` jakaumia (muun muassa) tunnuslukujen ja laatikko-janakuvaajan kautta. Tulkitse tuloksia.
4. Tarkastele omien nettotulojen (`oma_tulo`) yhteyttä tutkimusvuoden säästöihin (`tvsaasto`). Piirrä hajontakuvio ja laske korrelaatiokertoimien (Pearson ja Spearman) arvot. Tulkitse tuloksia: Millainen muuttujien yhteisjakauma on? Millainen on muuttujien välinen riippuvuus (esim. korrelaatiokertoimien kautta)?

Yhden selittäjän malli

5. Sovita lineaarinen regressiomalli, jossa selittäjänä on omat nettotulot (`oma_tulo`) ja vasteena tutkimusvuoden säästöt (`tvsaasto`). Tulkitse mallin tulosteita.
- Mikä on mallin yhtälö (estimoiduilla kertoimilla)?
 - Jos henkilön nettotulot kasvavat 350 euroa, paljonko keskimäärin hänen säästönsä mallin mukaan kasvavat?
 - Paljonko keskimäärin on säästöjä henkilöllä, jonka nettotulot ovat 1500 euroa?
 - Mikä on mallin selitysaste?
 - Onko malli tilastollisesti merkitsevä?
 - Onko selittäjä tilastollisesti merkitsevä?
 - Onko jäännösten hajonta vakio eri sovitteen arvoilla?
 - Onko jäännösten jakauma symmetrinen nollan suhteen?

Useamman selittäjän malli

6. Sovita lineaarinen regressiomalli, jossa selittäjinä ovat omat nettotulot (`oma_tulo`), ikä (`ika`), edellisen vuoden säästöt (`evsaasto`) ja työtilanne (`tyotilan`) sekä vasteena tutkimusvuoden säästöt (`tvsaasto`). Tulkitse mallin tulosteita.
- Jos kahden muuten samanlaisen henkilön ikäero on 10 vuotta, paljonko toisella on keskimäärin enemmän säästöjä kuin toisella?
 - Miten tulkitsisit muuttujan `oma_tulo` kerrointa?
 - Mikä on mallin selitysaste?
 - Onko malli tilastollisesti merkitsevä?
 - Ovatko selittäjät tilastollisesti merkitseviä?
 - Onko jäännösten hajonta vakio eri sovitteen arvoilla?
 - Onko jäännösten jakauma symmetrinen nollan suhteen?
7. Poista mallista mahdolliset epämerkitsevät selittäjät (Olkoon merkitsevyyden rajana $t \geq 2$ tai $p \leq 0.05$).
- Mikä on mallin selitysaste?
 - Miten muiden selittäjien kertoimet muuttuvat?