

TILM3702 — Tutoriaali 2 (osa 2)

March 24, 2024

Tehtävä 2

Lähdetään tutkimaan hajontojen yhtäsuuruutta sekä Bartlettin testin että Levenen testin avulla:

```
> bartlett.test(oma_tulo~taltyyt)

Bartlett test of homogeneity of variances

data: oma_tulo by taltyyt
Bartlett's K-squared = 5.9084, df = 3, p-value = 0.1162

> leveneTest(oma_tulo~taltyyt)
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  3  3.2282 0.02357 *
    197
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Bartlettin testin perusteella p-arvoksi saadaan 0.1162, joka on yli määritellyn merkitsevyystason 0.05 eli testin perusteella hajonnat ovat kutakuinkin yhtäsuuret. Levenen testin perusteella p-arvoksi saadaan puolestaan 0.02357, joka on alle määritellyn merkitsevyystason. Levenen testin perusteella tyytyväisyysluokkien populaatiohajontojen välillä on siis tilastollisesti merkitseviä eroja. Tehdään yksisuuntainen varianssianalyysi kuitenkin Bartlettin testin tulosten, eli hajontojen yhtäsuuruuden, perusteella:

```
> malli1 <- lm(oma_tulo~taltyyt)
> malli_lm <- aov(malli1)
> summary(malli_lm)


      Df Sum Sq Mean Sq F value    Pr(>F)
taltyyt   3  8254276 2751425   18.18 1.88e-10 ***
Residuals 197 29820026  151371
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Yksisuuntaisen varianssianalyysin F-testin p-arvoksi saadaan näin ollen $1.88 \cdot 10^{-10}$ eli tutkittavien tyytyväisyysluokkien populaatiokeskiarvoissa on tilastollisesti merkitseviä eroja. Tutkitaan vielä Tukeyn monivertailumenetelmän avulla yksittäisten vertailuparien tilastollista merkitsevyyttä:

```
> tukey.test <- TukeyHSD(malli_lm)
> tukey.test
Tukey multiple comparisons of means
95% family-wise confidence level

Fit: aov(formula = malli1)

$taltyyt
              diff            lwr            upr      p adj
melko tyytyväinen-erittäin tyytyväinen -50.67857 -333.2553  231.898176 0.9666501
melko tyytymaton-erittäin tyytyväinen -298.82051 -594.2775   -3.363572 0.0463104
erittäin tyytymaton-erittäin tyytyväinen -530.44667 -827.2236  -233.669733 0.0000389
melko tyytymaton-melko tyytyväinen -248.14194 -426.0240  -70.259846 0.0021479
erittäin tyytymaton-melko tyytyväinen -479.76810 -659.8342  -299.702040 0.0000000
erittäin tyytymaton-melko tyytymaton -231.62615 -431.2983  -31.953997 0.0157221
```



Testin tulosteesta voidaan lukea seuraavat tulokset ja niistä tehdyt päätelmät:

- Erittäin tyytyväiset vs. melko tyytyväiset: $p \approx 0.967$ (ei merkitsevä)
- Erittäin tyytyväiset vs. melko tyytymättömät: $p \approx 0.0463$ (merkitsevä)
- Erittäin tyytyväiset vs. erittäin tyytymättömät: $p \approx 3.89 \cdot 10^{-5}$ (merkitsevä)

- Melko tyytyväiset vs. melko tyytymättömät: $p \approx 0.00215$ (merkitsevä)
- Melko tyytyväiset vs. erittäin tyytymättömät: $p = 0$ (merkitsevä)
- Melko tyytymättömät vs. erittäin tyytymättömät: $p \approx 0.0157$ (merkitsevä)

Tarkastellaan sitten työtilanteen (*tyotilan*) ja taloudellisen tyytyväisyyden (*taltyyt*) yhteyttä omiin nettotuloihin (*oma_tulo*) kaksisuuntaisen varianssianalyysin kautta. Tehdään ensin kullekin selitettävien muuttujien luokkien yhdistelmälle normaalijakaumatestit ja piirretään näistä laatikko-janakuviot taloudellisen tyytyväisyyden luokissa omien nettotulojen jakaumista (työttömille sekä työssäoleville):

```
> # Keskiarvot soluittain (2)
> with(dat, tapply(oma_tulo, list(tyotilan, taltyyt), mean))
      erittain tyytyväinen melko tyytyväinen melko tyytymaton erittain tyytymaton
tyoton      1201.500      999.5769      946.3667      825.3488
tyossa      1437.077      1514.3103      1325.6818      1181.5714
> # Mediaanit soluittain (2)
> with(dat, tapply(oma_tulo, list(tyotilan, taltyyt), median))
      erittain tyytyväinen melko tyytyväinen melko tyytymaton erittain tyytymaton
tyoton      1201.5      935.5      945      730
tyossa      1326.0      1468.0      1292      1097
> # Keskihajonnat soluittain (2)
> with(dat, tapply(oma_tulo, list(tyotilan, taltyyt), sd))
      erittain tyytyväinen melko tyytyväinen melko tyytymaton erittain tyytymaton
tyoton      79.90307      255.1887      275.4617      351.3359
tyossa      288.84842      406.4278      355.6563      217.9532
```

Muuttujien tunnusluvuista voidaan tehdä muutamia huomioita. Esimerkiksi työssäkäyvillä sekä keskiarvoiset että mediaaninettotulot ovat säännönmukaisesti korkeammat joka luokassa kuin työttömällä. Toisaalta työssäkäyvillä myös keskihajonta on suurempaa lukuun ottamatta tuloihinsa erittäin tyytymättömiä.


Tutkittavien jakaumien normaalisuusoletusta voidaan testata Shapiro-Wilkin testillä, jonka avulla ensin tutkitaan työssäkäyvien ryhmää:

```
$`erittain tyytyväinen`
      Shapiro-Wilk normality test
data:  X[[i]]
W = 0.81151, p-value = 0.00937

$`melko tyytyväinen`
      Shapiro-Wilk normality test
data:  X[[i]]
W = 0.9753, p-value = 0.2825

$`melko tyytymaton`
      Shapiro-Wilk normality test
data:  X[[i]]
W = 0.92419, p-value = 0.09287

$`erittain tyytymaton`
      Shapiro-Wilk normality test
data:  X[[i]]
W = 0.90218, p-value = 0.3444
```



Tuloksista voidaan nähdä, että ainoastaan 'erittäin tyytyväinen' -luokan p-arvo 0.00937 on alle merkitsevyystason 0.05. Toteutetaan sitten sama testi työttömien osuudelle (josta myös poistetaan erittäin tyytyväisten osuus pienen lukumäärän takia):

```
$`erittain tyytyväinen`
NULL

$`melko tyytyväinen`

      Shapiro-Wilk normality test

data:  X[[i]]
W = 0.83256, p-value = 0.0006651

$`melko tyytymätön`


      Shapiro-Wilk normality test

data:  X[[i]]
W = 0.96417, p-value = 0.3939

$`erittain tyytymätön`

      Shapiro-Wilk normality test

data:  X[[i]]
W = 0.83702, p-value = 2.501e-05
```



Nyt puolestaan sekä 'erittain tyytymätön' että 'melko tyytyväinen' -luokkien p-arvot 0.0006651 ja $2.501 \cdot 10^{-5}$ ovat alle merkitsevyystason 0.05. Kaiken kaikkiaan normaalijakaumaoletuksen voidaan kuitenkin olettaa pitävän paikkansa sekä työttömille että työllisille, koska suurin osa tyytyväisyysryhmistä on normaalisti jakautuneita.

Tehtävä 3

Tutkitaan hajontojen yhtäsuuruusoletusta R:ssä Levenen testin avulla:

```
> leveneTest(oma_tulo~taltyyt*tyotilan)
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  7  2.2532 0.03171 *
      193
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Levenen testillä saatu p-arvo 0.03171 on alle määritellyn merkitsevyystason eli testin perusteella voidaan olettaa hajontojen olevan keskenään erisuuruiset. Siirrytään testaamaan mallin yksittäisten selittäjien tilastollista merkitsevyyttä erikseen sekä niiden yhteisvaikutusta:

```
> anova(lm(dat$oma_tulo~taltyyt*tyotilan))
Analysis of Variance Table

Response: dat$oma_tulo
      Df Sum Sq Mean Sq F value    Pr(>F)
taltyyt    3  8254276  2751425  23.7306 4.061e-13 ***
tyotilan    1  7183216  7183216  61.9540 2.465e-13 ***
taltyyt:tyotilan 3  259544   86515   0.7462  0.5258
Residuals 193 22377265  115944
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Testin tuloksista nähdään, että sekä taloudellinen tyytyväisyys että työtilanne ovat tilastollisesti merkittäviä selittäjiä p-arvoilla $4.061 \cdot 10^{-13}$ ja $2.465 \cdot 10^{-13}$. On kuitenkin selkeästi nähtävissä, että kyseisten selittäjien yhteisvaikutus ei ole tilastollisesti merkitsevä ($p = 0.5258$).

Tilaston kannalta tämä tarkoittaa siis sitä, ettei työttömien ja työllisten välillä ole merkittäviä eroja eri taloudellista tyytyväisyyttä kuvaavien luokkien suhteen. Tämä nähdään myös keskiarvojen profiilikuviossa, jossa tulokäyrät reagoivat samalla tavalla eri tyytyväisyysluokissa molemmille työllisyysryhmille.




Tehtävä 4

Vaihdetaan nyt merkittävästi pienempään aineistoon *demo2_2015r.sav*, joka kuvaa kahden tietyn tehtaan hylättyjen tuotteiden lukumääriä vuorokohtaisesti (*aamu*, *ilta*, *yo*):

```
> with(dat2, tapply(hyl, list(tehdas, vuoro), mean))
      aamu  ilta   yo
tehdas1 102.5 101.75 101.75
tehdas2 100.5 109.50 117.25
```

Keskiarvoista on havaittavissa, että tehtaassa 1 hylättyjen tuotteiden lukumäärä on huomattavasti tasaisempi, kun taas tehtaassa 2 hylättyjen tuotteiden määrät ovat huomattavasti korkeampia yö- ja iltavuoroissa aamuvuoroihin verrattuna. Tätä voidaan havainnollistaa myös Tukeyn laatikko-jana-kuviolla:



Hylättyjen tuotteiden jakaumien normaalisuusoletusta voidaan tutkia Shapiro-Wilkin testillä (vasemmalla *tehdas1*, oikealla *tehdas2*):

<pre>\$aamu Shapiro-Wilk normality test data: X[[i]] W = 0.86337, p-value = 0.2725 \$ilta Shapiro-Wilk normality test data: X[[i]] W = 0.97137, p-value = 0.85 \$yo Shapiro-Wilk normality test data: X[[i]] W = 0.92614, p-value = 0.5719</pre>	<pre>\$aamu Shapiro-Wilk normality test data: X[[i]] W = 0.99291, p-value = 0.9719 \$ilta Shapiro-Wilk normality test data: X[[i]] W = 0.9984, p-value = 0.9951 \$yo Shapiro-Wilk normality test data: X[[i]] W = 0.96307, p-value = 0.7982</pre>
---	--

Kuten Shapiro-Wilk-testin tuloksista nähdään, ei kummankaan tehtaan jakaumien kohdalla ole syytä kyseenalaistaa normaalisuusoletusta, sillä vuorojen p-arvot ylittävät merkitsevyystason 0.05 selvästi.

Tehtävä 5

Tehdään aineistolle kaksisuuntainen varianssianalyysi. Hajontojen yhtäsuuruusoletus voidaan tarkistaa Levenen testillä:

```
> leveneTest(hyl~tehdas*vuoro)
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  5  0.2444 0.9372
      18
```

Kuten Levenen testistä nähdään, on saatu p-arvo 0.9372 hyvin suuri, jonka johdosta havaintojen yhtäsuuruusoletus on selkeästi voimassa.

```
> anova(lm(hyl~tehdas*vuoro))
Analysis of Variance Table


Response: hyl
      Df Sum Sq Mean Sq F value    Pr(>F)
tehdas   1 301.04  301.042   83.046 3.656e-08 ***
vuoro     2  256.08  128.042   35.322 5.870e-07 ***
tehdas:vuoro 2  307.58  153.792   42.425 1.540e-07 ***
Residuals 18   65.25    3.625
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Tämän jälkeen tehdystä kaksisuuntaisesta varianssianalyysistä saadaan seuraavat p-arvot ja niistä voidaan muodostaa päätelmät:

- Selittäjä *tehdas*: $p = 3.656 \cdot 10^{-8}$ (merkitsevä)
- Selittäjä *vuoro*: $p = 5.87 \cdot 10^{-7}$ (merkitsevä)
- Yhteisvaikutus: $p = 1.540 \cdot 10^{-7}$ (merkitsevä)

Tehtävä 6

Tutkitaan lopuksi työvuorojen välisten vertailujen tilastollista merkitsevyyttä (kummassakin tehtaassa). Keskiarvojen profileista muodostetusta kuvaajasta nähdään, että sekä tehtaassa että työvuoron tilastolliseen merkitsevyyteen selittäjänä vaikuttavat merkittävästi tehtaassa 2 vuorojen väliset erot:



Keskiarvojen profiilien perusteella voidaankin todeta, että todellisiin yhteyksien tutkiminen edellyttää Tukeyn yhdysvaikeutustestin tekemistä:


```
> fit2 <- lm(hyl~tehdas*vuoro, data=dat2)
> malli_lm2 <- aov(fit2)
> tukey.test2 <- TukeyHSD(malli_lm2)
> tukey.test2
Tukey multiple comparisons of means
 95% family-wise confidence level

Fit: aov(formula = fit2)

$tehdas
      diff      lwr      upr p adj
tehdas2-tehdas1 7.083333 5.450325 8.716341 0

$vuoro
      diff      lwr      upr      p adj
ilta-aamu 4.125 1.695413 6.554587 0.0011100
yo-aamu 8.000 5.570413 10.429587 0.0000003
yo-iltä 3.875 1.445413 6.304587 0.0019731

$`tehdas:vuoro`
      diff      lwr      upr      p adj
tehdas2:aamu-tehdas1:aamu -2.00 -6.27856 2.27856 0.6771101
tehdas1:iltä-tehdas1:aamu -0.75 -5.02856 3.52856 0.9926410
tehdas2:iltä-tehdas1:aamu 7.00 2.72144 11.27856 0.0007328
tehdas1:yo-tehdas1:aamu -0.75 -5.02856 3.52856 0.9926410
tehdas2:yo-tehdas1:aamu 14.75 10.47144 19.02856 0.0000000
tehdas1:iltä-tehdas2:aamu 1.25 -3.02856 5.52856 0.9338558
tehdas2:iltä-tehdas2:aamu 9.00 4.72144 13.27856 0.0000367
tehdas1:yo-tehdas2:aamu 1.25 -3.02856 5.52856 0.9338558
tehdas2:yo-tehdas2:aamu 16.75 12.47144 21.02856 0.0000000
tehdas2:iltä-tehdas1:iltä 7.75 3.47144 12.02856 0.0002320
tehdas1:yo-tehdas1:iltä 0.00 -4.27856 4.27856 1.0000000
tehdas2:yo-tehdas1:iltä 15.50 11.22144 19.77856 0.0000000
tehdas1:yo-tehdas2:iltä -7.75 -12.02856 -3.47144 0.0002320
tehdas2:yo-tehdas2:iltä 7.75 3.47144 12.02856 0.0002320
tehdas2:yo-tehdas1:yo 15.50 11.22144 19.77856 0.0000000
```



Tulosteesta voidaan poimia kiinnostavat parit ja tehdä niille saaduista p-arvoista päätelmät tilastollisesta merkitsevyydestä:

- Tehdas 1 aamuvuoro vs. iltavuoro: $p \approx 0.993$
- Tehdas 1 aamuvuoro vs. yövuoro: $p \approx 0.993$
- Tehdas 1 iltavuoro vs. yövuoro: $p = 1$
- Tehdas 2 aamuvuoro vs. iltavuoro: $p \approx 3.67 \cdot 10^{-5}$
- Tehdas 2 aamuvuoro vs. yövuoro: $p = 0$
- Tehdas 2 iltavuoro vs. yövuoro: $p \approx 2.32 \cdot 10^{-4}$