

TILM3702 — Tutoriaali 4

Arttu Einistö

April 10, 2024

Tehtävä 2

Sovitetaan logistista binaarista regressiomallia, jossa numeerisina selittäjinä ovat omat nettotulot ja ikä, kategorisina omistusasunto ja koulutus sekä selitettävänä työtilanne.

```
Call:
glm(formula = tyotilan ~ oma_tulo + ika + omistusa + koulutus,
     family = binomial, data = dat)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   -8.5907564   1.7452068  -4.922 8.55e-07 ***
oma_tulo        0.0055025   0.0008223   6.692 2.20e-11 ***
ika            0.0683556   0.0206775   3.306 0.000947 ***
omistusaon    -0.0765737   0.3963730  -0.193 0.846813
koulutuslukio  0.8682461   1.3230154   0.656 0.511655
koulutuskoulututkinto 0.1510791  1.2639304   0.120 0.904855
koulutusamk-tutkinto -0.7778812  1.2770861  -0.609 0.542454
koulutuskorkeakoulututkinto -0.8590417  1.3664370  -0.629 0.529563
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 278.64  on 200  degrees of freedom
Residual deviance: 166.68  on 193  degrees of freedom
AIC: 182.68

Number of Fisher Scoring iterations: 5
```

R:llä sovitetun mallin yhteenvedosta voidaan lukea käytettyjen selittäjien p-arvot sekä päätellä niistä selittäjien tilastollinen merkitsevyys:

- *oma_tulo*: $p = 8.55 \cdot 10^{-7} < 0.001$ (merkitsevä)
- *ika*: $p = 0.000947 < 0.001$ (merkitsevä)
- *koulutus*: $p = 0.5117$, $p = 0.9049$, $p = 0.5425$, $p = 0.5296$ (ei merkitsevä)
- *omistusaon*: $p = 0.8468$ (ei merkitsevä)

	OR	2.5 %	97.5 %
(Intercept)	0.0001858155	3.889914e-06	0.004473988
oma_tulo	1.0055176623	1.004034e+00	1.007293384
ika	1.0707459727	1.029778e+00	1.117309278
omistusaon	0.9262846857	4.234349e-01	2.018743544
koulutuslukio	2.3827280043	1.996079e-01	57.878463906
koulutuskoulututkinto	1.1630886841	1.092808e-01	26.295091564
koulutusamk-tutkinto	0.4593783291	4.168635e-02	10.534078146
koulutuskorkeakoulututkinto	0.4235678015	3.171368e-02	10.798789709

R:n tulosteesta voidaan nyt tutkia tilastollisesti merkitsevien selittäjien (*oma_tulo* ja *ika*) odds ratioita (OR) sekä odds ratioiden 95% luottamusvälin ylärajoja:

- *oma_tulo*:
 - OR: 1.0055
 - 95% luottamusvälin alaraja OR:lle: 1.0040

- 95% luottamusvälin yläraja OR:lle: 1.0073
- *ika*:
 - OR: 1.0707
 - 95% luottamusvälin alaraja OR:lle: 1.0298
 - 95% luottamusvälin yläraja OR:lle: 1.1173

Odds ratioista nähdään, että tulojen kasvaessa työllisyyden todennäköisyys myös kasvaa eli tuloilla on positiivinen yhteys työllisyyteen. Samoin iän kohdalla nähdään positiivinen yhteys työllisyyteen, eli iän kasvaessa tulot kasvavat ~ 1.12 kertaisesti.

R:llä mallin selitysasteeksi (Nagelkerken R^2) saadaan 0.5695, kun havaintoja mallissa oli 201. Käytännössä tulos tarkoittaa sitä, että noin 57% työllisyystilanteen vaihtelusta on mallinnettavissa käytettyjen selittäjien avulla.

Tehtävä 5

Tutkitaan nyt useampiluokkaista selitettävää mallia (kun tehtävässä 2 tutkittava muuttuja oli kak-siluokkainen) logistisen regressioanalyysin avulla, jossa numeerisina selittäjinä ovat omat nettotulot ja ikä, kategorisena selittäjän omistusasunto sekä selitettävänä muuttujana tyytyväisyys taloudelliseen tilanteeseen. Valitaan selitettävän muuttujan (*taltyyt2*) referenssiluokaksi *erittäin tyytymaton*.

```
Call:
multinom(formula = taltyyt2 ~ oma_tulo + ika + omistusaon, data = dat)

Coefficients:
              (Intercept)      oma_tulo      ika      omistusaon
erittäin tyytyväinen    -8.892606  0.004275009  0.08846868 -1.44568507
melko tyytyväinen      -3.728151  0.003832908  0.02000670 -1.63142813
melko tyytymaton       -1.477182  0.002171937 -0.01691658 -0.02063842

Std. Errors:
              (Intercept)      oma_tulo      ika      omistusaon
erittäin tyytyväinen    0.05058165  0.0006876734  0.02025152  0.6803387
melko tyytyväinen      0.46303681  0.0005587491  0.01650852  0.4424751
melko tyytymaton       0.49242279  0.0005657890  0.01707409  0.4100610

Residual Deviance: 420.7204
AIC: 444.7204
> # P-arvot (5)
> p <- (1-pnorm(abs(z), 0, 1))*2
> p
              (Intercept)      oma_tulo      ika      omistusaon
erittäin tyytyväinen 0.000000e+00 5.079575e-10 1.251055e-05 0.0335908660
melko tyytyväinen   8.881784e-16 6.895595e-12 2.255502e-01 0.0002268679
melko tyytymaton    2.701350e-03 1.236494e-04 3.217956e-01 0.9598593144
```

R:llä sovitetun mallin yhteenvedon perusteella muodostetuista p-arvoista nähdään:

- *oma_tulo*: p-arvot < 0.05 kaikille OR:ille
- *ika*: p-arvot ensimmäisen OR:n (*erittäin tyytyväinen*) kohdalla < 0.05
- *omistusaon*: p-arvot kahden ensimmäisen OR:n (*erittäin tyytyväinen* ja *melko tyytyväinen*) kohdalla < 0.05

Tehtävä 6

	(Intercept)	oma_tulo	ika	omistusaon
erittäin tyytyväinen	0.0001374011	1.004284	1.0925000	0.2355846
melko tyytyväinen	0.0240372321	1.003840	1.0202082	0.1956500
melko tyytymätön	0.2282800613	1.002174	0.9832257	0.9795731

Tehtävän 5 mukaisesti kaikki kolme OR:ää ovat tilastollisesti merkitseviä ja voidaan nähdä OR:n olevan sitä korkeampi mitä tyytyväisempi testihenkilö on. On siis pääteltävissä, että tuloilla on kaikissa luokissa positiivinen vaikutus taloudelliseen tyytyväisyyteen, mutta mitä tyytyväisempiä testihenkilöt ovat talouteensa, sitä suurempi merkitys tuloilla on tähän tunteeseen.

Tehtävä 7

	(Intercept)	oma_tulo	ika	omistusaon
erittäin tyytyväinen	0.0001374011	1.004284	1.0925000	0.2355846
melko tyytyväinen	0.0240372321	1.003840	1.0202082	0.1956500
melko tyytymätön	0.2282800613	1.002174	0.9832257	0.9795731

Tehtävän 5 mukaisesti ainoastaan *erittäin tyytyväinen* luokan kohdalla ikä on tilastollisesti merkitsevä selittäjä. Kyseisen luokan kohdalla yhteys on positiivista eli korkeampi ikä vaikuttaa positiivisesti taloudelliseen tyytyväisyyteen.

Tehtävä 8

	(Intercept)	oma_tulo	ika	omistusaon
erittäin tyytyväinen	0.0001374011	1.004284	1.0925000	0.2355846
melko tyytyväinen	0.0240372321	1.003840	1.0202082	0.1956500
melko tyytymätön	0.2282800613	1.002174	0.9832257	0.9795731

Tehtävän 5 mukaisesti *erittäin tyytyväinen* ja *melko tyytyväinen* luokkien kohdalla tulokset ovat tilastollisesti merkitseviä. Näiden kohdalla on selkeästi nähtävissä, että OR:ien ollessa huomattavasti alle yhden, on asunnon omistamisella negatiivinen vaikutus taloudelliseen tyytyväisyyteen kahdessa ylimmässä luokassa.

Tehtävä 9

Tarkastellaan vielä lopuksi tilastollista riippuvuutta kolmen muuttujan taulussa (*työtilan*, *omistusaon* ja *yltyyt*). Aloitetaan tekemällä yksiulotteiset frekvenssijakaumat sekä kolmen muuttujan ristiintaulu R:llä:

```
> table(omistusa)
omistusa
ei  on
116 85
> table(työtilan)
työtilan
tyoton työssä
101 100
> table(yltyyt)
yltyyt
erittäin tyytyväinen    melko tyytyväinen    melko tyytymätön    erittäin tyytymätön
28                    82                    46                    45
```

Frekvenssijakaumien tutkimuksen tarkoituksena on arvioida, onko jokaisessa muuttujaluokassa riittävä määrä havaintoja. Tulosten perusteella nähdään, että pienin havaintolukumäärä 28 löytyy luokasta *erittäin tyytyväinen*. Lähtökohtana loglineaarille mallille voidaan pitää useampiluokkaista muuttujaa tarkastellessa 10 muuttujaa, jolloin siis 28 riittää hyvin.

		yltyyt			
		erittäin tyytyväinen	melko tyytyväinen	melko tyytymätön	erittäin tyytymätön
omistusa	työtilan				
ei	tyoton	5	23	17	11
	työssä	14	34	10	2
on	tyoton	3	6	11	25
	työssä	6	19	8	7

Kolmiulotteinen ristiintaulu ei sisällä yhtään nollasoluja eli havaintoja on kaikissa luokkien yhdistelmissä. Ristiintaulun pienin oslufrekvenssi on 2 (talouteensa erittäin tyytymättömille työssäkäyville, joilla ei ole omistusasuntoa).

Tehtävä 10

Koska ollaan tehtävässä 9 testattu, että tarkasteltava aineisto sopii loglineaarille malleille, voidaan lähteä tarkastelemaan kolmen muuttujan välisiä riippuvuuksia:

```
> # Täydellinen riippumattomuus (10)
> loglm(~omistusa+tyotilan+yltyyt, mytable)
Call:
loglm(formula = ~omistusa + tyotilan + yltyyt, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 55.95944 10 2.089139e-08
Pearson          56.76575 10 1.474987e-08
> # 'yltyyt' riippumaton muuttujaparista (10)
> loglm(~omistusa+tyotilan+yltyyt+tyotilan*omistusa, mytable)
Call:
loglm(formula = ~omistusa + tyotilan + yltyyt + tyotilan * omistusa,
      data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 55.53216  9 9.641686e-09
Pearson          54.04742  9 1.849048e-08
> # 'omistusa' riippumaton muuttujaparista (10)
> loglm(~omistusa+tyotilan+yltyyt+tyotilan*yltyyt, mytable)
Call:
loglm(formula = ~omistusa + tyotilan + yltyyt + tyotilan * yltyyt,
      data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 23.98459  7 0.001146480
Pearson          23.41687  7 0.001441729
> # 'tyotilan' riippumaton muuttujaparista (10)
> loglm(~omistusa+tyotilan+yltyyt+omistusa*yltyyt, mytable)
Call:
loglm(formula = ~omistusa + tyotilan + yltyyt + omistusa * yltyyt,
      data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 34.60453  7 1.327012e-05
Pearson          32.78607  7 2.901956e-05

> # Ehdollinen riippumattomuusmalli: 'omistusa' ja 'yltyyt' riippumattomia (
> loglm(~omistusa+tyotilan+yltyyt+omistusa*tyotilan+tyotilan*yltyyt, mytable)
Call:
loglm(formula = ~omistusa + tyotilan + yltyyt + omistusa * tyotilan +
      tyotilan * yltyyt, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 23.55732  6 0.0006297754
Pearson          22.90353  6 0.0008294418
> # Ehdollinen riippumattomuusmalli: 'tyotilan' ja 'yltyyt' riippumattomia (
> loglm(~omistusa+tyotilan+yltyyt+omistusa*tyotilan+omistusa*yltyyt, mytable)
Call:
loglm(formula = ~omistusa + tyotilan + yltyyt + omistusa * tyotilan +
      omistusa * yltyyt, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 34.17726  6 6.217405e-06
Pearson          32.43792  6 1.344746e-05
> # Ehdollinen riippumattomuusmalli: 'tyotilan' ja 'omistusa' riippumattomia (
> loglm(~omistusa+tyotilan+yltyyt+omistusa*yltyyt+tyotilan*yltyyt, mytable)
Call:
loglm(formula = ~omistusa + tyotilan + yltyyt + omistusa * yltyyt +
      tyotilan * yltyyt, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 2.629681  4 0.6215743
Pearson          2.543558  4 0.6368535
> # Parittaisten riippuvuuksien malli (10)
> loglm(~omistusa+tyotilan+yltyyt+omistusa*tyotilan+omistusa*yltyyt+tyotilan
Call:
loglm(formula = ~omistusa + tyotilan + yltyyt + omistusa * tyotilan +
      omistusa * yltyyt + tyotilan * yltyyt, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 1.240172  3 0.7433863
Pearson          1.260793  3 0.7384635
```

Loglineaaristen mallien yksinkertaisuutta voidaan vertailla keskenään ottamalla huomioon seuraavat seikat: mallin sopivuus (esim. uskottavuusosamäärän tai Pearsonin khin neliön testin avulla, matalampi arvo indikoi parempaa sopivuutta), vapausasteet (yksinkertaisemmilla malleilla enemmän vapausasteita) ja p-arvo (tilastollinen merkitsevyys).

R:n tulosteesta nähdään, että yksinkertaisin sopiva malli kuvaamaan riippuvuusrakennetta olisi malli, jossa muuttujat *tyotilan* ja *omistusa*. Kyseisen mallin generoiva luokka on {omistusa * yltyyt, tyotilan * yltyyt}. Tälle mallille uskottavuusosamäärä on 2.6297 ja Pearsonin khin neliön testi 2.5436 vapausasteella 4 ja p-arvoilla 0.6216 ja 0.6369. P-arvot ylittävät merkitsevyystason, jolloin saadut tulokset vaikuttavat järkeviltä (ts. eivät ole poikkeavia).

Tehtävä 11

Tehdään vielä lopuksi mallin mukainen yhteyksien jatkotarkastelu ristiintauluihin ja tulkitaan malli suhteellisten frekvenssien avulla:

```
> # Mallin jatkotarkastelu (11)
> taulu1 <- table(omistusa, yltyyt)
> prop.table(taulu1, 1)
      yltyyt
omistusa erittain tyytyväinen melko tyytyväinen melko tyytymaton erittain tyytymaton
ei      0.1637931      0.4913793      0.2327586      0.1120690
on      0.1058824      0.2941176      0.2235294      0.3764706
> taulu2 <- table(tyotilan, yltyyt)
> prop.table(taulu2, 1)
      yltyyt
tyotilan erittain tyytyväinen melko tyytyväinen melko tyytymaton erittain tyytymaton
tyoton   0.07920792   0.28712871   0.27722772   0.35643564
tyossa   0.20000000   0.53000000   0.18000000   0.09000000
```

Ensimmäisessä taulussa tutkitaan omistusasunnon sekä yleisen tyytyväisyyden frekvenssejä. Tuloksista voidaan nähdä, että asunnon omistavat ovat keskimäärin tyytymättömämpiä yleiseen elämäntilanteeseensa kuin ne, jotka eivät omista asuntoa. Asunnon omistajien keskuudessa suurin frekvenssi 0.3765 löytyy erittäin tyytymättömien luokasta, kun taas niillä jotka eivät omista asuntoa suurin frekvenssi 0.4914 löytyy melko tyytyväisten luokasta.

Toisessa taulussa tutkitaan työtilanteen sekä yleisen tyytyväisyyden frekvenssejä. Tuloksista voidaan nähdä, että työssäkäyvät ovat keskimäärin tyytyväisempiä yleiseen elämäntilanteeseensa kuin työttömät. Työllisillä suurin frekvenssi 0.5300 löytyy melko tyytyväisten luokasta, kun taas työttömien suurin frekvenssi 0.3564 löytyy erittäin tyytymättömien luokasta.

Työtilanteella ja asunnon omistamisella ei ole yhteyttä keskenään.