

TILM3702 — Tutoriaali 5

Arttu Einistö

April 19, 2024

Pääkomponenttianalyysin käyttö muuttujien ryhmittelyssä

Lähdetään tutkimaan pääkomponenttianalyysin avulla, millaisia kokonaisuuksia aineistona käytetyn lomakkeen väittämistä *ahyöt1b-ahyöt10b* muodostuu.

Aloitetaan tarkastelemalla muuttujien keskinäisiä korrelaatioita:

```
> res2 <- rcorr(as.matrix(data_pca))
> res2
```


	ahyot1b	ahyot2b	ahyot3b	ahyot4b	ahyot5b	ahyot6b	ahyot7b	ahyot8b	ahyot9b	ahyot10b
ahyot1b	1.00	0.58	0.24	0.52	0.65	0.53	0.45	0.58	0.52	-0.06
ahyot2b	0.58	1.00	0.05	0.24	0.33	0.19	0.10	0.23	0.28	-0.16
ahyot3b	0.24	0.05	1.00	0.38	0.28	0.35	0.37	0.30	0.15	0.04
ahyot4b	0.52	0.24	0.38	1.00	0.45	0.55	0.52	0.56	0.56	-0.12
ahyot5b	0.65	0.33	0.28	0.45	1.00	0.67	0.52	0.75	0.53	0.16
ahyot6b	0.53	0.19	0.35	0.55	0.67	1.00	0.65	0.61	0.76	0.26
ahyot7b	0.45	0.10	0.37	0.52	0.52	0.65	1.00	0.58	0.62	0.15
ahyot8b	0.58	0.23	0.30	0.56	0.75	0.61	0.58	1.00	0.54	-0.04
ahyot9b	0.52	0.28	0.15	0.56	0.53	0.76	0.62	0.54	1.00	0.20
ahyot10b	-0.06	-0.16	0.04	-0.12	0.16	0.26	0.15	-0.04	0.20	1.00

n= 53

P

	ahyot1b	ahyot2b	ahyot3b	ahyot4b	ahyot5b	ahyot6b	ahyot7b	ahyot8b	ahyot9b	ahyot10b
ahyot1b		0.0000	0.0840	0.0000	0.0000	0.0000	0.0008	0.0000	0.0000	0.6880
ahyot2b	0.0000		0.7095	0.0813	0.0144	0.1747	0.4624	0.0923	0.0461	0.2476
ahyot3b	0.0840	0.7095		0.0047	0.0422	0.0111	0.0063	0.0305	0.2872	0.7793
ahyot4b	0.0000	0.0813	0.0047		0.0008	0.0000	0.0000	0.0000	0.0000	0.4100
ahyot5b	0.0000	0.0144	0.0422	0.0008		0.0000	0.0000	0.0000	0.0000	0.2664
ahyot6b	0.0000	0.1747	0.0111	0.0000	0.0000		0.0000	0.0000	0.0000	0.0579
ahyot7b	0.0008	0.4624	0.0063	0.0000	0.0000	0.0000		0.0000	0.0000	0.2738
ahyot8b	0.0000	0.0923	0.0305	0.0000	0.0000	0.0000	0.0000		0.0000	0.7511
ahyot9b	0.0000	0.0461	0.2872	0.0000	0.0000	0.0000	0.0000	0.0000		0.1422
ahyot10b	0.6880	0.2476	0.7793	0.4100	0.2664	0.0579	0.2738	0.7511	0.1422	

R:n tulosteesta nähdään, että tarkasteltavista muuttujista ainoa, jossa on havaittavissa säännöllistä korreloimattomuutta muiden muuttujien kanssa on *ahyöt10b*. Kyseisen muuttujan korrelaatiokertoimien p-arvot ovat aina yli merkitsevyystason 0.05. Korrelaatioiden voimakkuuksia voidaan myös havainnollistaa kuvion avulla:



Seuraavaksi muuttujia voidaan tutkia Kaiser-Meyer-Olkin sekä Bartlettin testin avulla:

```
> cor.test.bartlett(data.kor2, n=53, diag=TRUE)
$chisq
[1] 260.4731

$p.value
[1] 4.03861e-32

$df
[1] 45

> KMO(data.kor2)
Kaiser-Meyer-Olkin factor adequacy
Call: KMO(r = data.kor2)
Overall MSA = 0.83
MSA for each item =
  ahyot1b  ahyot2b  ahyot3b  ahyot4b  ahyot5b  ahyot6b  ahyot7b  ahyot8b  ahyot9b  ahyot10b
    0.86    0.67    0.73    0.88    0.82    0.85    0.92    0.84    0.81    0.43
```

R:n tulosteesta voidaan poimia seuraavat tiedot:


Kriteerilaji	Otoksesta laskettu	Toteutuuko edellytys?
KMO-suureen arvo	0.83	Kyllä, koska $MSA > 0.6$
Bartlettin testin hmt.	$4.039 \cdot 10^{-32}$	Kyllä, koska $p < 0.05$

KMO-testin tuloksesta on siis pääteltävissä, että muuttujien välillä esiintyy riittävästi korrelaatiota faktorianalyysin hyödyntämiseen ja että aineistosta on mahdollista luotettavasti eritellä suuret yleislinjat pääkomponentteina. Bartlettin testin p-arvo puolestaan todistaa vahvasti vastaan väitettä, että muuttujien varianssit olisivat yhtä suuria. Korrelaatiomatriisi näyttää siis sopivan hyvin pääkomponenttianalyysiin.

Tutkitaan sitten aineiston pääkomponenttien lukumäärää ja niiden kumulatiivista selitysprosenttia:

```
> summary(pca)
Importance of components:
      PC1    PC2    PC3    PC4    PC5    PC6    PC7    PC8    PC9    PC10
Standard deviation  2.2040 1.4912 1.2164 0.80712 0.5225 0.50509 0.37270 0.27460 0.21245 2.184e-16
Proportion of Variance 0.4858 0.2224 0.1480 0.06514 0.0273 0.02551 0.01389 0.00754 0.00451 0.000e+00
Cumulative Proportion 0.4858 0.7081 0.8561 0.92124 0.9485 0.97406 0.98795 0.99549 1.00000 1.000e+00
> # Ominaisarvot
> (pca$sdev)^2
[1] 4.857486e+00 2.223738e+00 1.479735e+00 6.514354e-01 2.730490e-01 2.551138e-01 1.389032e-01
[8] 7.540308e-02 4.513598e-02 4.768618e-32
```

Pääkomponentteja on yhteensä kymmenen, mutta näistä ominaisarvokriteerien perusteella (varianssia kuvaava ominaisarvo yli 1) jäävät jäljelle *PC1*, *PC2* ja *PC3*. Näiden kumulatiivinen selitysprosentti aineiston muuttujien vaihtelusta on noin 85.62 %.



Tutkitaan sitten pääkomponenttien latauksia sekä Varimax- (suorakulmainen rotaatio) että Promax- rotaation (vinokulmainen rotaatio) mukaisesti:

```
> pca.varimax
$loadings

Loadings:
      PC1  PC2  PC3
ahyot1b -0.152 -0.488
ahyot2b  0.135 -0.628
ahyot3b  0.198  0.273  0.702
ahyot4b -0.186         0.417
ahyot5b -0.361 -0.187
ahyot6b -0.494  0.127
ahyot7b -0.391  0.205  0.210
ahyot8b -0.331 -0.134  0.214
ahyot9b -0.490         -0.152
ahyot10b         0.416 -0.455

      PC1 PC2 PC3
SS loadings  1.0 1.0 1.0
Proportion Var 0.1 0.1 0.1
Cumulative Var 0.1 0.2 0.3

$rotmat
      [,1]      [,2]      [,3]
[1,] 0.8231971 0.3879836 -0.4145059
[2,] -0.4407072 0.8969415 -0.0356817
[3,] 0.3579436 0.2120488 0.9093468

> pca.promax
$loadings

Loadings:
      PC1  PC2  PC3
ahyot1b -0.119 -0.491
ahyot2b  0.191 -0.669 -0.199
ahyot3b  0.200  0.264  0.812
ahyot4b -0.178         0.356
ahyot5b -0.363 -0.156 -0.118
ahyot6b -0.528  0.185
ahyot7b -0.422  0.255  0.170
ahyot8b -0.331 -0.104  0.110
ahyot9b -0.515         -0.266
ahyot10b -0.141  0.442 -0.385

      PC1 PC2 PC3
SS loadings  1.106 1.096 1.112
Proportion Var 0.111 0.110 0.111
Cumulative Var 0.111 0.220 0.331

$rotmat
      [,1]      [,2]      [,3]
[1,] 0.8228080 0.3154643 -0.14500316
[2,] -0.5355527 0.9813001 0.06825956
[3,] 0.3773937 0.1833765 1.04230335
```

Varimax-rotatation tulosteesta voidaan poimia seuraavat pääkomponentteihin kohdistuvat lataukset:

Muuttujat	PC1 lataus	PC2 lataus	PC3 lataus
<i>ahyöt1b</i>	-0.152	-0.488	-
<i>ahyöt2b</i>	0.135	-0.628	-
<i>ahyöt3b</i>	0.198	0.273	0.702
<i>ahyöt4b</i>	-0.186	-	0.417
<i>ahyöt5b</i>	-0.361	-0.187	-
<i>ahyöt6b</i>	-0.494	0.127	-
<i>ahyöt7b</i>	-0.391	0.205	0.210
<i>ahyöt8b</i>	-0.331	-0.134	0.214
<i>ahyöt9b</i>	-0.490	-	-0.152
<i>ahyöt10b</i>	-	0.416	-0.455

Promax-rotatation tulosteesta voidaan puolestaan poimia seuraavat pääkomponentteihin kohdistuvat lataukset:

Muuttujat	PC1 lataus	PC2 lataus	PC3 lataus
<i>ahyöt1b</i>	-0.119	-0.491	-
<i>ahyöt2b</i>	0.191	-0.669	-0.199
<i>ahyöt3b</i>	0.200	0.264	0.812
<i>ahyöt4b</i>	-0.178	-	0.356
<i>ahyöt5b</i>	-0.363	-0.156	-0.118
<i>ahyöt6b</i>	-0.528	0.185	-
<i>ahyöt7b</i>	-0.422	0.255	0.170
<i>ahyöt8b</i>	-0.331	-0.104	0.110
<i>ahyöt9b</i>	-0.515	-	-0.266
<i>ahyöt10b</i>	-0.141	0.442	-0.385

Se mikä muuttuja kuuluu mihinkin pääkomponenttiin määräytyy latausten itseisarvojen perusteella. Esim. viim. tarkastellussa Promax-rotatiossa *ahyöt10b* kuuluu pääkomponenttiin 2, sillä siinä on itseisarvoltaan suurin lataus.

Kommunaliteetti kuvaa pääkomponenttianalyysissä sitä, kuinka suuri osuus muuttujan vaihtelusta on selitettävissä pelkästään pääkomponenttien avulla (tässä tapauksessa *PC1*, *PC2* ja *PC3*). Mitä lähempänä kommunaliteetti on lukua 1, sitä paremmin pääkomponentit selittävät vaihtelua.

```
> # Kommunaliteetit
> comp.matrix[,1]^2+comp.matrix[,2]^2+comp.matrix[,3]^2
[1] 0.7737052 0.7483383 0.6498311 0.6622509 0.6995724 0.8077270 0.6815036 0.6796515 0.7115195
[10] 0.8003240
```

Tässä tapauksessa kommunaliteetit ovat noin välillä (0.6498,0.8077).

Pääkomponenttien keskinäisiä korrelaatioita voidaan tutkia Pearsonin korrelaatiokertoimien avulla:

```

> cor.test(apuvalineet, media, method="pearson")

Pearson's product-moment correlation

data:  apuvalineet and media
t = 5.6444, df = 51, p-value = 7.355e-07
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.4202188 0.7625664
sample estimates:
      cor
0.6200821

> cor.test(apuvalineet, laheiset, method="pearson")

Pearson's product-moment correlation

data:  apuvalineet and laheiset
t = 4.5831, df = 51, p-value = 2.991e-05
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.3159317 0.7071614
sample estimates:
      cor
0.5401037

> cor.test(media, laheiset, method="pearson")

Pearson's product-moment correlation

data:  media and laheiset
t = 3.5674, df = 51, p-value = 0.0007951
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.2008474 0.6398838
sample estimates:
      cor
0.4468811

```

R:n tulosteesta voidaan poimia seuraavat korrelaatiot:

	<i>apuvalineet</i>	<i>media</i>	<i>laheiset</i>
<i>apuvalineet</i>	-	0.6201	0.5401
<i>media</i>	0.6201	-	0.4469
<i>laheiset</i>	0.5401	0.4469	-

Koska muuttujat selkeästi korreloivat keskenään (kaikki korrelaatiokertoimet yli 0.3), on järkevintä käyttää vinokulmaista eli tässä tapauksessa Promax-rotatiota (vrt. Varimax-rotatioon).

Klusterianalyysin käyttö havaintojen ryhmittelyssä

Tutkitaan nyt k-keskiarvoklusteroinnin (k-means clustering) käyttöä havaintojen ryhmittelyssä asteittain, kun ryhmien lukumäärä $k \in \{2, 3, 4, 5\}$.

$k = 2$:

```
K-means clustering with 2 clusters of sizes 24, 29

Cluster means:
apuvalineet      media      laheiset
1  0.8809029  0.6897783  0.7223993
2 -0.7290231 -0.5708510 -0.5978477
```

Klusteri	Havaintojen lkm.	Profiloivat pääkomponentit
1	24	<i>apuvalineet, media, laheiset</i>
2	29	-

$k = 3$:

```
K-means clustering with 3 clusters of sizes 23, 7, 23

Cluster means:
apuvalineet      media      laheiset
1 -0.5148358 -0.2146154 -0.4222814
2 -1.2373786 -1.6188084 -1.1530078
3  0.8914293  0.7072962  0.7731968
```

Klusteri	Havaintojen lkm.	Profiloivat pääkomponentit
1	23	-
2	7	Matalat arvot (< -1)
3	23	<i>apuvalineet, media, laheiset</i>

$k = 4$:

```
K-means clustering with 4 clusters of sizes 6, 21, 15, 11

Cluster means:
apuvalineet      media      laheiset
1 -1.3055624 -1.595847487 -1.3612085
2  0.9303133  0.824964192  0.7846043
3 -0.4152325 -0.009460613 -0.8609926
4 -0.4977015 -0.691568537  0.4186772
```

Klusteri	Havaintojen lkm.	Profiloivat pääkomponentit
1	6	Matalat arvot (< -1)
2	21	<i>apuvalineet, media, laheiset</i>
3	15	-
4	11	-

$k = 5$:

```
K-means clustering with 5 clusters of sizes 13, 6, 16, 8, 10

Cluster means:
  apuvalineet      media    laheiset
1   1.1074094  0.74166861  0.1883317
2  -1.1100212 -1.85124020 -1.0437548
3  -0.5860980 -0.09356583 -0.9185198
4   0.7074822  0.95770831  1.6142290
5  -0.4018484 -0.46988640  0.5596701
```

Klusteri	Havaintojen lkm.	Profiloivat pääkomponentit
1	13	<i>apuvalineet</i>
2	6	Matalat arvot (< -1)
3	16	-
4	8	<i>media, laheiset</i>
5	10	-