


TILM3702 — Tutoriaali 6


Arttu Einistö

April 26, 2024

Tehtävä 1




Jo yllä nähtävästä kausitasoittamattomasta aikasarjan kuvaajasta on helppo nähdä, että sarja sisältää selkeästi nousevaa kehityssuuntaa eli trendiä.



Havainto voidaan todentaa hajottamalla kyseinen aikasarja komponentteihin ja muodostamalla tätä kautta kausitasoitettu aikasarja, jossa satunnaisvaihtelusta huolimatta kasvava trendi on selkeästi silmämääräisesti nähtävissä.

Tehtävä 2


Tutkitaan kausitasoitettun aikasarjan stationaarisuutta tarkemmin ottamalla siitä 1. differenssin Δy_t erotukset:



Tästä kerran differensoidusta aikasarjasta voidaan laskea keskiarvo 2.2644, jonka ympärille differenssien erotusten kuvaajassa nähtävä vaihtelu keskittyy. Uuden aikasarjan tilastolliset ominaisuudet (mm. keskiarvo ja varianssi) eivät siis riipu ajasta (ts. pysyvät ajan suhteen vakioina) eli kyseinen aikasarja on stationaarinen toisin kuin alkuperäinen aikasarja, jossa kasvava trendikomponentti tekee aikasarjasta epästationaarisen.

Tehtävä 3

Tutkitaan sitten uuden, kerran differensoidun, aikasarjan autokorrelaatio- sekä osittaisautokorrelaatiofunktioita eli aikasarjan korreloituneisuutta viivästettyjen havaintojen y_{t-k} (viipeiden) välillä:



R:llä muodostetuissa kuvissa siniset katkoviivat ovat 95 % approksimatiiviset luottamusvälit, jolloin siis katkoviivojen ulkopuolelle ulottuvat viivat viittaavat tilastolliseen merkitsevyyteen kyseisen viipeen kohdalla merkitsevyystasolla 0.05 (huomioitavaa on, että $r_0 = 1$ aina, joten viipettä 0 ei huomioida).

Aikasarjan vaihtelua kuvaavan ARMA-mallin (ARIMA($p, 1, q$) alkuperäiselle differensoimattomalle aineistolle) estimointi vaatii malliasteiden p ja q selvittämistä.

AR(p)-malleilla on eksponentiaalisesti laskevat autokorrelaatioiden arvot (mahd. neg. sekä pos.) ja p kappaletta piikkejä p :ssä ensimmäisessä osittaiskorrelaatiossa, jonka jälkeen äkisti laskeva katkos. Tutkittaessa yllä olevaa osittaisautokorrelaatiofunktioita nähdään, ettei selkeää katkospistettä esiinny, mutta potentiaalinen ehdokas tähän voisi olla esim. viides viipe, jolloin $p = 5$. Valinnassa voidaan myös ottaa huomioon se, että heikosti autokorreloivissa prosesseissa pidemmälle viipeissä mentäessä kasvaa myös todennäköisyys sille, että korrelaatio johtuu virheestä/satunnaisuudesta.

MA(q)-malleilla on puolestaan eksponentiaalisesti laskevat osittaisautokorrelaatioiden arvot ja q kappaletta piikkejä q :ssa ensimmäisessä autokorrelaatiossa, jonka jälkeen äkisti laskeva katkos. Tutkittaessa yllä olevaa autokorrelaatiofunktioita nähdään, että potentiaalinen katkoskohta voisi olla esim. kolmas viipe, jolloin $q = 3$. Kolmannen viipeen jälkeen seuraava tilastollisesti merkitsevä viipe löytyy vasta hyvin kaukaa ja välissä on monia lähes nollan autokorrelaation viipeitä.

Alustavasti malliksi voitaisiin valita siis esim. ARMA(3, 5), jota voidaan lähteä vertaamaan tehtävänannon ARMA(3, 2)-malliin myöhemmissä vaiheissa.

Tehtävä 4

Tutkitun kerran differensoidun aikasarjan residuaalien autokorrelaatiota voidaan mitata Ljung-Box-testisuureen avulla (jolle viivepituus $K = 20$), jossa nollahypoteesina on oletus residuaalien autokorrelaamattomuudesta:

```
> Box.test(dy, lag=20, type=c("Ljung-Box"))  
  
Box-Ljung test  
  
data: dy  
X-squared = 62.266, df = 20, p-value = 3.159e-06
```

Koska testin p-arvo $3.159 \cdot 10^{-6}$ on selvästi alle merkitsevyystason 0.05, voidaan nollahypoteesi residuaalien autokorrelaamattomuudesta hylätä. Residuaaleissa on siis selvästi autokorrelaatiota, vaikkei se olekaan kovin vahvaa. Käytännössä tässä vaiheessa tutkitaan siis ARIMA(0,1,0)-mallin kykyä kuvata alkuperäistä aikasarjaa hotellihuoneiden varausmääristä, joka voidaan todeta kohtalaisen huonosti autokorrelaation toteutumisen takia.

Tehtävä 5 & 6

Mallivalintoja (mallien ARMA(5,3) ja ARMA(3,2) välillä) voidaan vertailla R:n `Arima` -komennolla käyttäen kertaalleen differensoitua aikasarjaa:


```
> fit <- Arima(dy, order=c(5,0,3), include.mean=TRUE, include.drift=FALSE, transform.pars=TRUE)
> fit
Series: dy
ARIMA(5,0,3) with non-zero mean
Coefficients:
      ar1      ar2      ar3      ar4      ar5      ma1      ma2      ma3      mean
 1.7341 -0.9940 -0.2248  0.4446 -0.2444 -2.5657  2.2893 -0.7236  1.9520
s.e.  0.1287  0.1959  0.1691  0.1632  0.0983  0.1097  0.2129  0.1114  0.0108

sigma^2 = 145.8: log likelihood = -652.33
AIC=1324.66 AICc=1326.07 BIC=1355.84
ARMA(5, 3)


> fit <- Arima(dy, order=c(3, 0, 2), include.mean=TRUE, include.drift=FALSE, transform.pars=TRUE)
> fit
Series: dy
ARIMA(3,0,2) with non-zero mean
Coefficients:
      ar1      ar2      ar3      ma1      ma2      mean
 1.007 -0.1171 -0.2971 -1.8246  0.8246  1.9518
s.e.  0.087  0.1106  0.0798  0.0622  0.0606  0.0091

sigma^2 = 150.7: log likelihood = -656.59
AIC=1327.18 AICc=1327.89 BIC=1349.01
ARMA(3, 2)
```

Jälkimmäisen tehtävänannossa määritellyn ARMA(3,2)-vertailumallin residuaaleja voidaan tarkastella sekä diagnostisesti että Ljung-Box-testisuureella:



R:llä muodostetuista autokorrelaatiokertoimista voidaan nähdä, että käytännössä ARMA(3, 2)-mallin residuaalisarja on autokorreloimaton, sillä ainoastaan viipeessä 18 on tilastollisesti merkitsevää autokorrelaatiota. Koska kyseinen viipe on hyvin kaukana, voi saatu tulos hyvin johtua myös satunaisvaihtelusta eikä sitä näin ollen ole mielekäästä ottaa huomioon.



Vastaavasti sama tutkimus voidaan toteuttaa itse muodostamallemme mallille ARMA(5, 3), joka silmä-
määräisesti näyttää myös autokorreloimattomalta, sillä viippeiden korrelaatiot eivät ole tutkittavalla
välillä $K = 20$ tilastollisesti merkitseviä. Molemmat mallit olisivat siis sen perusteella suhteellisen
sopivia aikasarjan analysointiin.

```
> Box.test(resid, lag=20, type=c("Ljung-Box"), fitdf=length(fit.own$coef)) # see ?Box.test
```

Box-Ljung test ARMA(5, 3)

data: resid
X-squared = 13.666, df = 11, p-value = 0.252

```
> Box.test(resid, lag=20, type=c("Ljung-Box"), fitdf=length(fit.og$coef)) # see ?Box.test
```

Box-Ljung test ARMA(3, 2)

data: resid
X-squared = 18.419, df = 14, p-value = 0.1884

Autokorrelaatiokertoimien perusteella aiemmin muodostettu päätelmä molempien mallien autokor-
reloimattomuudesta voidaan nähdä todeksi myös Ljung-Box-testisuureiden avulla. ARMA(5, 3)-malli
saa p-arvokseen 0.252 ja ARMRA(3, 2)-malli 0.1884. Vaikkei malleissa olekaan merkittävän suurta
eroa, valinta voisi tässä kohtaa kallistua itse määrittelemämme mallin ARMA(5, 3) puoleen, joka tuot-

taa pienemmän p-arvon ja jonka viipeet ovat näin ollen hieman satunnaisempia kuin ARMA(3, 2)-mallissa.