

TILM3702 — Kotitehtävä 1

Arttu Einistö

April 13, 2024

Kaksisuuntainen varianssianalyysi

Lähdetään tutkimaan kuntamuodon (*kumu*) ja asumisahtauden (*ahtas*) yhteyttä asunnon pinta-alaan (*pala*) kaksisuuntaisen varianssianalyysin avulla. Tällöin edellytyksenä on, että otokset on poimittu normaalijakautuneista populaatioista, joissa on samat hajonnat.

Tunnusluvut

Aloitetaan tutkimalla muuttujia kuvailevia tunnuslukuja:


```
> # 700 kokoinen otos
> oma.otos <- kotit1.dat[sample(nrow(kotit1.dat), 700),]
> # Kuvailevat tunnusluvut
> with(oma.otos, tapply(pala, list(kumu, ahtas), mean)) # Keskiarvot
      ahtas normaali tilava
kaupunki 52.04082 73.48493 111.8246
muukunta 59.93333 89.57047 122.0800
> with(oma.otos, tapply(pala, list(kumu, ahtas), median)) # Mediaanit
      ahtas normaali tilava
kaupunki  50.0      72 110.0
muukunta  58.5      84 115.5
> with(oma.otos, tapply(pala, list(kumu, ahtas), sd)) # Keskihajonnat
      ahtas normaali tilava
kaupunki 29.51550 28.96688 32.83135
muukunta 30.70318 40.77861 45.50795
```

Tunnusluvuista voidaan pintapuolisesti nähdä esimerkiksi se, että kaupungeissa asunnot ovat keskimääräisesti pienempiä kuin muualla. Myös asuntojen pinta-alat vaihtelevat keskimäärin vähemmän kaupungeissa kuin muualla.

Mallin oletusten tarkastelu

Tarkastellaan sitten otosten normalisuutta Shapiro–Wilkin testeillä:

```
> # Shapiro-Wilkin testit
> with(oma.otos, tapply(pala, list(kumu, ahtas), function(x) shapiro.test(x)$p.value))
      ahtas normaali tilava
kaupunki 0.003840754 5.529008e-08 3.740693e-01
muukunta 0.230161061 1.565472e-05 7.835469e-05
```



R:n tulosteesta ja piirretystä Tukeyn laatikko-janakuvioista nähdään, että ahtaiden kaupunkien ulkopuolella sijaitsevien asuntojen (*maakunta.ahdas*) sekä tilavien kaupunkiasuntojen (*kaupunki.tilava*) kohdalla p-arvot ovat yli merkitsevyystason 0.05. Shapiro–Wilkin testissä nollahypoteesina H_0 on oletus jakauman normaalisuudesta eli saatujen testitulosten perusteella neljä kuudesta luokkien yhdistelmästä ei ole normaalisti jakautuneita.

Testataan myös hajontojen yhtäsuuruutta Levenen testin avulla:

```
> leveneTest(pala~kumu*ahtas)
Levene's Test for Homogeneity of Variance (center = median)
  Df F value    Pr(>F)
group 5  5.1648 0.0001161 ***
694
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Kuten testituloksesta nähdään, myöskään jakaumien hajonnat eivät ole yhtäsuuria. Tämä voidaan kuitenkin tässä asiayhteydessä lähes sivuuttaa, sillä varianssianalyysi on lähtökohtaisesti suhteellisen robusti testi huolimatta suurelle otoskoolle tyypillisistä erisuuruuksista.

Kaksisuuntainen varianssianalyysi

Lähdetään siis toteuttamaan itse kaksisuuntaista varianssianalyysiä:


```
> anova(lm(pala~kumu*ahtas))
Analysis of Variance Table

Response: pala
      Df Sum Sq Mean Sq F value    Pr(>F)
kumu    1  43967    43967  38.9933 7.408e-10 ***
ahtas    2 178884    89442  79.3236 < 2.2e-16 ***
kumu:ahtas  2   1527      764   0.6773   0.5083
Residuals 694 782527    1128
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Nyt saadusta R-tulosteesta voidaan lukea tarkasteltavan mallin muuttujien sekä niiden yhteisvaikutuksen tilastollinen merkitsevyys. Koska sekä kuntamuodon että asumisahtauden p-arvot ovat alle merkitsevyystason 0.001, ovat molemmat selittäjät tilastollisesti merkitseviä. Kyseisten selittäjien yhteisvaikutuksen p-arvo puolestaan on huomattavan korkea, jonka perusteella yhteisvaikutusta ei voida pitää tilastollisesti merkitseväenä.

Selittäjien monivertailu

Vastataksemme vielä lopuksi kysymykseen selittäjien luokkien eroista, tulee tarkastella jakaumia Tukeyn monivertailutestin (engl. HSD, honestly significant difference) avulla:



```

> TukeyHSD(malli_lm2)
  Tukey multiple comparisons of means
    95% family-wise confidence level

Fit: aov(formula = malli)

$ kumu
              diff      lwr      upr p adj
muukunta-kaupunki 16.89218 11.58093 22.20344    0

$ ahtas
              diff      lwr      upr p adj
normaali-ahdas  24.62788 15.09687 34.15888    0
tilava-ahdas    60.10006 48.40082 71.79930    0
tilava-normaali 35.47218 27.09151 43.85285    0

$ `kumu:ahtas`
              diff      lwr      upr      p adj
muukunta:ahdas-kaupunki:ahdas      7.892517 -14.352936 30.13797 0.9133331
kaupunki:normaali-kaupunki:ahdas  21.444115   6.844478 36.04375 0.0004363
muukunta:normaali-kaupunki:ahdas  37.529653  21.727081 53.33223 0.0000000
kaupunki:tilava-kaupunki:ahdas    59.783745  41.089676 78.47781 0.0000000
muukunta:tilava-kaupunki:ahdas    70.039184  50.749685 89.32868 0.0000000
kaupunki:normaali-muukunta:ahdas  13.551598  -4.673835 31.77703 0.2755975
muukunta:normaali-muukunta:ahdas  29.637136  10.434576 48.83970 0.0001731
kaupunki:tilava-muukunta:ahdas    51.891228  30.246709 73.53575 0.0000000
muukunta:tilava-muukunta:ahdas    62.146667  39.985851 84.30748 0.0000000
muukunta:normaali-kaupunki:normaali 16.085538   6.756683 25.41439 0.0000154
kaupunki:tilava-kaupunki:normaali 38.339630  24.673085 52.00618 0.0000000
muukunta:tilava-kaupunki:normaali 48.595068  34.124720 63.06542 0.0000000
kaupunki:tilava-muukunta:normaali 22.254092   7.309315 37.19887 0.0003408
muukunta:tilava-muukunta:normaali 32.509530  16.826327 48.19273 0.0000001
muukunta:tilava-kaupunki:tilava   10.255439  -8.337834 28.84871 0.6145902

```

R-tulosteesta nähdään suoraan selkeät erot kuntamuodon eri luokkien kesken (ero noin 16.89) sekä asumisahtauden eri luokkien välillä (erot noin 24.63, 60.10 ja 35.47). Mielenkiintoisempaa on kuitenkin tarkastella yhteisvaikutusten eroja, joista esiin voidaan nostaa asumisahtauden eri luokkien väliset merkittävät erot (etenkin verrattuna luokkaan *ahdas*) molemmilla kuntamuodon luokilla.

Käytännössä voidaan siis todeta sekä kuntamuodolla *kumu* että asumisahtaudella *ahtas* olevan tilastollisesti merkittävä ja silminnähden selkeä vaikutus asunnon pinta-alaan *pala*.