

TILM3702 — Kotitehtävä 2

Arttu Einistö

April 14, 2024

Kategoriset muuttujat: loglineaarinen malli ja sen tulkinta

Kategoristen muuttujien välisiä riippuvuusrakenteita voidaan tutkia loglineaaristen mallien avulla. Tässä tapauksessa kiinnostuksen kohteina ovat 1000 havainnon otoksessa kaksikategoriset muuttujat sukupuoli ($d2$) ja äänestyspäättös ($k23$) sekä viisikategorinen muuttuja siviilisääty ($d4$).

Tutkittavaa otosta voidaan havainnollistaa erilaisin frekvenssitauluin:

Sukupuoli	Lkm.	Vastaus	Lkm.
Mies	439	en	294
Nainen	461	kyllä	472

Siviilisääty	Lkm.
Naimaton	202
Avoliitossa tai muussa rekisteröidyssä parisuhteessa	394
Avoliitossa	123
Eronnut tai asumuserossa	119
Leski	62

```
> # Kolmen muuttujan taulu
> mytable <- table(d2,d4,k23)
> ftable(mytable)
```

		k23	en	kyllä
d2	d4			
Mies	Naimaton	25	58	
	Avoliitossa tai muussa rekisteröidyssä parisuhteessa	55	148	
	Avoliitossa	14	23	
	Eronnut tai asumuserossa	18	23	
	Leski	3	10	
Nainen	Naimaton	34	41	
	Avoliitossa tai muussa rekisteröidyssä parisuhteessa	68	90	
	Avoliitossa	26	29	
	Eronnut tai asumuserossa	28	32	
	Leski	23	18	

Loglineaarisen mallin oletukset

Loglineaaristen mallien käyttöön liittyvät keskeisesti odotukset aineiston satunnaisuudesta, riippumattomuudesta ja kategoriakohtaisten havaintojen lukumäärästä. Solufrekvenssejä voidaan tarkastella esim. aiemmin muodostetun kolmen muuttujan taulun avulla, josta nähdään että aineistossa ei ole nollasoluja (pienin solufrekvenssi 3). Vaihtoehtoisesti nollasolujen olemassaoloa voidaan tutkia R:n totuusarvon palauttavalla komennolla `any(mytable == 0)`.

Loglineaarisen mallin ajo

Mallia valittaessa pyritään valitsemaan mahdollisimman yksinkertainen malli, jonka yhteensopivuustestin p-arvo ylittää merkitsevyystason 0.1. Mallit voidaan muodostaa R:llä:

```

> loglm(~d2+d4+k23, mytable) # Täydellinen riippumattomuus
Call:
loglm(formula = ~d2 + d4 + k23, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 55.78542 13 2.940499e-07
Pearson          58.58682 13 9.387165e-08

> loglm(~d2+d4+k23+d2*k23, mytable) # d4 riippumaton muuttujaparista
Call:
loglm(formula = ~d2 + d4 + k23 + d2 * k23, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 36.18881 12 0.0003021083
Pearson          35.58327 12 0.0003779125

> loglm(~d2+d4+k23+d2*d4+d2*k23, mytable) # d4 ja k23 riippumattomia
Call:
loglm(formula = ~d2 + d4 + k23 + d2 * d4 + d2 * k23, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 7.956124 8 0.4377678
Pearson          8.169361 8 0.4171039

> loglm(~d2+d4+k23+d2*d4+d4*k23, mytable) # d2 ja k23 riippumattomia
Call:
loglm(formula = ~d2 + d4 + k23 + d2 * d4 + d4 * k23, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 19.33117 5 0.001667325
Pearson          19.13937 5 0.001810553

> loglm(~d2+d4+k23+d4*k23, mytable) # d2 riippumaton muuttujaparista
Call:
loglm(formula = ~d2 + d4 + k23 + d4 * k23, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 47.56386 9 3.080893e-07
Pearson          45.23290 9 8.355017e-07

> loglm(~d2+d4+k23+d2*d4, mytable) # k23 riippumaton muuttujaparista
Call:
loglm(formula = ~d2 + d4 + k23 + d2 * d4, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 27.55273 9 0.001132549
Pearson          27.15464 9 0.001318700

> loglm(~d2+d4+k23+d2*k23+d2*k23, mytable) # d2 ja d4 riippumattomia
Call:
loglm(formula = ~d2 + d4 + k23 + d2 * k23 + d2 * k23, data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 36.18881 12 0.0003021083
Pearson          35.58327 12 0.0003779125

> loglm(~d2+d4+k23+d2*d4+d4*k23+d2*k23, mytable)
Call:
loglm(formula = ~d2 + d4 + k23 + d2 * d4 + d4 * k23 + d2 * k23,
      data = mytable)

Statistics:
              X^2 df      P(> X^2)
Likelihood Ratio 3.404386 4 0.4925648
Pearson          3.349217 4 0.5011723

```

Tulosteista nähdään, että potentiaalisia ehdot täyttäviä malleja ovat parittaisten riippuvuussuhteiden malli ($p \approx 0.4926$) sekä ehdollinen riippumattomuusmalli, jossa siviilisäätö $d4$ ja äänestyspäätös $k23$ ovat riippumattomia ($p \approx 0.4378$).

Malleista jälkimmäinen on yksinkertaisempi, joten valitaan se. Kyseisen mallin generoiva luokka on $\{d2*d4, d2*k23\}$. Mallia voitaisiin tulkita käytännönläheisesti esim. niin, että sukupuoli on merkitystä sekä siviilisäätöyn että äänestyspäätökseen, mutta siviilisäädellä ja äänestyspäätöksellä ei ole tilastollisesti merkittävää vaikutusta toisiinsa.

Ristiintaulut

Valitun mallin tulkintaan tarvitaan kaksi ristiintaulua:

```

> taulu1 <- table(d4, d2)
> prop.table(taulu1, 1)

              d2
d4
Naimaton      0.5346535 0.4653465
Avoliitossa tai muussa rekisteroidyssa parisuhteessa 0.5532995 0.4467005
Avoliitossa    0.4390244 0.5609756
Eronnut tai asumuserossa 0.3865546 0.6134454
Leski          0.2096774 0.7903226
> taulu2 <- table(k23, d2)
> prop.table(taulu2, 1)

              d2
k23
en      0.3911565 0.6088435
kylla  0.5550847 0.4449153

```

R:llä muodostetuista ristiintauluista nähdään, että naiset ovat huomattavassa enemmistössä niiden vastanneiden keskuudessa, jotka eivät aio äänestää. Siviilisäädyn suhteen naiset ovat selkeässä enemmistössä leskien sekä eronneiden kategorioissa. Siviilisäädyllä ja päätöksellä äänestää ei puolestaan ole yhteyttä keskenään.